REDES NEURONAIS ARTIFICIAIS

Luís Morgado

ISEL-DEI

APRENDIZAGEM AUTOMÁTICA

Capacidade de um sistema computacional adquirir conhecimento, adaptar-se a nova informação e melhorar o seu desempenho ao longo do tempo

Aprendizagem = Melhoria de **desempenho**,
para uma dada **tarefa**,
com a **experiência**

- Melhorar o desempenho para uma dada **tarefa *T***
- Com base numa medida de **desempenho *D***
- Com base na **experiência *E***

Exemplo: Aprender a reconhecer escrita manual

T: Reconhecer e classificar caracteres escritos manualmente

D: Percentagem de caracteres reconhecidos correctamente

E: Conjunto de exemplos de caracteres e respectiva classificação

APRENDIZAGEM AUTOMÁTICA

A aprendizagem não corresponde a uma simples memorização de informação, requere a capacidade de generalização, para que o conhecimento resultante da experiência obtida possa ser aplicado em situações diferentes das que foram observadas e serviram de base à aprendizagem

Aprendizagem ≠ Memorização

- Aprendizagem
  - **Generalização**
  - Formação de **abstracções** (**modelos**), que podem ter diferentes formas
    - Protótipos com características gerais
    - Modelos de conceitos (e.g. redes neuronais)
    - Padrões comportamentais (e.g. funções *estado-acção-valor*)

VERTENTES DE APRENDIZAGEM

- **Aprendizagem conceptual**
  - Aprender "*o que é*"
    - Conceitos
  - **Exemplo**:
    - Redes neuronais artificiais
- **Aprendizagem comportamental**
  - Aprender "*como fazer*"
    - Comportamentos
  - **Exemplo**:
    - Aprendizagem por reforço

APRENDIZAGEM AUTOMÁTICA

Abordagens principais de aprendizagem automática:

- **Aprendizagem supervisionada**
  - O sistema é treinado com um conjunto de dados etiquetados, onde cada entrada é associada a uma saída conhecida
- **Aprendizagem não supervisionada**
  - O sistema é treinado com dados não etiquetados e deve encontrar padrões ou regularidades nos dados de forma autónoma
- **Aprendizagem por reforço**
  - O sistema recebe recompensas ou penalizações com base nas suas acções, de modo a maximizar as recompensas e a minimizar as penalizações ao longo do tempo

REDES NEURONAIS ARTIFICIAIS

- **As *redes neuronais artificiais* são um modelo computacional derivado do estudo de sistemas nervosos biológicos**, em particular do cérebro, caracterizadas por processamento distribuído massivo e com capacidade de aprendizagem
- **São compostas por múltiplas unidades individuais de processamento, designadas *neurónios***, interligadas entre si e organizadas em *camadas*
- **As redes neuronais artificiais têm-se mostrado eficazes na resolução de problemas complexos** que envolvem dados não estruturados e relações não lineares, para os quais são difíceis ou mesmo desconhecidas soluções com base noutros modelos computacionais e métodos de programação

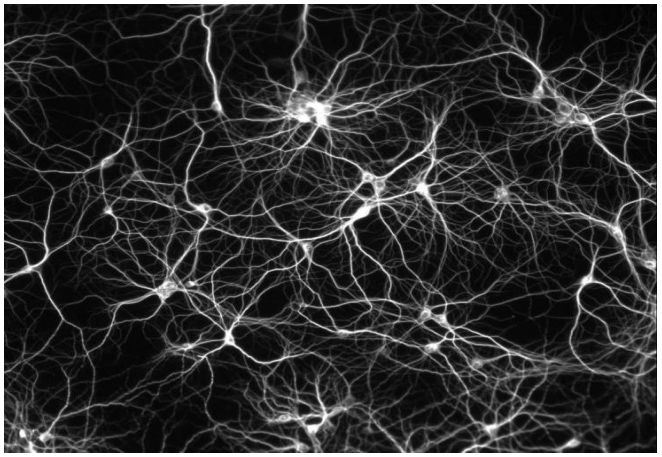


Ilustração de uma rede neuronal biológica

REDES NEURONAIS ARTIFICIAIS

Etapas principais de desenvolvimento

Surgimento na década de 1940

- **1943**: Modelo de neurónio proposto por McCulloch e Pitts, com a capacidade de discriminar entre categorias distintas de valores de entrada

1950 - 1960 – Primeiras arquitecturas de redes neuronais artificiais

- **1958**: Frank Rosenblatt propõe um modelo linear designado *Perceptrão*, o primeiro neurónio artificial com capacidade de aprendizagem
- **1969**: Minsky e Papert apresentam as limitações associadas ao *Perceptrão*, essas limitações levam a uma diminuição do entusiasmo no estudo e desenvolvimento de redes neuronais artificiais

REDES NEURONAIS ARTIFICIAIS

Etapas principais de desenvolvimento

1980 - 1990 – Retropropagação, conexionismo

- **1986**: Rumelhart apresenta um método de treino de redes multicamada baseado no conceito de retropropagação e propõe o conceito de conexionismo – ênfase na capacidade de processamento massivamente distribuído das redes neuronais
- **Década de 1990**: Retomar do interesse no estudo e desenvolvimento de redes neuronais artificiais

2000 - 2020 – Aprendizagem profunda

- **Década de 2000**: Avanços importantes nas tecnologias de redes neuronais artificiais, com o surgimento do conceito de aprendizagem profunda (*Deep Learning*)
- **Década de 2020**: Desenvolvimento de grandes modelos de linguagem (*Large Language Models* - LLM) com base em redes neuronais profundas, inteligência artificial generativa

APLICAÇÕES DE REDES NEURONAIS ARTIFICIAIS

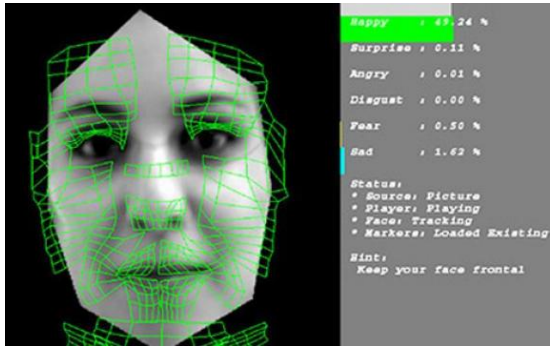
As redes neuronais artificiais têm sido amplamente utilizadas em diferentes áreas

Alguns exemplos de utilização:

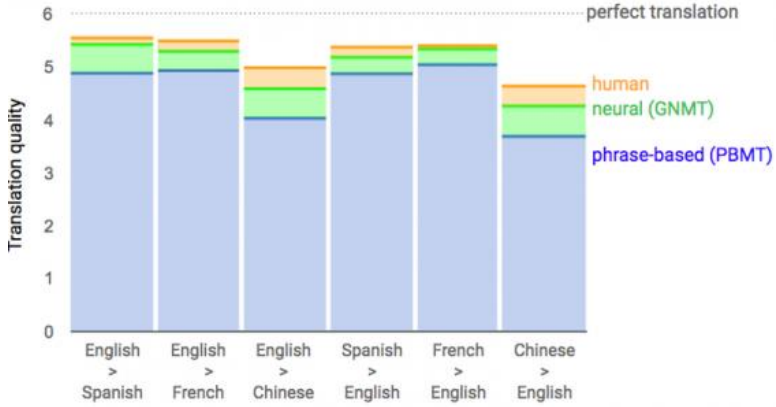
- Reconhecimento de padrões (imagens, voz, texto)
- Classificação e previsão (diagnóstico médico, análise de risco, previsão de vendas)
- Processamento de linguagem natural (tradução, geração de texto)
- Robótica e controlo de sistemas
- Detecção de fraudes
- Sistemas de recomendação
- Jogos e personagens virtuais



Reconhecimento de impressões digitais



Detecção de emoções em faces



Tradução automática

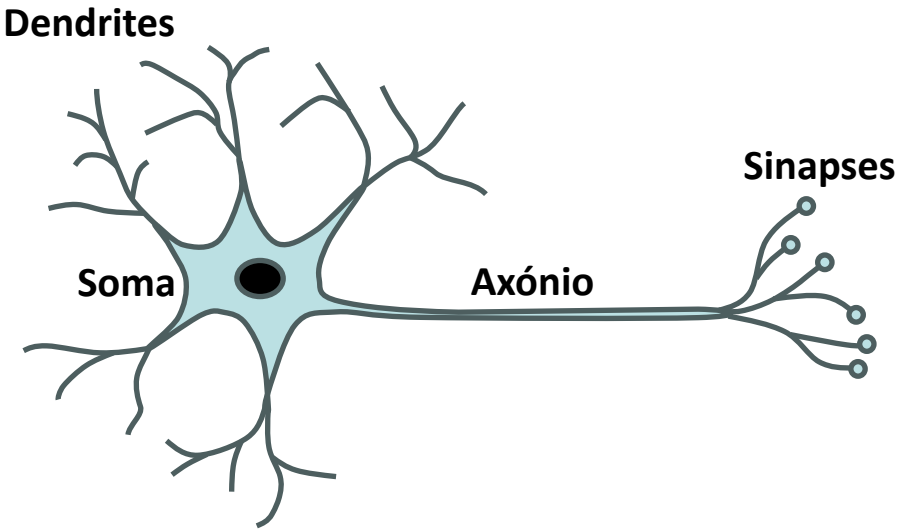
REDES NEURONAIS ARTIFICIAIS

Características das redes neuronais artificiais (RNA):

- **Aprendizagem com base em exemplos**
  - As RNA aprendem a partir de dados de treino, tendo capacidade de melhorar o seu desempenho com a experiência
- **Capacidade de generalização**
  - Após o treino, as RNA podem aplicar o conhecimento adquirido a novos dados, para os quais não foram explicitamente treinadas
- **Processamento distribuído**
  - As RNA realizam o processamento de dados de forma massivamente distribuída, o que as torna capazes de lidar com tarefas complexas que envolvem grandes quantidades de dados
- **Tolerância a falhas**
  - As RNA são resilientes a falhas locais, pois o conhecimento está distribuído por toda a rede, não concentrado num único ponto de processamento

MODELO DE NEURÓNIO

Modelo simplificado de neurónio biológico



Dendrites - Responsáveis por receber informação de outros neurónios

Soma - Corpo do neurónio, responsável por processar a informação recebida a partir das dendrites e produzir um resultado na forma de impulsos eléctricos

Axónio - Responsável por transmitir o resultado produzido

Sinapse - Ponto de ligação do neurónio a outros neurónios

As sinapses controlam a influência das entradas para a resposta de um neurónio, através da permeabilidade à transmissão de sinais químicos e eléctricos

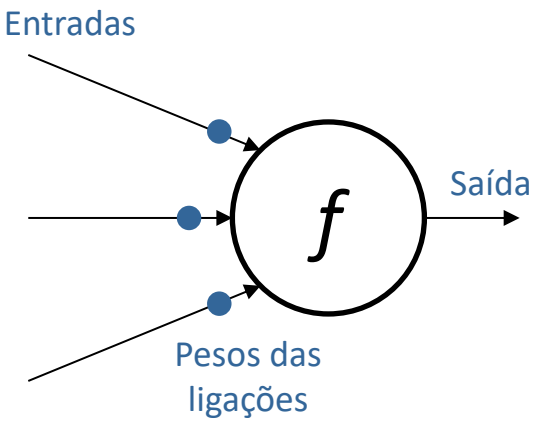
A variabilidade da permeabilidade de cada sinapse é determinante para a aprendizagem

NEURÓNIO ARTIFICIAL

Um neurónio artificial é a unidade básica de processamento de uma rede neuronal artificial, o seu modelo é inspirado no que se conhece do funcionamento de neurónios biológicos

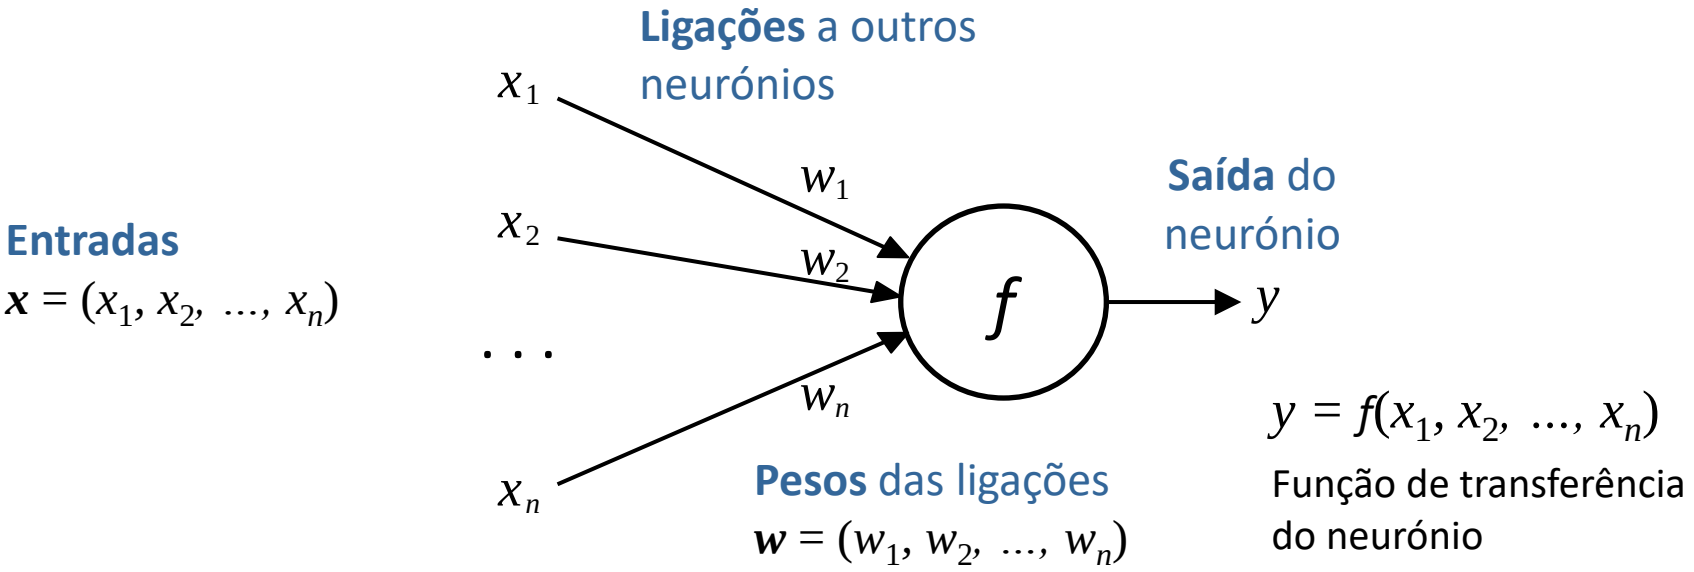
Um neurónio artificial é composto por quatro elementos principais:

- **Entradas**
  - Sinais de entrada que chegam ao neurónio através de ligações com outros neurónios ou com as entradas da rede
- **Pesos** (das ligações)
  - Valores que representam a permeabilidade sináptica, ou seja, a influência de cada ligação para a resposta do neurónio
- **Função de transferência *f***
  - Função que determina o processamento das entradas para gerar a saída do neurónio
- **Saída**
  - Sinal de saída do neurónio, o qual pode ser enviado a outros neurónios da rede ou ser directamente a saída da rede



MODELO DE NEURÓNIO ARTIFICIAL

Modelo geral de neurónio artificial

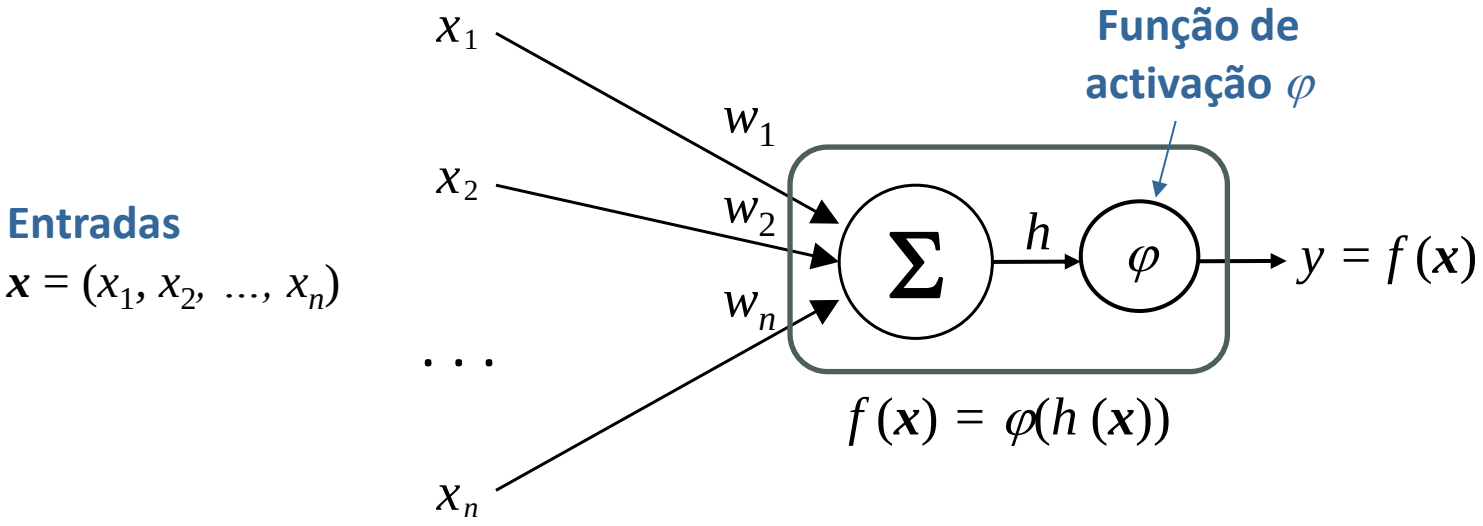


Os pesos das ligações controlam a influência das entradas na activação do neurónio

No processo de aprendizagem, os pesos das ligações são ajustados para minimizar o erro entre o valor de saída a aprender e o valor de saída gerado y

MODELO DE NEURÓNIO ARTIFICIAL

Modelo geral de neurónio artificial



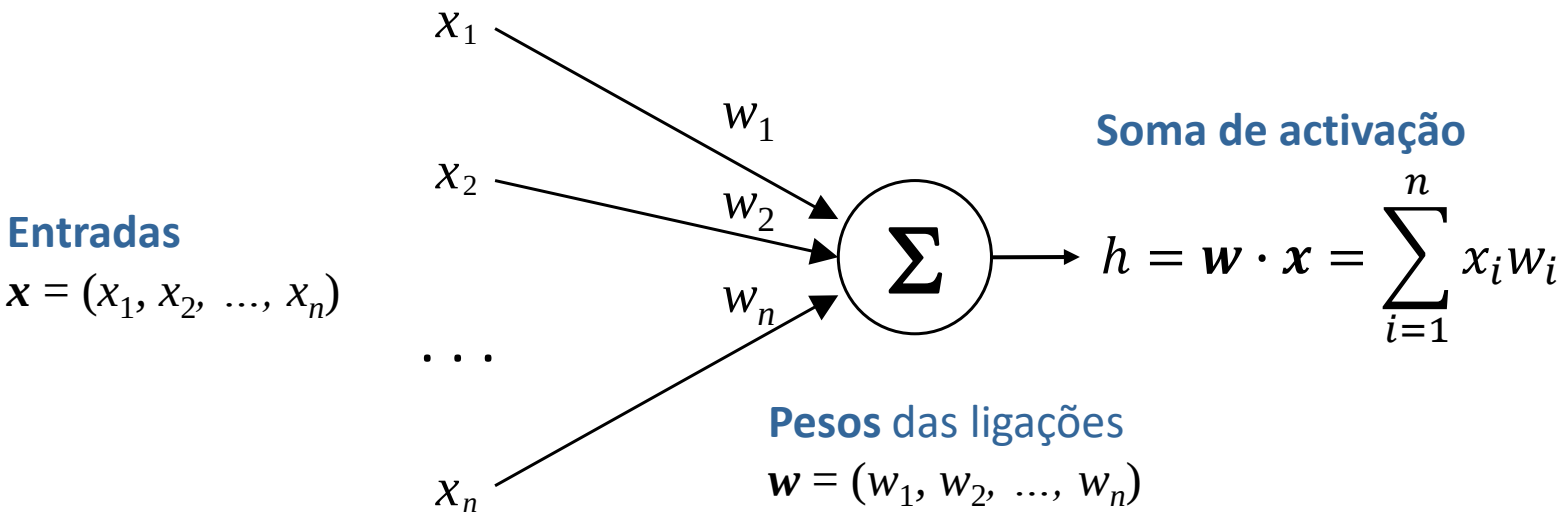
O modelo geral de um neurónio artificial pode ser representado por um vector de entradas $\boldsymbol{x} = (x_1, x_2, \ldots, x_n)$ e por um vector de pesos $\boldsymbol{w} = (w_1, w_2, \ldots, w_n)$, em que cada entrada x_i possui um peso associado w_i, representando a permeabilidade da sinapse, ou seja, a influência da ligação para a resposta do neurónio

A **função de transferência** f é definida como a **soma de activação** h, *a* soma ponderada das entradas pelos respectivos pesos (produto escalar entre os vectores $\boldsymbol{x}$ e $\boldsymbol{w}$), à qual é aplicada uma **função de activação** φ que determina a resposta produzida

MODELO DE NEURÓNIO ARTIFICIAL

Soma de activação

Soma das entradas ponderadas pelos pesos respectivos



O valor do produto escalar $\boldsymbol{w} \cdot \boldsymbol{x}$ entre as entradas do neurónio e os pesos das respectivas ligações, representa uma medida de semelhança entre o vector de entrada $\boldsymbol{x}$ e o vector de pesos $\boldsymbol{w}$

Quanto maior o valor do produto interno, mais o vector de entrada está alinhado com o vector de pesos, resultando numa maior possibilidade de activação do neurónio

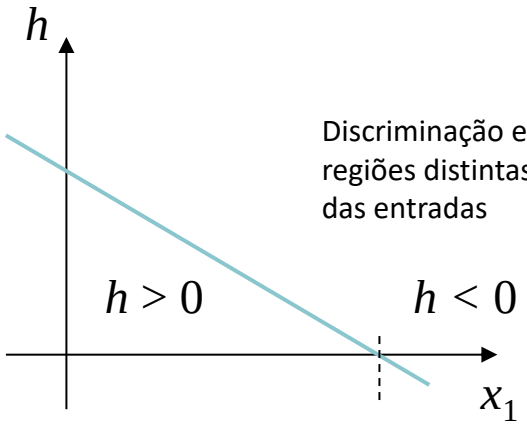
Nesse sentido, cada neurónio pode ser visto como representando um protótipo de dados que a rede tem capacidade de reconhecer

MODELO DE NEURÓNIO ARTIFICIAL

Interpretação geométrica

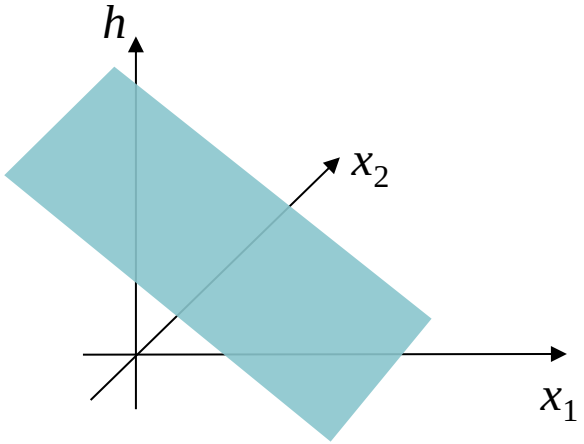
Um neurónio define uma **fronteira de discriminação** no *espaço das entradas*, que pode ser uma *recta*, um *plano* ou, no caso geral, um *hiperplano*, em função do número de entradas

Recta



$$h = w_1 x_1$$

Plano



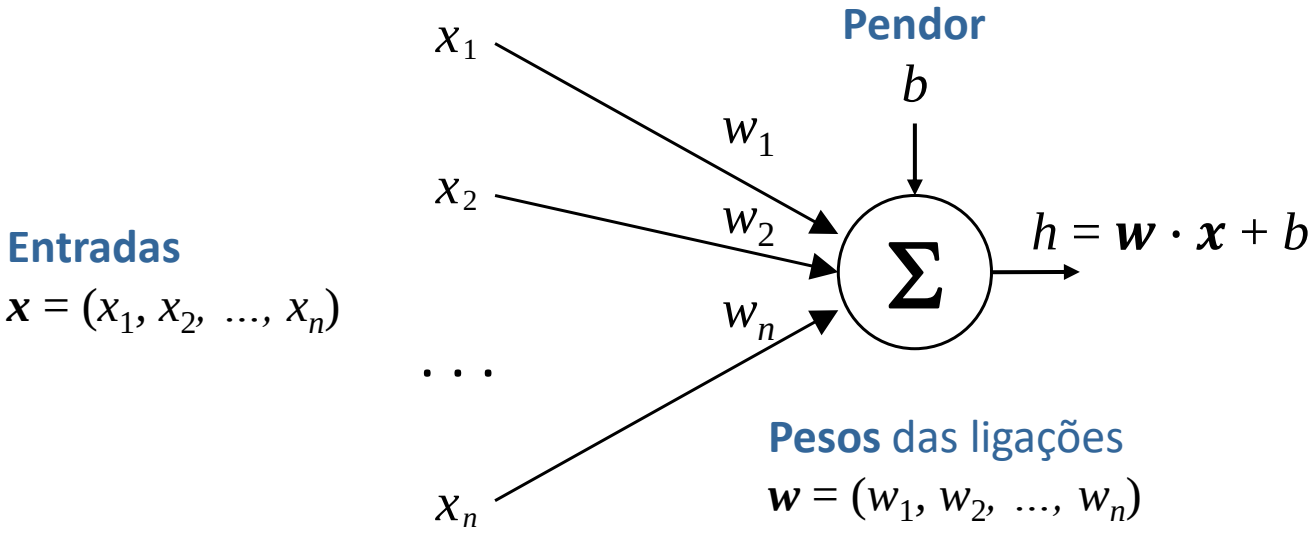
$$h = w_1 x_1 + w_2 x_2$$

Hiperplano (neurónio com *n* entradas)

$$h = \sum_{i=1}^{n} x_i w_i = w_1 x_1 + w_2 x_2 + \cdots + w_n x_n$$

MODELO DE NEURÓNIO ARTIFICIAL

Pendor de activação

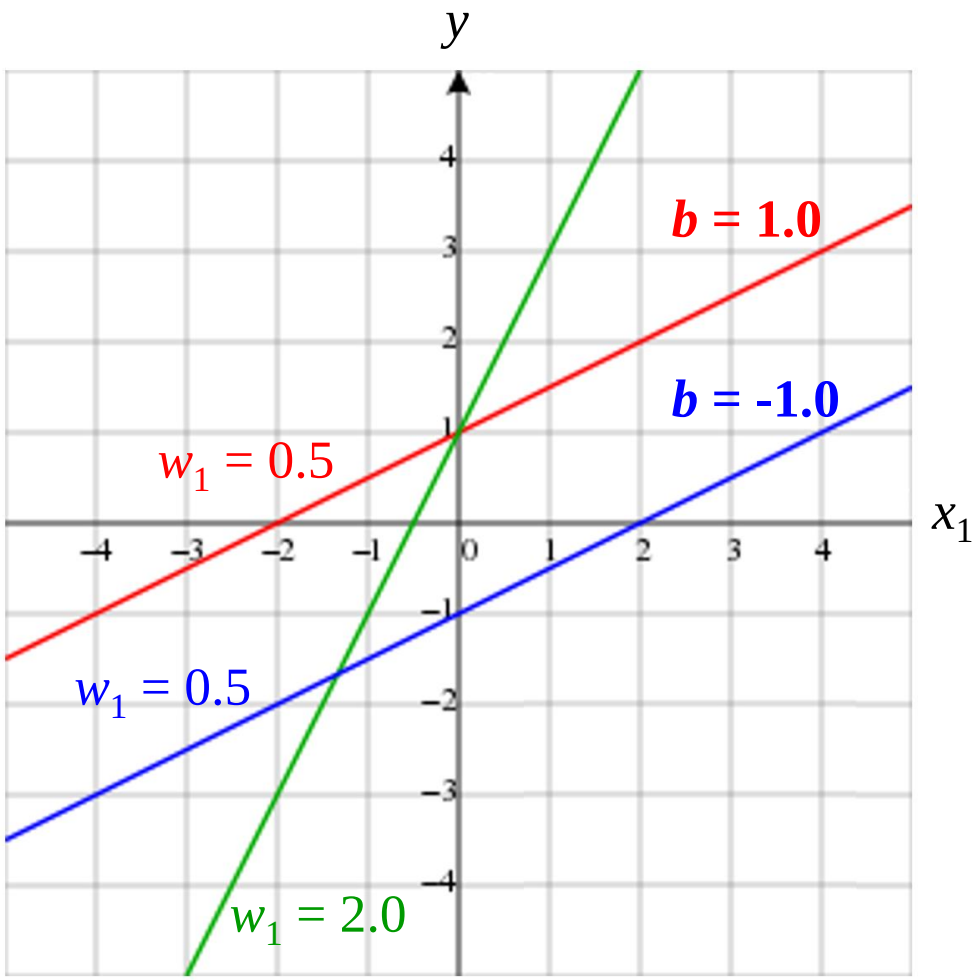


O pendor b de um neurónio artificial é um parâmetro que possibilita o ajuste do limiar de activação da rede

Geometricamente, determina a deslocação da fronteira de discriminação definida por $h = \boldsymbol{w} \cdot \boldsymbol{x} + b$

MODELO DE NEURÓNIO ARTIFICIAL

Interpretação geométrica



O **pendor** de um neurónio determina a deslocação da fronteira de discriminação definida por $h = \boldsymbol{w} \cdot \boldsymbol{x} + b$

Os **pesos** determinam o declive (orientação) da fronteira de discriminação

Exemplo:

$h = w_1 x_1 + b$
(neurónio com uma entrada x_1)

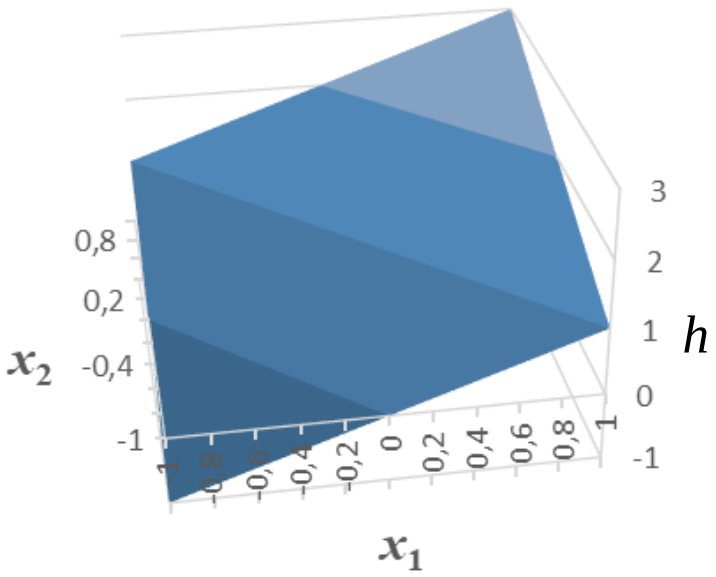
$w_1 = 2.0, b = 1.0$
$w_1 = 0.5, \boldsymbol{b = 1.0}$
$w_1 = 0.5, \boldsymbol{b = -1.0}$

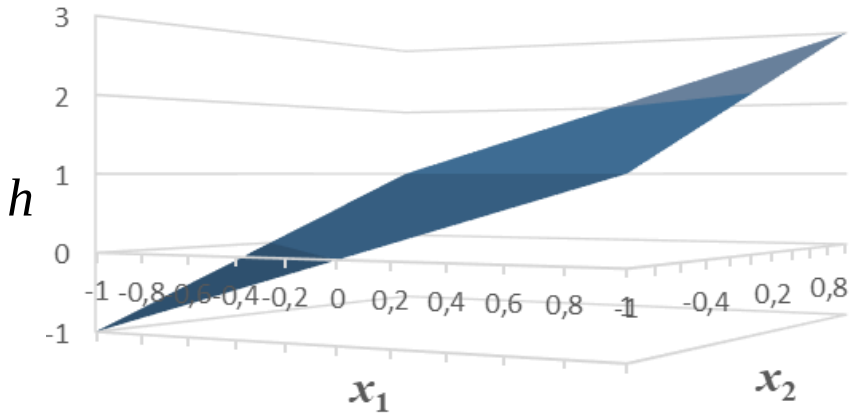
MODELO DE NEURÓNIO ARTIFICIAL

Interpretação geométrica

Exemplo: Neurónio com duas entradas x_1 e x_2

$$h = w_1 x_1 + w_2 x_2$$



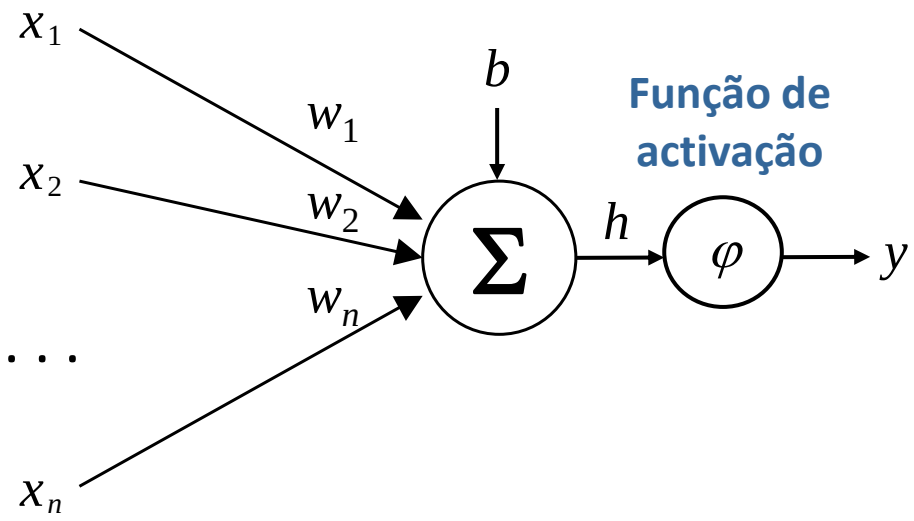


Plano que delimita a fronteira de discriminação no *espaço das entradas*

MODELO DE NEURÓNIO ARTIFICIAL

Função de activação

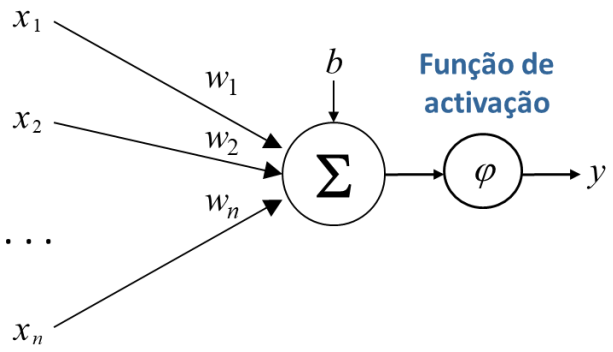
A função de activação $y = \varphi(h)$ é responsável por determinar a saída do neurónio com base na sua soma de activação h, resultante do produto escalar das entradas e dos pesos sinápticos, somado com o pendor b

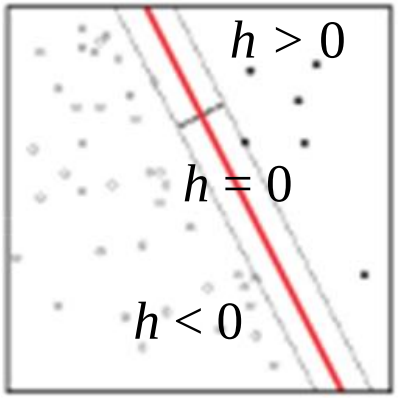


MODELO DE NEURÓNIO ARTIFICIAL

Objectivos da função de activação

- **Introduzir não linearidade**
  - A função de activação é responsável por introduzir um carácter não linear na resposta do neurónio
  - **Possibilita a discriminação entre padrões de dados**
- **Limitar a saída do neurónio**
  - A função de activação também serve para limitar a saída do neurónio a um intervalo de valores determinado
  - Evita que a saída do neurónio cresça indefinidamente, o que poderia causar problemas de estabilidade na rede





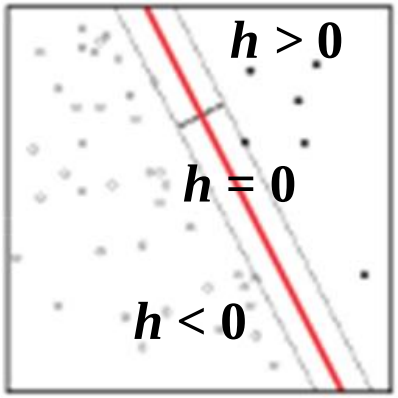
Discriminação entre padrões de dados devido ao carácter não linear da função de activação φ

FUNÇÃO DE ACTIVAÇÃO

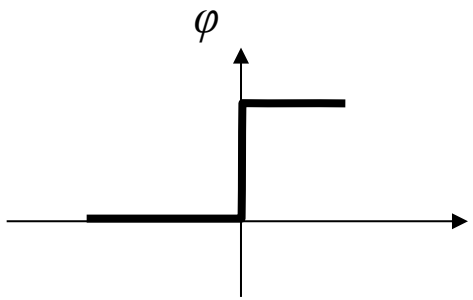
A função de activação determina o tipo de fronteira de separação no espaço das entradas, podendo ser uma transição abrupta, como no caso da função degrau, ou uma transição progressiva, como no caso da função linear por troços ou de uma função sigmoide

A **transição abrupta** determina uma **classificação booleana** (verdade / falso)

A **transição progressiva** determina um **grau de pertença** a uma determinada região (classe de dados)

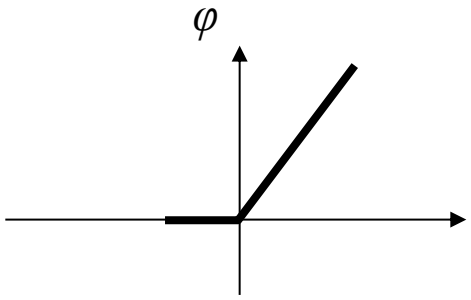


Exemplos de funções de activação



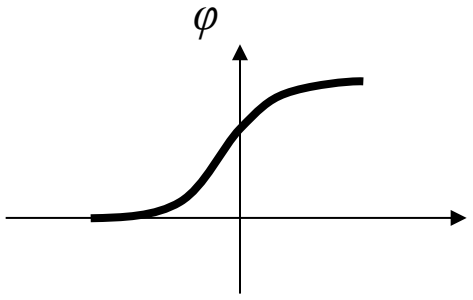
Degrau
(*Step*)

$$y = \begin{cases} 1 & \text{se } x \geq 0 \\ 0 & \text{se } x < 0 \end{cases}$$



Linear por troços
(*Rectified Linear Unit - ReLU*)

$$y = \begin{cases} x & \text{se } x > 0 \\ 0 & \text{se } x \leq 0 \end{cases}$$

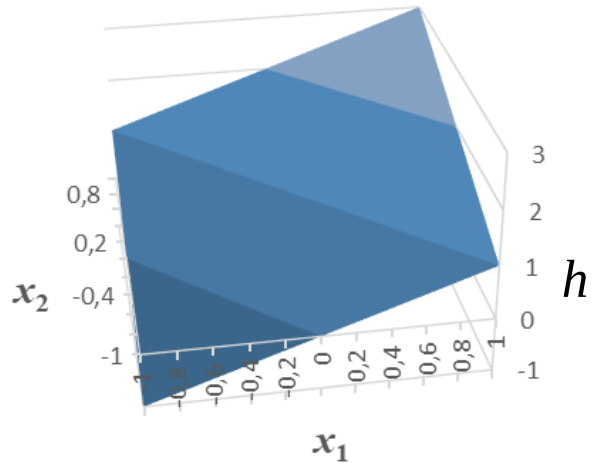


Sigmoide

$$y = \frac{1}{1 + e^{-x}}$$

EXEMPLO:

Neurónio com duas entradas x_1 e x_2

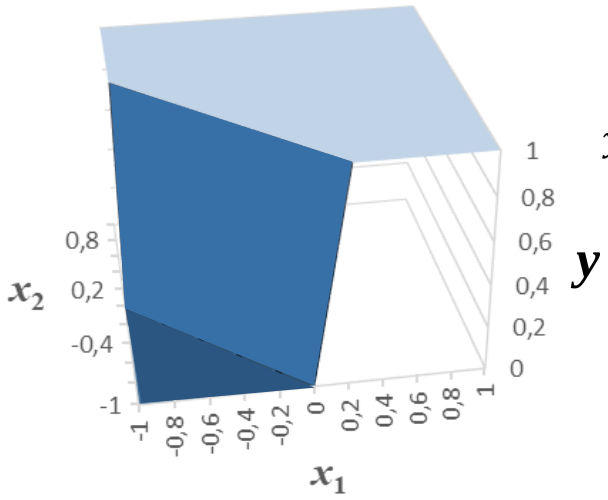


$$h = w_1 x_1 + w_2 x_2$$

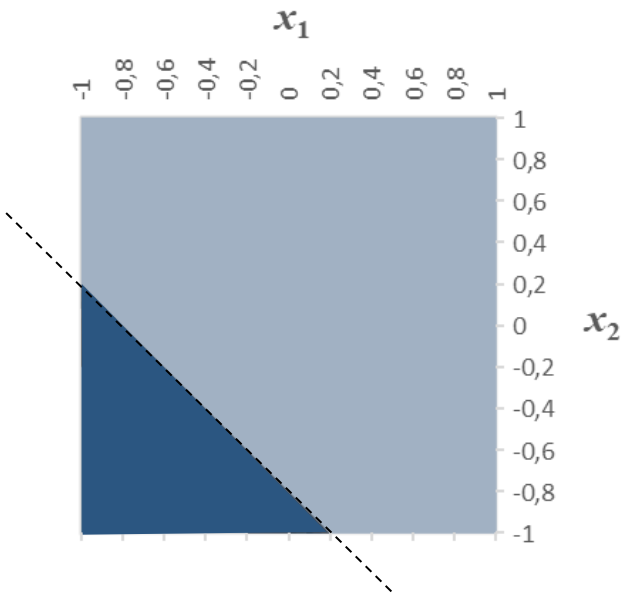
Plano que delimita a fronteira de discriminação no espaço das entradas

função de activação do tipo *degrau*

$$y = \begin{cases} 1 & \text{se } h \geq 0 \\ 0 & \text{se } h < 0 \end{cases}$$



Discriminação não linear por aplicação de uma função de activação do tipo *degrau*



Fronteira de discriminação resultante da aplicação de uma função de activação do tipo *degrau*

FUNÇÃO DE ACTIVAÇÃO

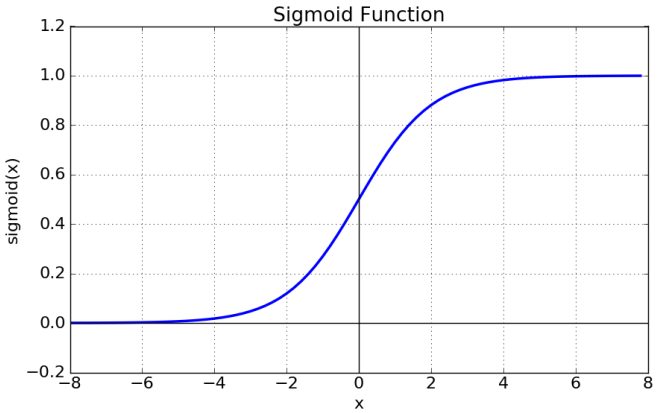
Exemplos de tipos de funções de activação:

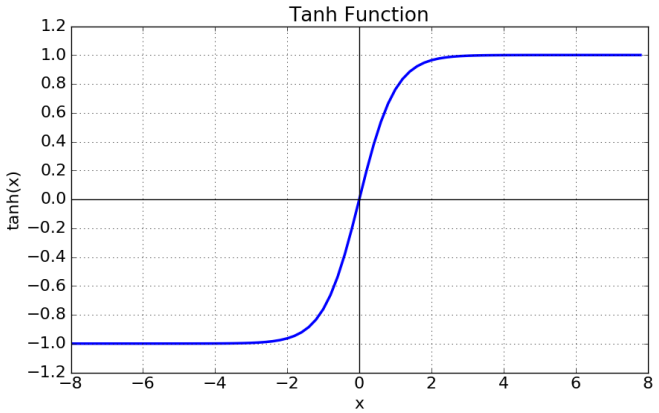
- **Função Degrau**
  - Produz o valor 0 se a soma de activação h for menor que um determinado limiar, e 1 no caso contrário
  - É uma função binária e **não diferenciável**
- **Função Sigmoide**
  - Produz um valor de activação no intervalo [0, 1]
  - Função diferenciável
- **Função Tangente Hiperbólica**
  - Produz um valor de activação no intervalo [-1, 1]
  - Função diferenciável
- **Função ReLU** (*Rectified Linear Unit*)
  - Produz o valor de activação h se este for positivo, e 0 caso contrário
  - É uma função linear por partes que possibilita um cálculo eficiente
  - Função diferenciável

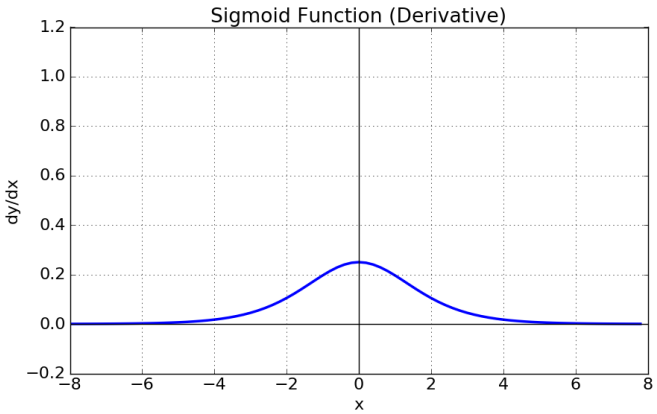
EXEMPLOS DE FUNÇÕES DE ACTIVAÇÃO

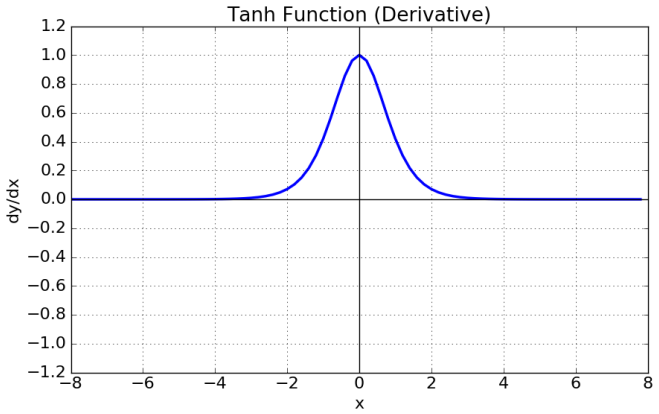
$$f(x_i) = \frac{1}{1+e^{-x_i}}, \quad f'(x_i) = \sigma(x_i)\,(1-\sigma(x_i))$$

$$f(x_i) = \tanh(x_i), f'(x_i) = 1 - \tanh(x_i)^2$$









A derivada de uma função de activação é relevante no contexto do processo de aprendizagem de uma rede neuronal artificial

FUNÇÃO DE ACTIVAÇÃO

- A escolha da função de activação depende do problema a ser resolvido e das características pretendidas para a rede neuronal
- A derivada da função de activação é relevante no contexto do processo de aprendizagem
  - Tem influência na convergência do treino e na capacidade de generalização da rede
- A escolha adequada da função de activação pode melhorar significativamente o desempenho da rede
  - Eficiência da aprendizagem
  - Capacidade de classificação

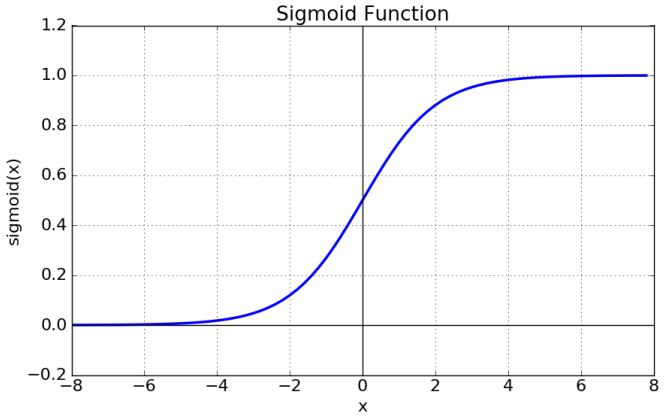
MODELO DE NEURÓNIO ARTIFICIAL

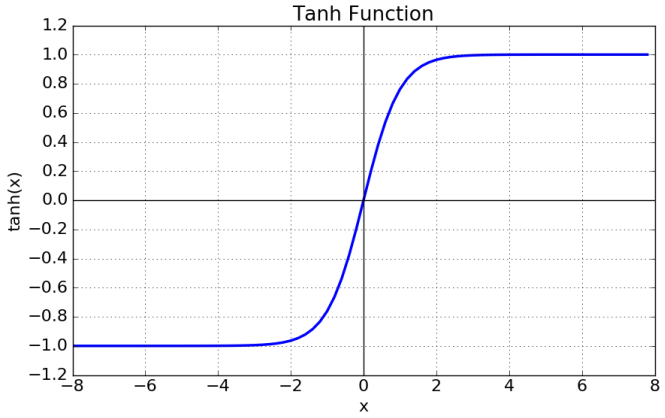
Codificação de entrada e de saída

A codificação de entrada e de saída determina os domínios de valores das entradas e das saídas da rede, nomeadamente:

- **Valores reais**
- **Valores booleanos**
  - **Codificação binária**
    - Verdade: 1
    - Falso: 0
  - **Codificação bipolar**
    - Verdade: +1
    - Falso: -1

O tipo de codificação deve ser considerado na definição de funções de activação, por exemplo a função sigmoide não admite valores de saída negativos, em alternativa, a função tangente hiperbólica (*tanh*), admite valores de saída negativos





MODELO DE NEURÓNIO ARTIFICIAL

Implementação de funções lógicas

- **Um neurónio artificial, com uma função de activação do tipo degrau , pode ser utilizado para implementar funções lógicas**, nomeadamente, conjunção (AND), disjunção (OR) e negação (NOT)
- A capacidade de implementar funções booleanas é um aspecto fundamental no desenvolvimento de redes neuronais artificiais
  - **Demonstra que os neurónios artificiais podem ser usados como blocos construtores para criar sistemas de processamento de informação mais complexos, capazes de resolver problemas gerais resolúveis por computadores digitais**
- Essa ligação entre neurónios artificiais e funções booleanas foi um dos primeiros desenvolvimentos importantes no âmbito das redes neuronais artificiais, pois mostrou a capacidade dos modelos baseados em redes neuronais biológicas [McCulloch & Pitts, 1943]

IMPLEMENTAÇÃO DE FUNÇÕES LÓGICAS

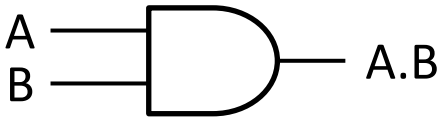
Exemplo: Conjunção (AND)

Codificação binária

A	B	A.B
0	0	0
0	1	0
1	0	0
1	1	1

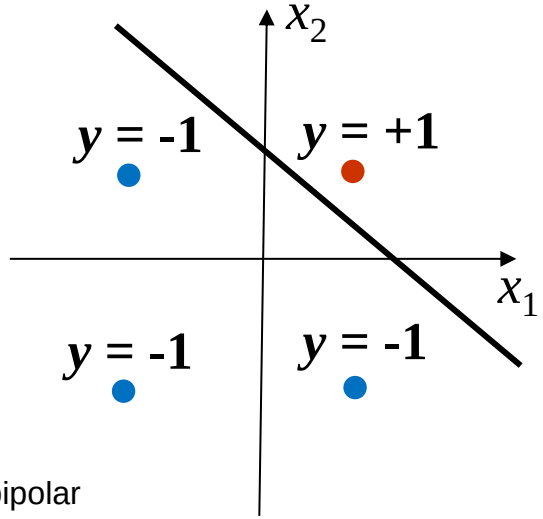
Codificação bipolar

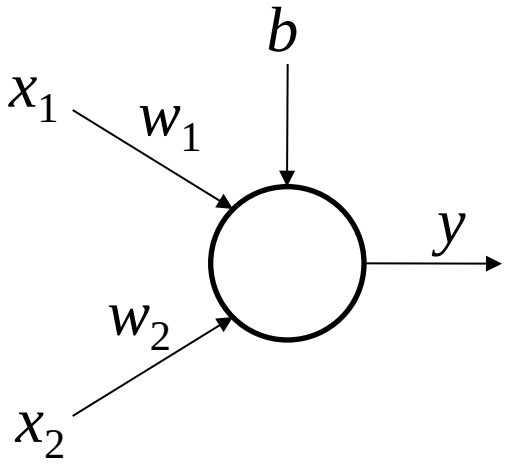
A	B	A.B
-1	-1	-1
-1	1	-1
1	-1	-1
1	1	1



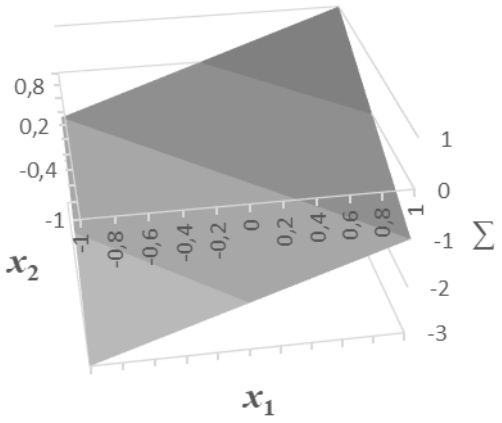
IMPLEMENTAÇÃO DE FUNÇÕES LÓGICAS

Conjunção (*AND*)





Codificação bipolar
Verdade: +1
Falso: -1



Exemplo:

$$w_1 = 1, w_2 = 1, b = -1$$

x_1	x_2	$\sum$	y
-1	-1	-3	-1
-1	1	-1	-1
1	-1	-1	-1
1	1	1	1

IMPLEMENTAÇÃO DE FUNÇÕES LÓGICAS

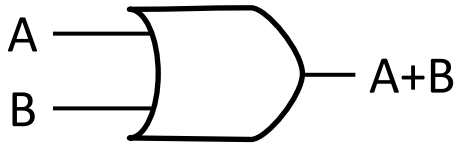
Exemplo: Disjunção (OR)

Codificação binária

A	B	A+B
0	0	0
0	1	1
1	0	1
1	1	1

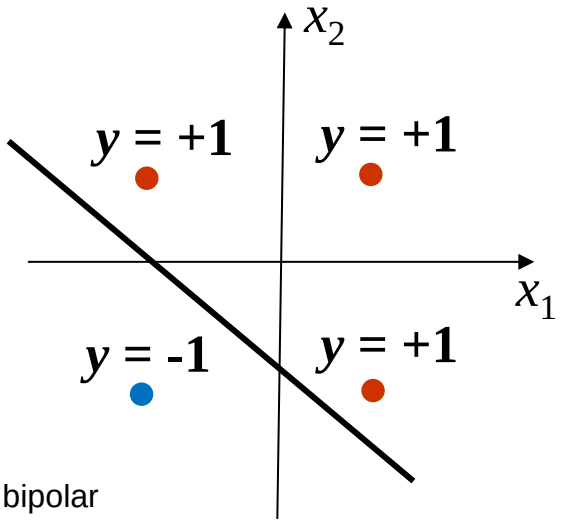
Codificação bipolar

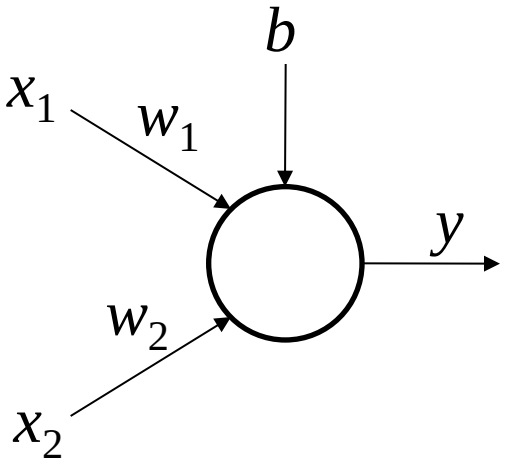
A	B	A+B
-1	-1	-1
-1	1	1
1	-1	1
1	1	1



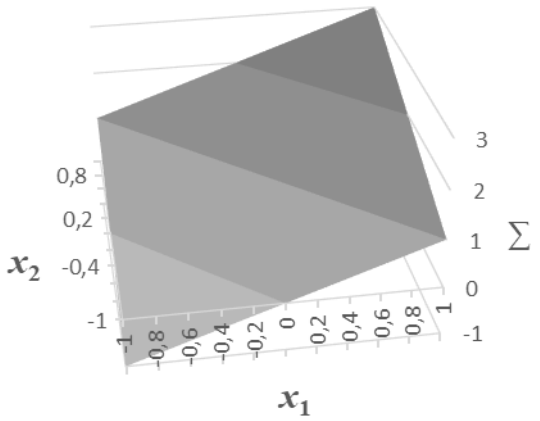
IMPLEMENTAÇÃO DE FUNÇÕES LÓGICAS

Disjunção (*OR*)





Codificação bipolar
Verdade: +1
Falso: -1



Exemplo:

$$w_1 = 1, w_2 = 1, b = 1$$

x_1	x_2	$\sum$	y
-1	-1	-1	-1
-1	1	1	1
1	-1	1	1
1	1	3	1

IMPLEMENTAÇÃO DE FUNÇÕES LÓGICAS

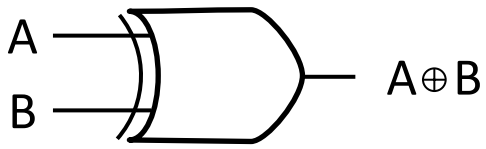
Exemplo: Disjunção exclusiva (XOR)

Codificação binária

A	B	A⊕B
0	0	0
0	1	1
1	0	1
1	1	0

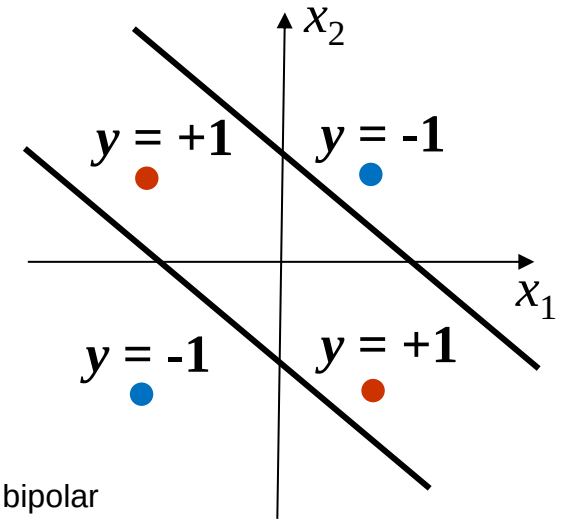
Codificação bipolar

A	B	A⊕B
-1	-1	-1
-1	1	1
1	-1	1
1	1	-1

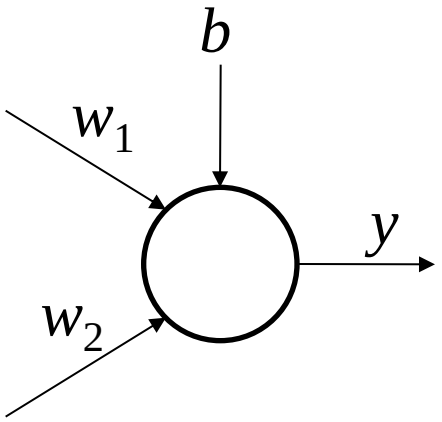


IMPLEMENTAÇÃO DE FUNÇÕES LÓGICAS

Disjunção exclusiva (*XOR*)



Codificação bipolar
Verdade: +1
Falso: -1



?

A disjunção exclusiva (XOR) não é possível de realizar com uma camada de neurónios, pois o resultado não pode ser determinado por uma única fronteira de separação linear

Problema da separabilidade linear

REDES NEURONAIS ARTIFICIAIS

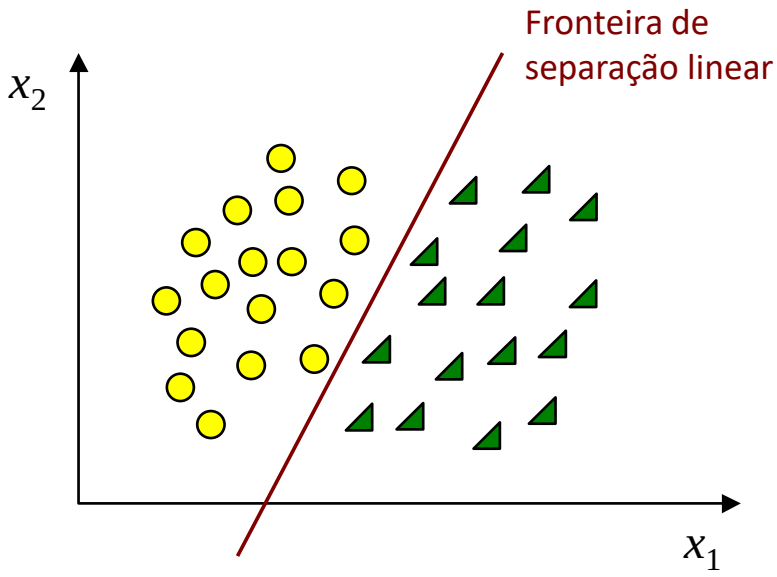
Capacidade computacional

- Que problemas são resolúveis por redes neuronais artificiais?
- Quais os limites computacionais das redes neuronais artificiais (ignorando restrições de tempo, espaço e recursos energéticos)?

CAPACIDADE COMPUTACIONAL DAS RNA

Separação linear

- O conceito de separação linear refere-se à capacidade de um neurónio artificial discriminar dois ou mais conjuntos de dados (classes) por meio de uma fronteira linear
- Dado um conjunto de dados com duas classes, representadas por pontos num espaço *n*-dimensional, esses dados são *linearmente separáveis* se existir um hiperplano que possibilite a separação completa das instâncias das duas classes

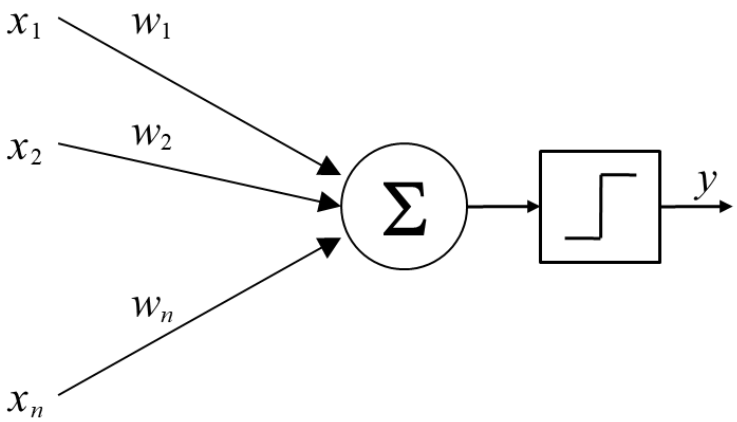


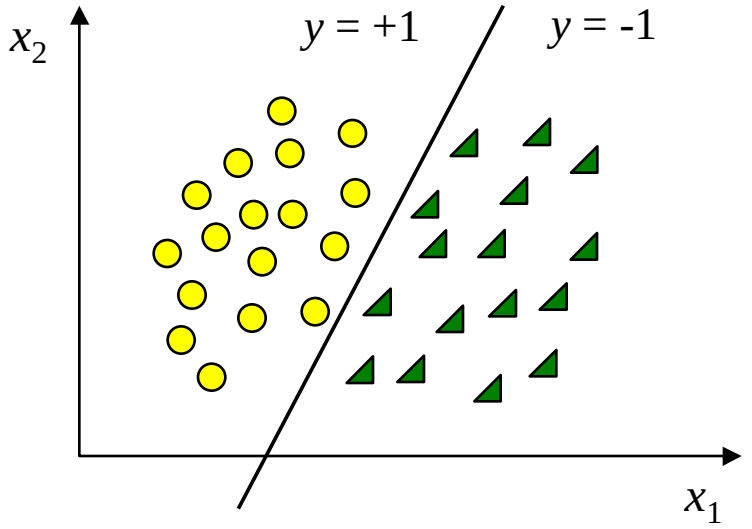
Exemplo de um conjunto de dados com duas classes separáveis linearmente

CAPACIDADE COMPUTACIONAL DAS RNA

Separação linear por um neurónio artificial

- Um **problema é linearmente separável** se existirem pesos w_i e pendor b que definam uma fronteira linear entre a *região da resposta excitadora* e a *região da resposta inibitória*
- **O perceptrão tem capacidade de resolver problemas linearmente separáveis**

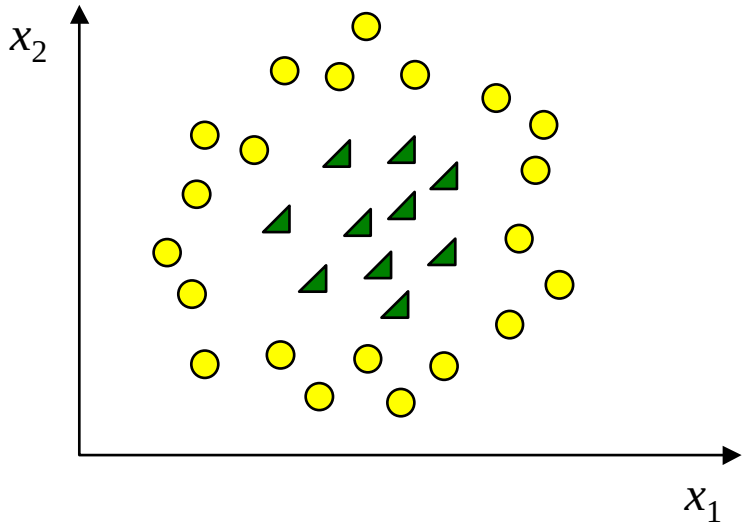




CAPACIDADE COMPUTACIONAL DAS RNA

Separação não linear

- No caso geral os problemas de classificação podem não ser linearmente separáveis
- As **redes de uma única camada**, como é o caso do perceptrão não têm capacidade de resolver problemas que não são separáveis linearmente
- Nessa situação, é necessário utilizar modelos de redes neuronais mais complexos, como redes neuronais com múltiplas camadas



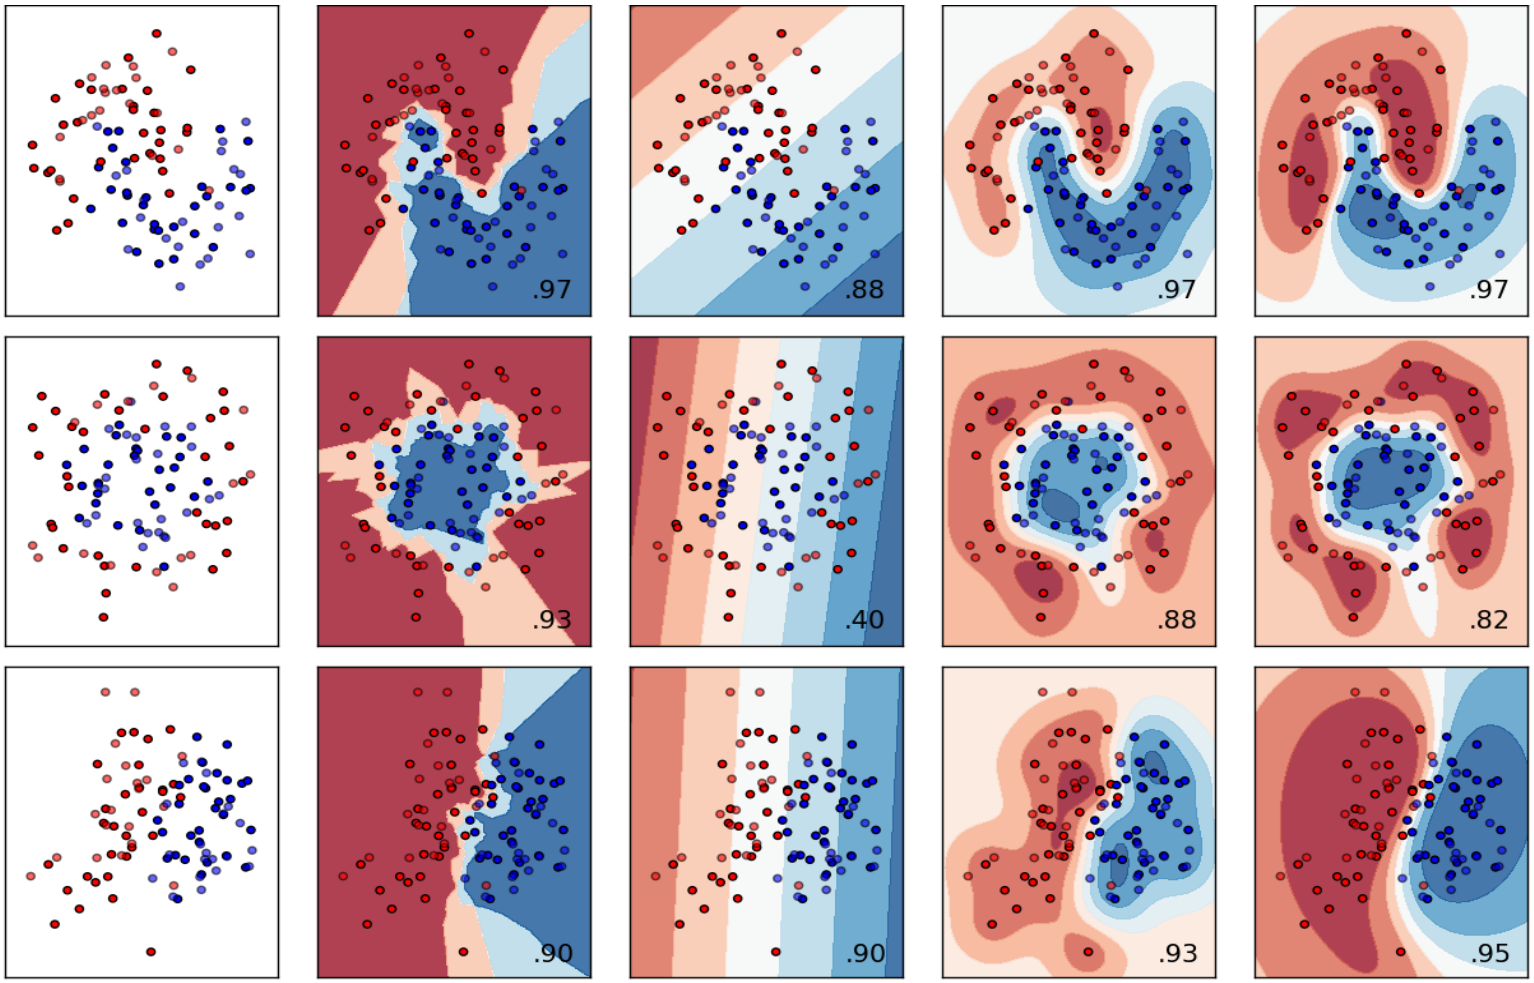
Exemplo de um conjunto de dados com duas classes não separáveis linearmente

SEPARAÇÃO NÃO-LINEAR

No caso geral, problemas complexos requerem a capacidade de separação não-linear

Exemplos:

Dados de entrada | Respostas de diferentes tipos de algoritmos de aprendizagem



[https://scikit-learn.org]

BIBLIOGRAFIA

[Aggarwal, 2018]
C. Aggarwal, Neural Networks and Deep Learning
Springer, 2018

[Munakata, 1998]
T. Munakata, *Fundamentals of the New Artificial Intelligence*, Springer, 1998

[Winston, 1992]
P. Winston, *Artificial Intelligence*, 3rd Edition, Addison-Wesley, 1992

[Raizer *et al.*, 2009]
K. Raizer, H. Idagawa, E. Nobrega, L. Ferreira, *Training and Applying a Feedforward Multilayer Neural Network in GPU*, CILAMCE, 2009

[Gutierrez-Osuna, 2005]
R. Gutierrez-Osuna*, Introduction to Pattern Analysis*, Texas A&M University, 2005

[LeCun *et al.*, 2015]
Y. LeCun, Y. Bengio, G. Hinton, *Deep learning*, Nature, Vol. 521, p. 436-444, 2015

[Deisenroth *et al*., 2020]
M. Deisenroth, A. Faisal, Cheng Soon Ong, *Mathematics for Machine Learning*, Cambridge University Press, 2020

[Rosenblatt, 1957]
F. Rosenblatt, *The Perceptron - A Perceiving and recognizing Automaton*, Report No. 85-460-1, Cornell Aeronautical Laboratory, 1957

[Minsky & Papert, 1969]
M. Minsky, S. Papert, *Perceptrons*. MIT Press, Cambridge, 1969

[McCulloch & Pitts, 1943]
W. McCulloch, W. Pitts, *A logical calculus of the ideas immanent in nervous activity*, Bulletin of Mathematical Biophysics, 5 (4): 115–133, 1943