PROCESSOS DE DECISÃO SEQUENCIAL

Luís Morgado

ISEL-DEI

INTELIGÊNCIA ARTIFICIAL

Dois problemas principais:

- **Problema da classificação**
  - Determinar "*o que é…*"
    - Discriminar informação nos dados processados
- **Problema da decisão**
  - Determinar "*o que fazer…*"
    - Decidir qual das opções de acção possíveis realizar

No caso geral, não são conhecidas soluções algorítmicas para estes problemas

- As soluções são produzidas por **aprendizagem**
  - Em particular, *redes neuronais artificiais* e *aprendizagem por reforço*

O PROBLEMA DA TOMADA DE DECISÃO

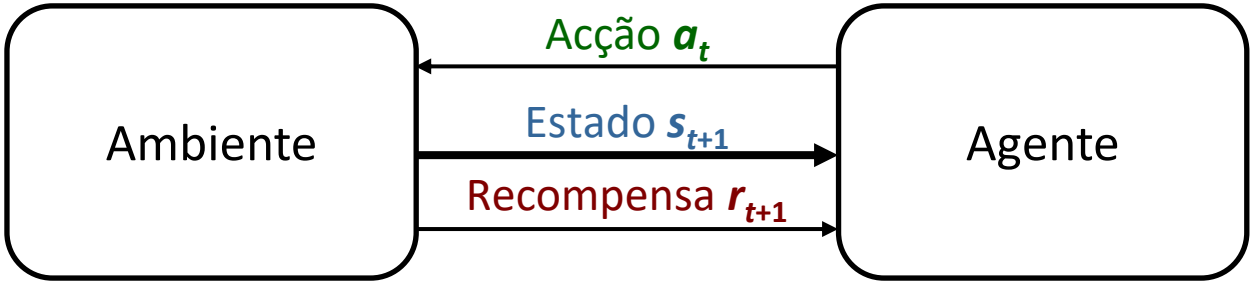
TOMADA DE DECISÃO

- Processo cognitivo que resulta na selecção de uma opção entre várias alternativas
- Baseada em alguma forma de **valor** ou preferência
  - Reflecte **propósito** (objectivo)
- **Teorias de racionalidade ilimitada**
  - Capacidade de representação e cálculo ilimitada
  - Representações completas e consistentes
  - Optimização
- **Teorias de racionalidade limitada**
  - Capacidade de representação e cálculo limitada
  - Utilização de heurísticas
  - Soluções aproximadas

O CONCEITO DE AGENTE

AGENTE

- Sistema computacional capaz de percepção, decisão e acção para concretização autónoma de objectivos, maximizando uma medida de desempenho
  - Cognição, racionalidade
- Opera num ambiente no qual num instante ***t*** executa acções a_t e observa estados s_{t+1} e recompensas r_{t+1}



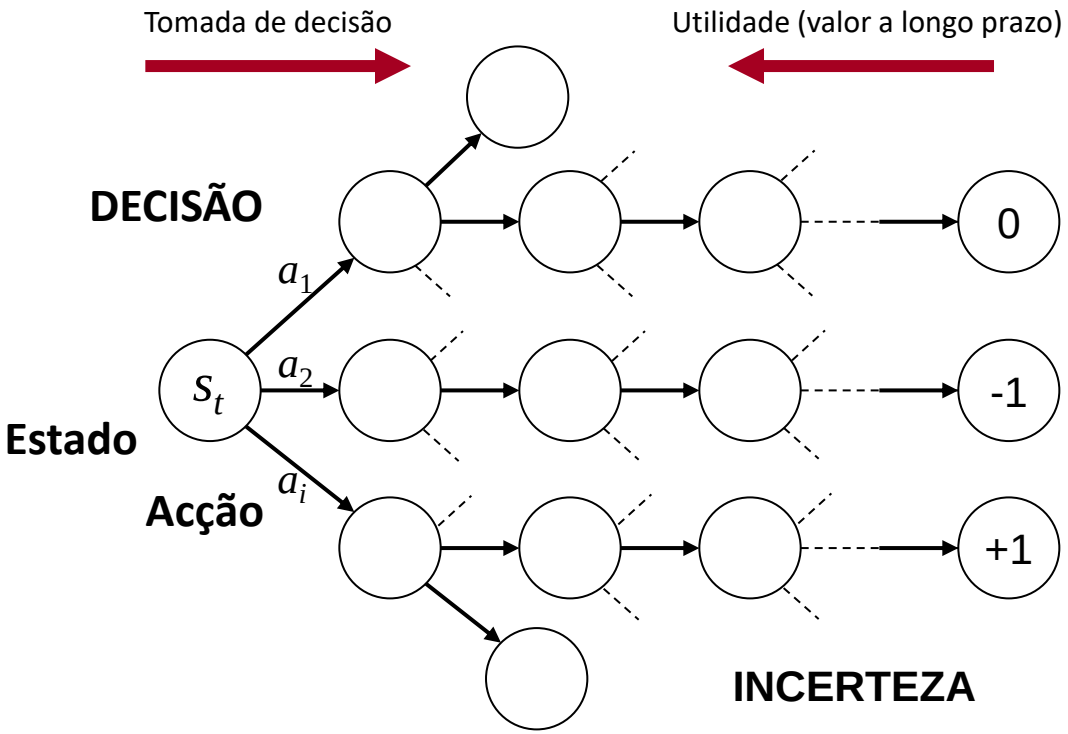
TOMADA DE DECISÃO SEQUENCIAL

Num processo de decisão geral, para cada estado s_n, cada decisão de acção (a_1, a_2, …, a_i) pode levar a **múltiplas ramificações de estados e decisões futuras**

O **valor** (*utilidade*) desses estados e decisões pode não ser conhecido de imediato, acontecendo apenas **diferido no tempo**, em função dos encadeamentos de estados e decisões futuras

No caso geral, a própria evolução dos estados observados em função das acções realizadas pode não ser determinista, ou seja, estar sujeita a **incerteza**

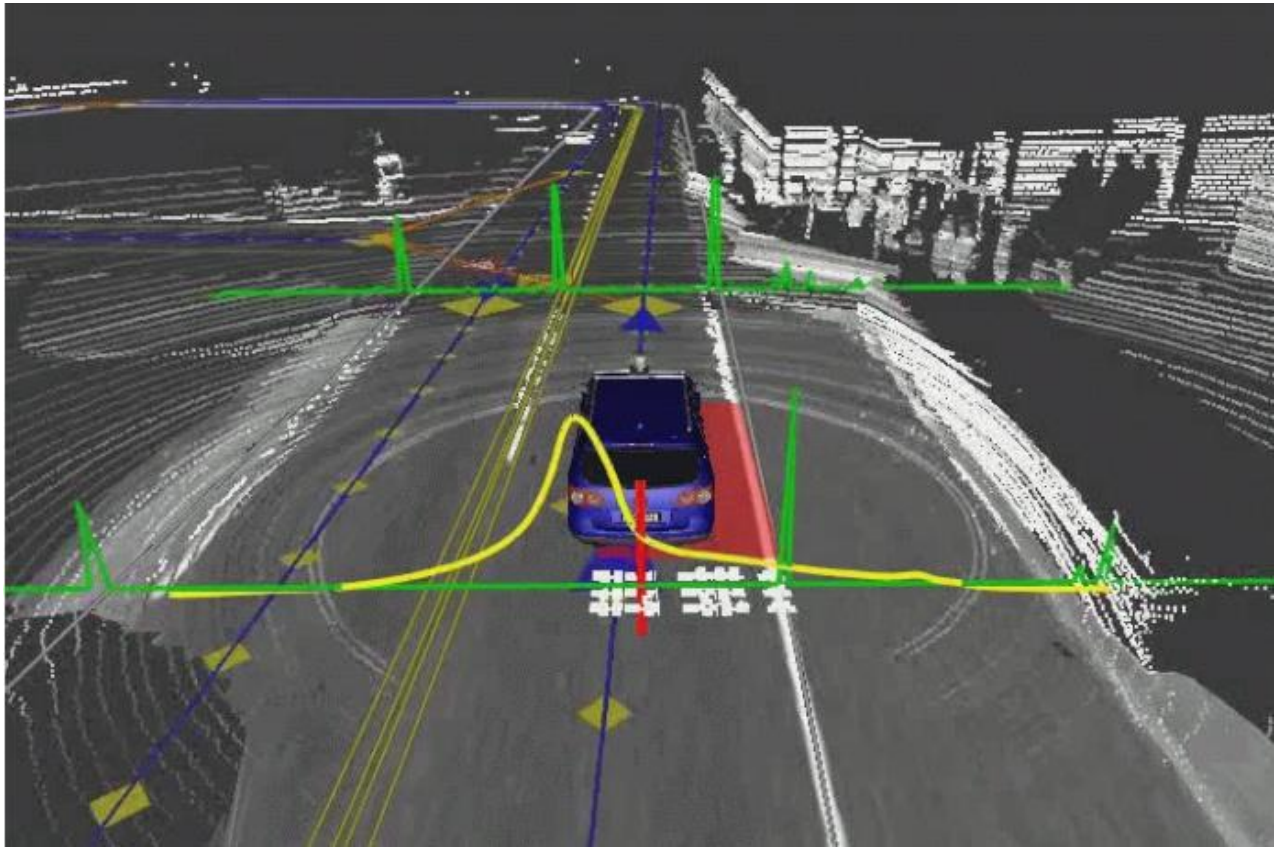
Como decidir qual a acção a realizar?



TOMADA DE DECISÃO COM INCERTEZA

A incerteza resulta da impossibilidade de se obter informação completa relativa ao domínio do problema

Exemplo: Navegação em veículos autónomos

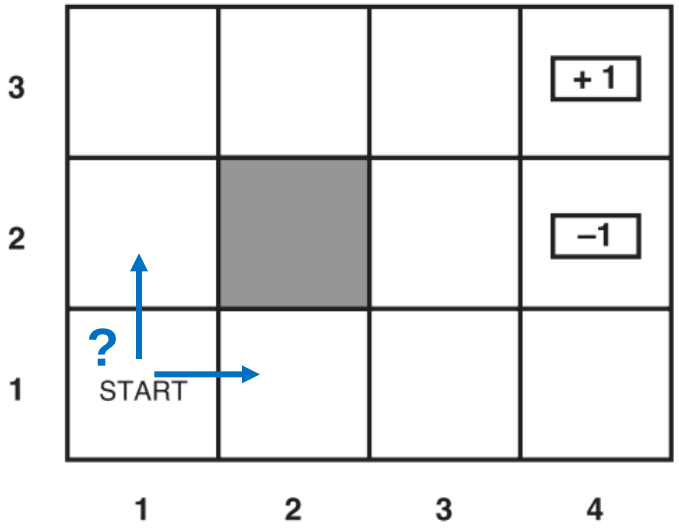


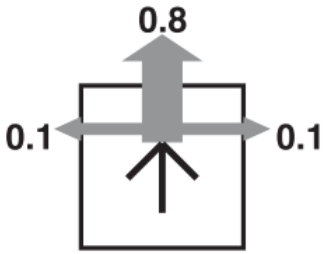
[Montemerlo, 2008]

PROCESSOS DE DECISÃO SEQUENCIAL

- Problema da decisão ao longo do tempo
  - Valor de uma acção depende de uma sequência de decisões
  - Possibilidade de ganhos e perdas
  - Incerteza na decisão
  - Efeito cumulativo

Exemplo:



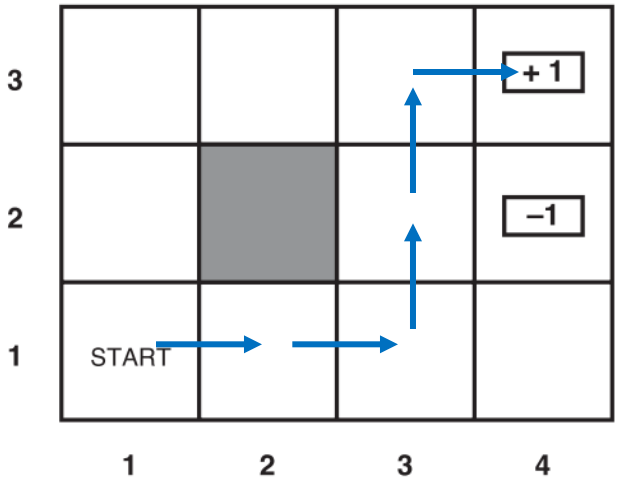


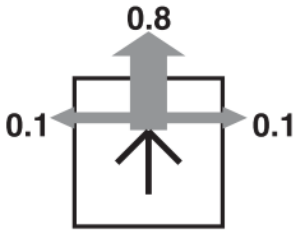
Desvios possíveis

Incerteza no resultado de uma acção

PROCESSOS DE DECISÃO SEQUENCIAL

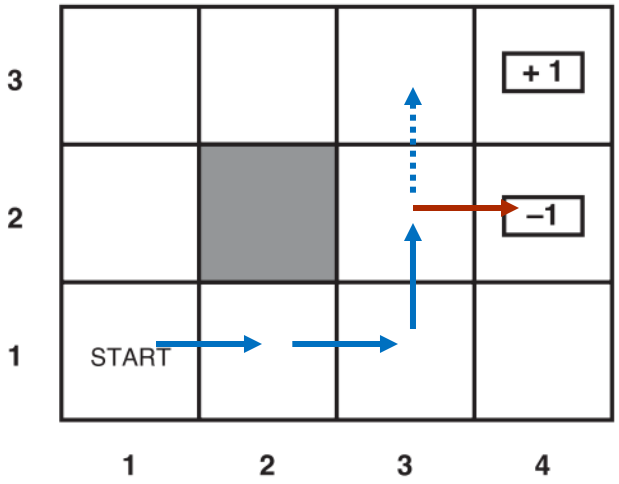
Exemplo:





Desvios possíveis

Incerteza no resultado de uma acção



O efeito da incerteza no resultado da acção, resulta na possibilidade de **transições de estado não deterministas**, ou seja, sobre as quais o sistema não tem controlo total

PROCESSOS DE DECISÃO SEQUENCIAL

Num processo de decisão sequencial, a evolução entre estados ocorre por efeito de acções que, no caso geral, podem ser *não-deterministas*, ou seja, **o seu resultado pode não ser completamente previsível**, pode existir incerteza no resultado da acção (*não determinismo* da acção).

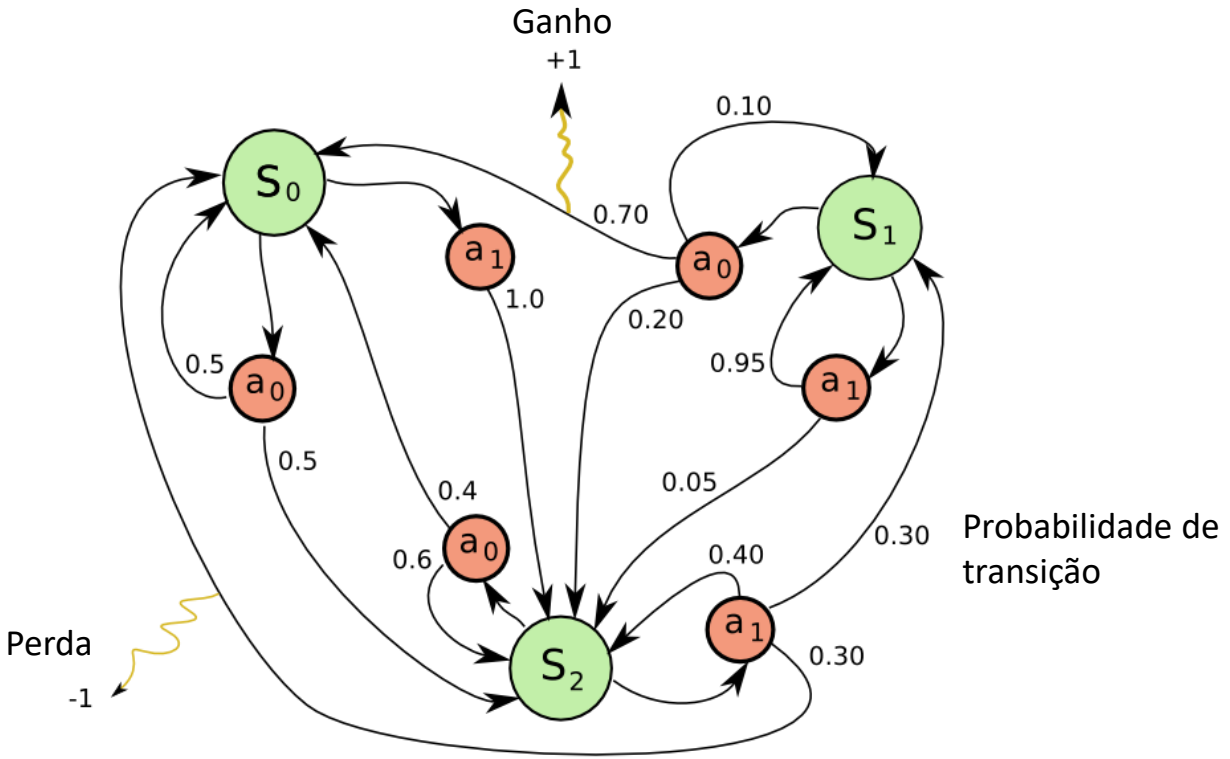
A este tipo de processos correspondem *espaços de estados não-deterministas*, nos quais as transições entre estados ocorrem por efeito das acções, com uma determinada **probabilidade de transição**.

A cada transição pode estar associada uma **recompensa**, que representa o **ganho ou perda** associado a essa transição de estado.

Exemplo:

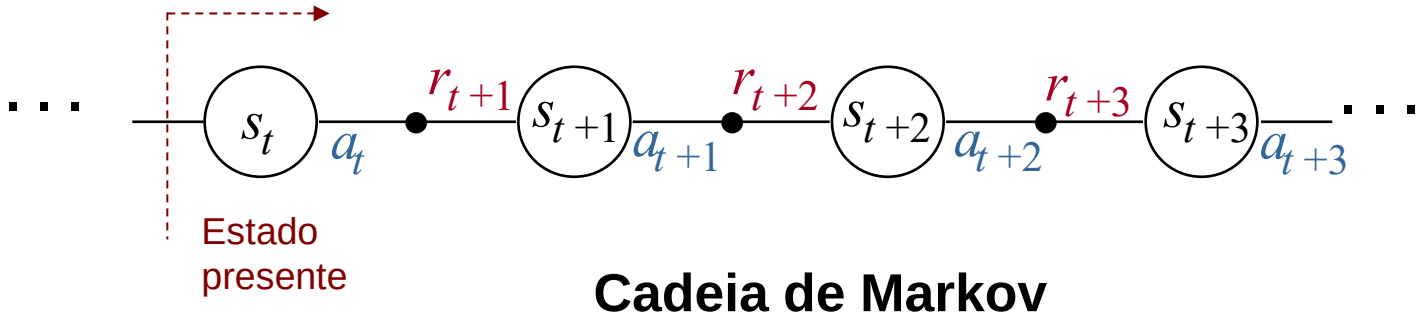
Estados = $\{s_0, s_1, s_2\}$

Acções = $\{a_0, a_1\}$



PROPRIEDADE DE MARKOV

- Andrey Markov
  - Matemático Russo (1856 – 1922)
- Um processo estocástico tem a ***propriedade de Markov*** se a distribuição probabilística condicional dos **estados futuros** de um processo depender exclusivamente do **estado presente**
- **A previsão dos estados seguintes só depende do estado presente**



Cadeia de Markov

Sequência de evolução ao longo dos estados possíveis
(estado, acção, recompensa)

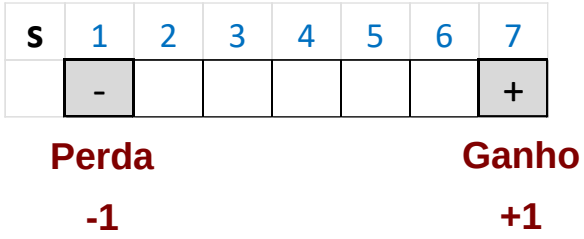
PROCESSOS DE DECISÃO DE MARKOV

Um PDM é definido por cinco componentes principais (*modelo do mundo*):

- **Conjunto de Estados - S**
  - Conjunto de estados possíveis em que o agente pode se encontrar
- **Conjunto de Ações – $A(s)$**
  - Conjunto de acções que o agente pode realizar em cada estado s
- **Função de Transição - $T(s, a, s') \in [0, 1]$**
  - Função que descreve a probabilidade de transição de estado por efeito da realização de uma acção (probabilidade de a partir do estado s transitar para o estado s' ao realizar a acção a)
- **Função de Recompensa - $R(s, a, s') \in \Re$**
  - Função que descreve a recompensa de transição de estado por efeito da realização de uma acção (recompensa por transitar do estado s para o estado s' ao realizar a acção a)
- **Factor de Desconto - $\gamma \in [0, 1]$**
  - Valor entre 0 e 1 que determina a importância das recompensas futuras em relação às recompensas imediatas

PROCESSOS DE DECISÃO DE MARKOV

Exemplo: Ambiente determinista



- **Conjunto de Estados - S**
  - Conjunto de posições válidas:
    $S = \{1, 2, 3, 4, 5, 6, 7\}$
- **Conjunto de Ações – $A(s)$**
  - Conjunto de acções válidas em cada estado:
    $A(s) = \{\leftarrow, \rightarrow\}, \forall_s \in S$
- **Função de Transição - $T(s, a, s') \in [0, 1]$**
  - Probabilidade de transição de estado por efeito das acções, considerando um ambiente determinista:
    $T(s, a, s') = 1$ se $s \in \{2, 3, 4, 5, 6\}$
    $T(s, a, s') = 0$ se $s \in \{1, 7\}$
- **Função de Recompensa - $R(s, a, s') \in \Re$**
  - Recompensas possíveis:
    $R(s, a, s') = 0$ se $s \in \{2, 3, 4, 5, 6\}$
    $R(s, a, s') = +1$ se $s' = 7$
    $R(s, a, s') = -1$ se $s' = 1$

UTILIDADE (VALOR) DE ESTADO

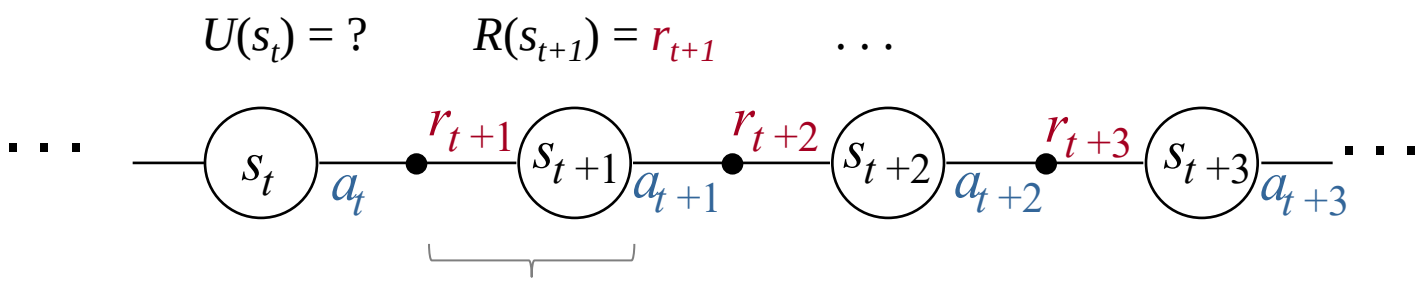
Medida de desempenho para tomada de decisão que reflecte o efeito cumulativo da evolução de estado através das **recompensas** observadas, expressando ***ganhos*** e ***perdas***

- **Recompensa**
  - Valor finito positivo (***ganho***) ou negativo (***perda***)
  - Expressa ganho ou perda num determinado estado
  - Diferentes formas de recompensa

    $R(s)$ – Recompensa depende apenas do estado

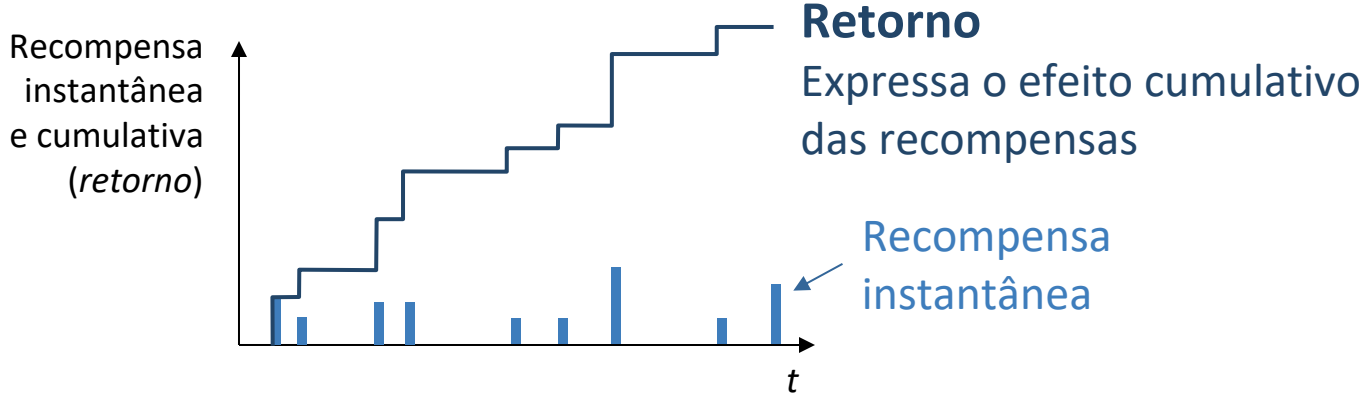
    $R(s, a)$ – Recompensa depende do estado e da acção realizada

    $R(s, a, s')$ – Recompensa depende do estado, da acção e do estado seguinte
  - Tem um âmbito **local** (**curto prazo**)



A recompensa tem um âmbito **local** (**curto prazo**)

RECOMPENSA E RETORNO



Retorno

Expressa o efeito cumulativo das recompensas

Recompensa instantânea

Tipos de retorno

Horizonte finito

$$G_t = r_t + r_{t+1} + \ldots + r_{t+n} = \sum_{i=0}^{n} r_{t+i}$$

Horizonte infinito

$$G_t = \lim_{n\to\infty} \left(\frac{1}{n} \sum_{i=0}^{n} r_{t+i} \right)$$

Horizonte infinito com desconto temporal

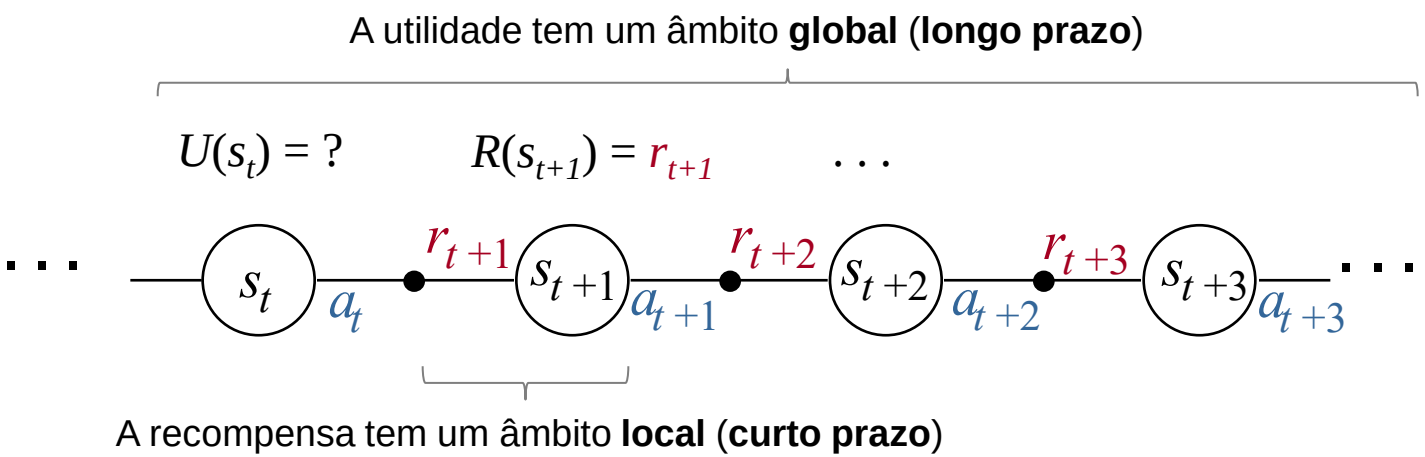
$$G_t = r_t + \gamma \cdot r_{t+1} + \gamma^2 \cdot r_{t+2} + \gamma^3 \cdot r_{t+3} + \ldots = \sum_{i=0}^{\infty} \gamma^i \cdot r_{t+i}$$

$\gamma \in [0,1]$ - Factor de desconto

UTILIDADE (VALOR) DE ESTADO

A utilidade de um estado corresponde ao *retorno esperado* a partir desse estado, ou seja, o efeito cumulativo da evolução de estado através das **recompensas** observadas, expressando ***ganhos*** e ***perdas***

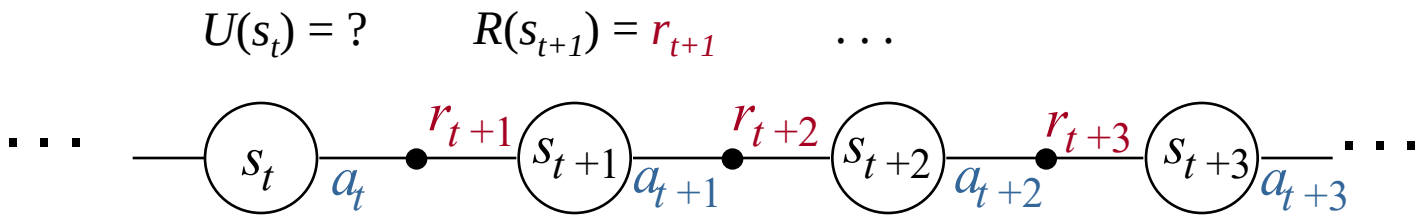
- **Utilidade**
  - $U(s)$
  - Valor de um determinado estado s para realização do objectivo pretendido
  - Reflecte o valor que pode ser obtido a partir dum estado ao longo de uma sequência de evolução de estado
  - Tem um âmbito **global** (**longo prazo**)



UTILIDADE (VALOR) DE ESTADO

Cálculo da utilidade

(considerando que a recompensa depende apenas do estado)



A utilidade de um estado representa o valor que pode ser obtido a partir desse estado ao longo de uma sequência de evolução de estado

Uma forma possível de cálculo de utilidade é realizando a **soma das recompensas** ao longo da sequência de estados:

$$U(s_t) = R(s_t) + R(s_{t+1}) + R(s_{t+2}) + \ldots$$

UTILIDADE (VALOR) DE ESTADO

Soma das recompensas

$$U(s_t) = R(s_t) + R(s_{t+1}) + R(s_{t+2}) + \ldots$$

- Problemas
  - Recompensas estão limitadas a uma gama finita de valores, caso contrário **a soma das recompensas pode ser infinita**
    - Impossibilita a decisão
  - Não reflecte o efeito da passagem do **tempo**
    - As recompensas mantêm o seu valor independente do momento em que ocorram

UTILIDADE (VALOR) DE ESTADO

Recompensas descontadas (no tempo)

$$U(s_t) = R(s_t) + \gamma R(s_{t+1}) + \gamma^2 R(s_{t+2}) + \dots$$

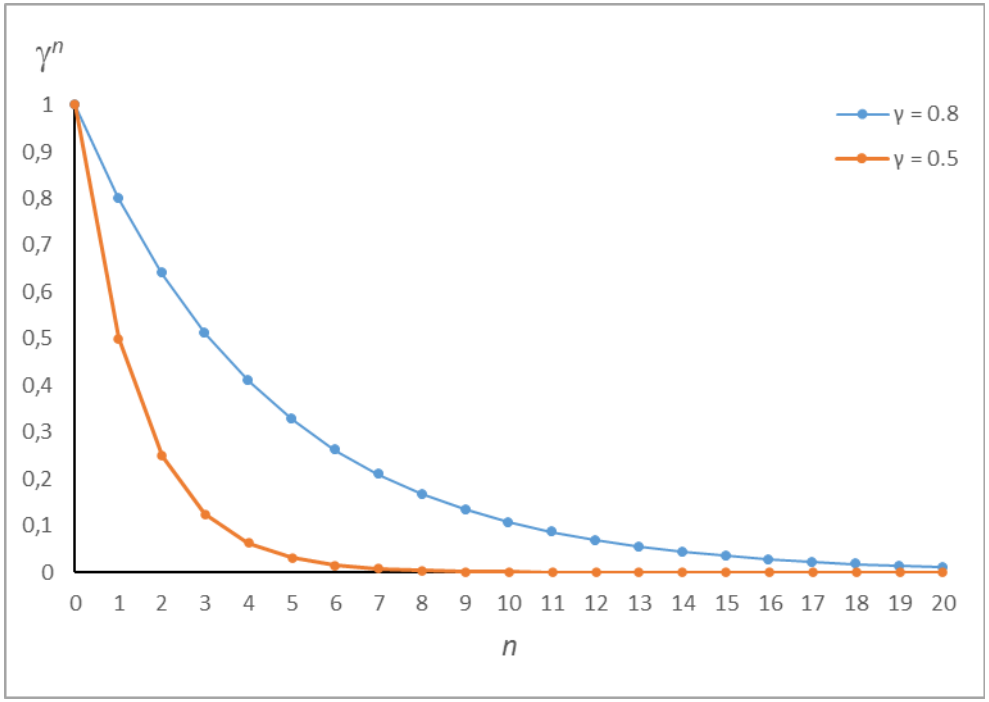
Factor de desconto γ

- Redução de valor não-linear em função da distância no tempo da recompensa

  $\gamma \in [0,1]$

- Recompensas não estão limitadas a uma gama finita de valores
- O factor de desconto reflecte o efeito da passagem do tempo
  - O momento em que a recompensa ocorre é relevante para a sua contribuição para a utilidade (*valor*) a longo prazo

γ^n com $\gamma \in [0,1]$ – Função com decaimento exponencial em função de n



POLÍTICA COMPORTAMENTAL

Forma de representação do comportamento do agente

Define qual a acção que deve ser realizada em cada estado

- Política **determinista**
  - Para cada estado indica uma acção específica a realizar

$$\pi : S \rightarrow A(s) \; ; \; s \in S$$

- Política **não determinista**
  - Para cada par (estado, acção) indica a probabilidade de no estado realizar a acção

$$\pi : S \times A(s) \rightarrow [0,1] \; ; \; s \in S$$

POLÍTICA COMPORTAMENTAL

Concretizada com base numa função que define qual a acção que deve ser realizada em cada estado (*estratégia de acção*)

Política **determinista**

$$\pi : S \rightarrow A(s) \; ; \; s \in S$$

Para cada estado indica uma acção específica a realizar

Exemplo:

$$\pi(s_1) = a_1$$

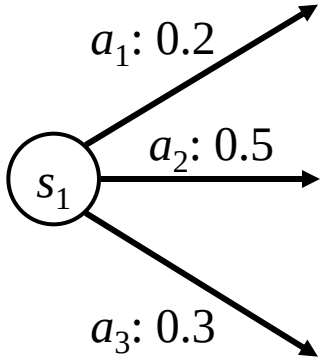
Política **não determinista**

$$\pi: S \times A(s) \rightarrow [0,1] \; ; \; s \in S$$

Para cada par (estado, acção) indica a probabilidade de no estado realizar a acção

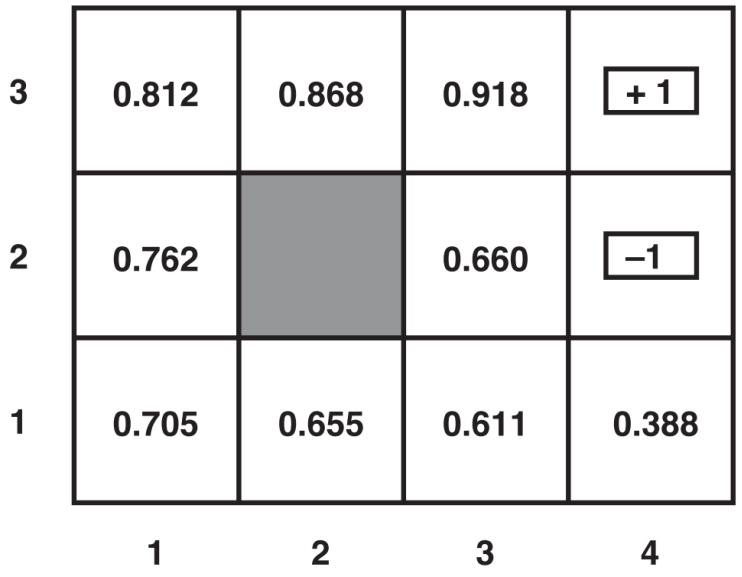
Exemplo:

$$\pi(s_1, a_1) = 0.2$$
$$\pi(s_1, a_2) = 0.5$$
$$\pi(s_1, a_3) = 0.3$$

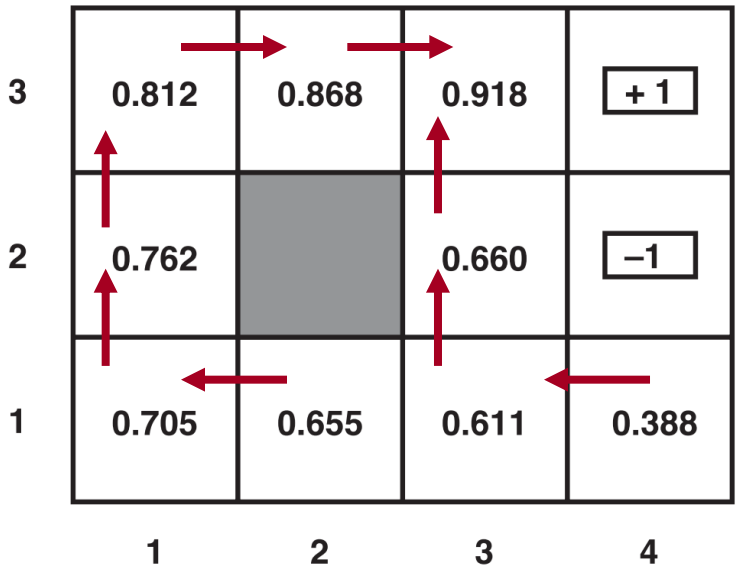


POLÍTICA (DE TOMADA DE DECISÃO)

Exemplo:



Utilidade de estado para o ambiente 4 x 3, com $\gamma = 1$ e $R(s) = -0.04$ para estados não terminais



Política óptima para a utilidade de estado calculada

PROCESSOS DE DECISÃO MARKOV

Resolução de processos de decisão de Markov

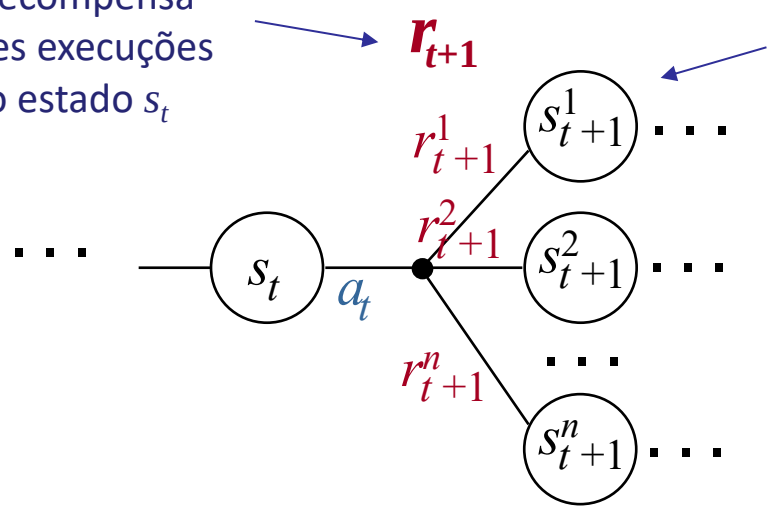
- O objectivo de um processo de decisão de Markov (PDM) é encontrar uma política que maximize o *retorno* em cada estado, ou seja, a soma das recompensas esperadas ao longo do tempo
- Duas vertentes principais na resolução de um PDM:
  - **Cálculo da utilidade de estado**
  - **Cálculo da política** (de tomada de decisão)

UTILIDADE (VALOR) DE ESTADO

Cálculo da utilidade de estado considerando o não determinismo da acção

- É necessário considerar a probabilidade de ocorrência de cada valor possível de recompensa
- Por exemplo, a recompensa r_{t+1} pode ter diferentes valores possíveis, dependendo do efeito não determinista da acção a_t

Diferentes valores possíveis de recompensa para diferentes execuções da acção a_t no estado s_t

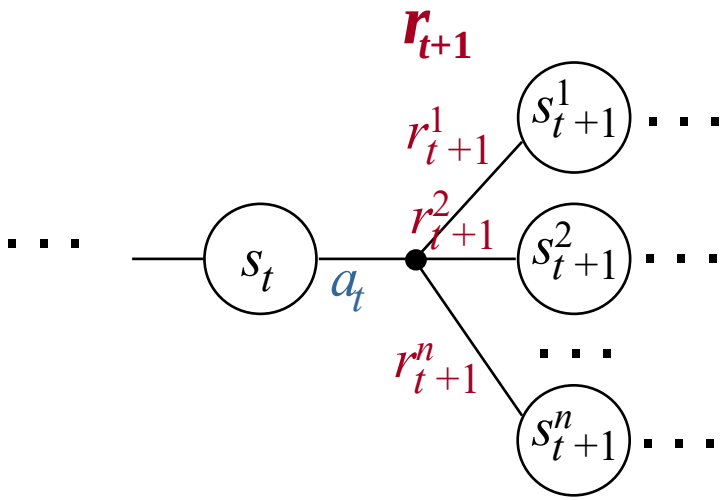


Diferentes transições de estado possíveis para diferentes execuções da acção a_t no estado s_t

UTILIDADE (VALOR) DE ESTADO

Cálculo da utilidade de estado considerando o não determinismo da acção

- Para considerar a probabilidade de ocorrência de diferentes valores possíveis de recompensa, é necessário ponderar esses valores pela probabilidade da sua ocorrência, ou seja, deve ser calculado o *valor esperado*



Valor esperado:

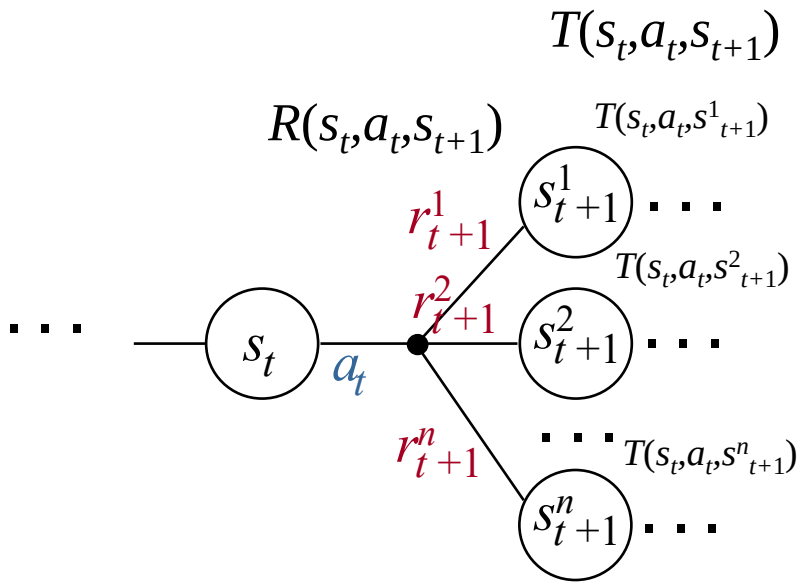
$$E\langle x\rangle = \sum_{i=0}^{n} p(x_i)x_i$$

$$U(s_t) = \mathrm{E}\left\langle r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \ldots \right\rangle$$

Valor esperado das recompensas ao longo do tempo, descontadas em função do tempo t

UTILIDADE (VALOR) DE ESTADO

Cálculo da utilidade de estado, tendo por base um **modelo de transição** de estado *T*(*s, a, s'*) e um **modelo de recompensa** *R*(*s, a, s'*)



$R(s_t,a_t,s_{t+1})$ pode gerar diferentes resultados com diferentes probabilidades:

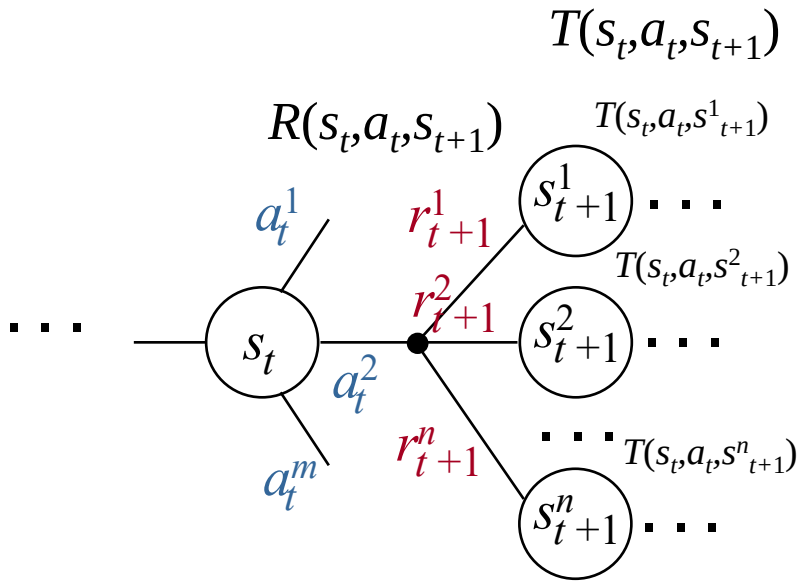
$R(s_t,a_t,s^1{}_{t+1}) = r^1{}_{t+1}$
$R(s_t,a_t,s^2{}_{t+1}) = r^2{}_{t+1}$
. . .
$R(s_t,a_t,s^n{}_{t+1}) = r^n{}_{t+1}$

$$U(s_t) = \mathrm{E}\left\langle R(s_t,a_t,s_{t+1}) + \gamma R(s_{t+1},a_{t+1},s_{t+2}) + \gamma^2 R(s_{t+2},a_{t+2},s_{t+3}) + \ldots \right\rangle$$

$$= \mathrm{E}\left\langle R(s_t,a_t,s_{t+1}) + \gamma U(s_{t+1}) \right\rangle$$

Utilidade (Valor) de Estado

Cálculo da utilidade de estado, tendo por base um **modelo de transição** de estado *T*(*s, a, s'*) e um **modelo de recompensa** *R*(*s, a, s'*)



Valor esperado:

$$E\langle x\rangle = \sum_{i=0}^{n} p(x_i)x_i$$

$$U(s_t) = E\langle R(s_t, a_t, s_{t+1}) + \gamma U(s_{t+1})\rangle$$

$$= \sum_{i=1}^{m} \pi(s_t, a_t^i) \sum_{j=1}^{n} T\left(s_t, a_t^i, s_{t+1}^j\right)\left[R\left(s_t, a_t^i, s_{t+1}^j\right) + \gamma U(s_{t+1}^j)\right]$$

O PRINCÍPIO DA DECISÃO ÓPTIMA

A decisão óptima é a que maximiza a utilidade de cada estado observado

- O cálculo da utilidade é possível através de *Programação Dinâmica*
  - Solução obtida por decomposição de um problema em sub-problemas
- Num PDM isso é viável devido à propriedade de Markov
- As utilidades dos estados podem ser determinadas em função das utilidades dos estados sucessores

$$U^{\pi}(s) = \mathrm{E}\left\langle r_1 + \gamma r_2 + \gamma^2 r_3 + \ldots \right\rangle$$

$$= \mathrm{E}\left\langle r_1 + \gamma U^{\pi}(s') \right\rangle$$

$$= \sum_{a} \pi(s,a) \sum_{s'} T(s,a,s') \left[R(s,a,s') + \gamma U^{\pi}(s') \right]$$

Equação de Bellman

CÁLCULO DA UTILIDADE DE ESTADO

Utilidade de estado para uma política π

$$U^{\pi}(s) = \sum_{a} \pi(s,a) \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma U^{\pi}(s')]$$

Utilidade de estado para a política óptima π*

$$U^{\pi^*}(s) = \max_{a} \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma U^{\pi}(s')]$$

Política óptima π*

Para cada estado ***s***, escolher a acção ***a*** com maior utilidade

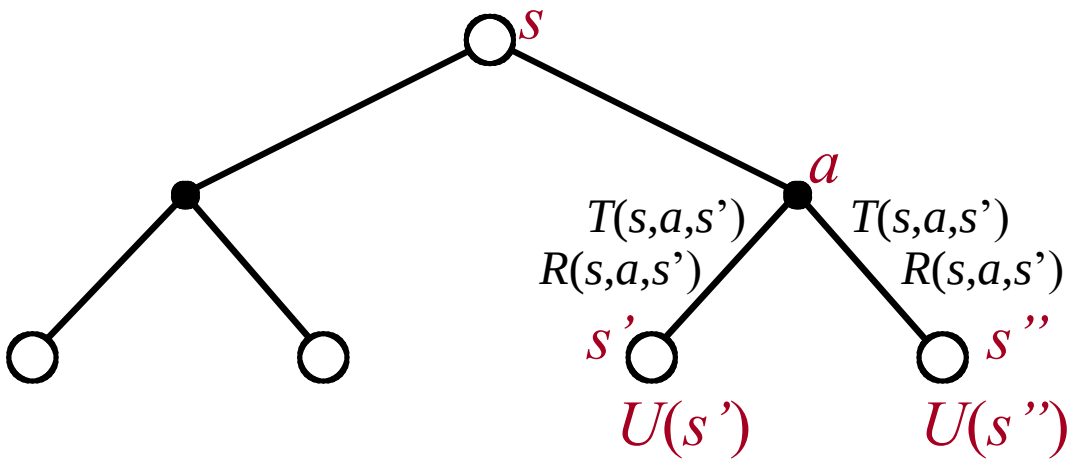
$$\pi^*(s) = \arg\max_{a} \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma U(s')]$$

PROGRAMAÇÃO DINÂMICA

Resolução de um problema por composição iterativa de soluções parciais

- **Iteração**
  - Propagação de retornos parciais
    - Utilizar estimativa de retornos futuros para estimar o retorno do estado actual

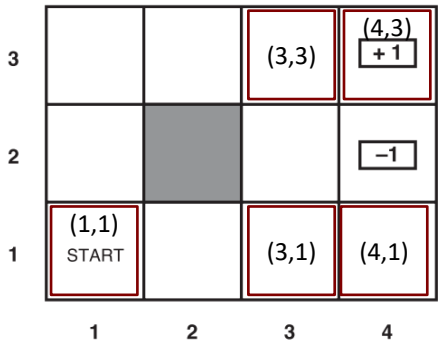
$$U^{\pi^*}(s) = \max_a \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma U^{\pi}(s')]$$

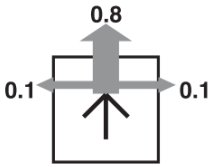


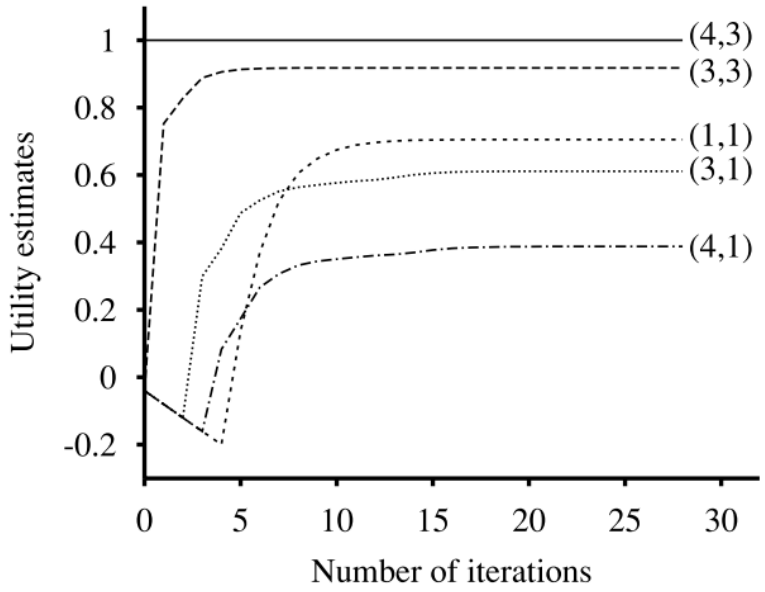
Adaptado de [Sutton & Barto, 1998]

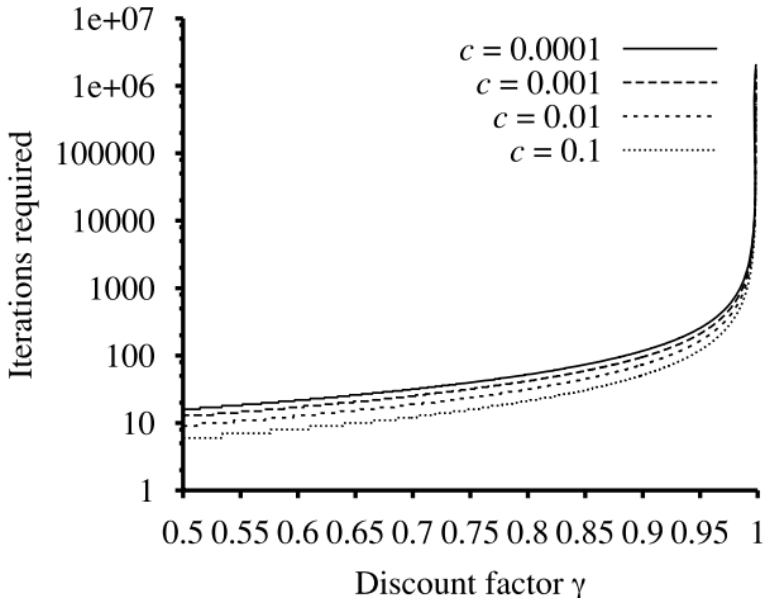
CÁLCULO DA UTILIDADE DE ESTADO

Exemplo de cálculo iterativo da utilidade para alguns estados do problema







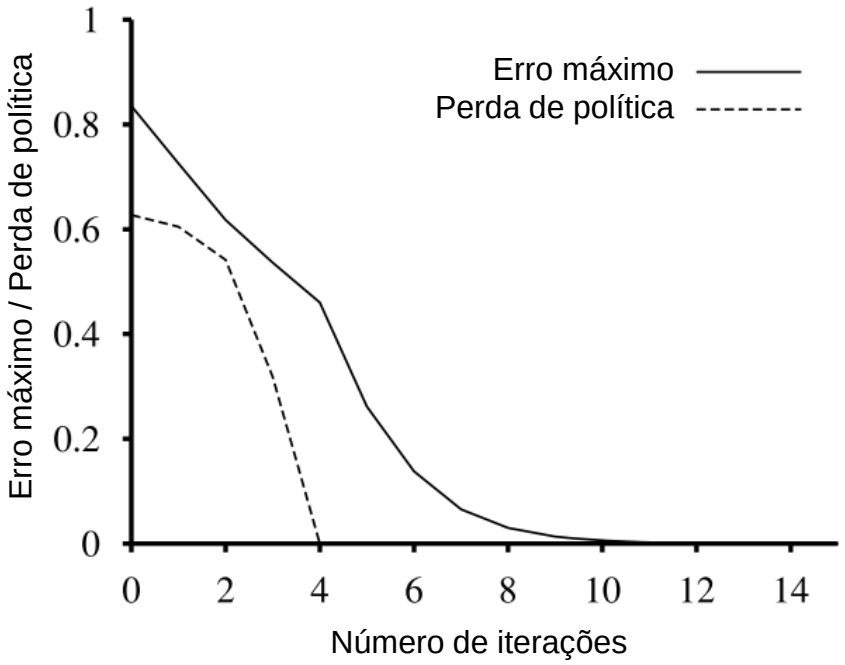


[Russel & Norvig, 2010]

CÁLCULO DA UTILIDADE DE ESTADO

O erro da política (acções de estado incorrectas) decresce de forma mais rápida do que o erro da utilidade

A política reflecte o gradiente da função de utilidade, pelo que tem um carácter relativo, possibilitando a convergência para a política óptima antes da convergência da função de utilidade



Adaptado de [Russel & Norvig, 2010]

CÁLCULO DA UTILIDADE DE ESTADO

Iteração da utilidade de estado

Iniciar $U(s)$:

$$U(s) \leftarrow 0, \ \forall s \in S$$

Iterar $U(s)$:

$$U(s) \leftarrow \max_a \sum_{s'} T(s,a,s')[R(s,a,s')+\gamma U(s')], \ \forall s \in S$$

No limite:

$$U \rightarrow U^{\pi *}$$

Critério de paragem de iteração

$$\Delta = \left\| U_{i+1} - U_i \right\|, \quad \Delta < \Delta_{\max}$$ (limiar de convergência)

UTILIDADE - IMPLEMENTAÇÃO

Cálculo da utilidade de estado

1. utilidade():
2. $U(s) = 0, \forall_{s \in S}$
3. do:
4. $U_{\text{ant}} = U.\text{copy}()$
5. $\delta = 0$
6. for s in S:
7. $U(s) = \max_{a \in A(s)} U_{\text{accao}}(s, a, U_{\text{ant}})$
8. $\delta = \max(\delta, |U(s) - U_{\text{ant}}(s)|)$
9. while $\delta > \Delta_{\text{max}}$:
10. return U

Cálculo da utilidade de acção

1. $U_{\text{accao}}(s, a, U)$:
2. return $\sum_{s' \in suc(s)} T(s, a, s')(R(s, a, s') + \gamma U(s'))$

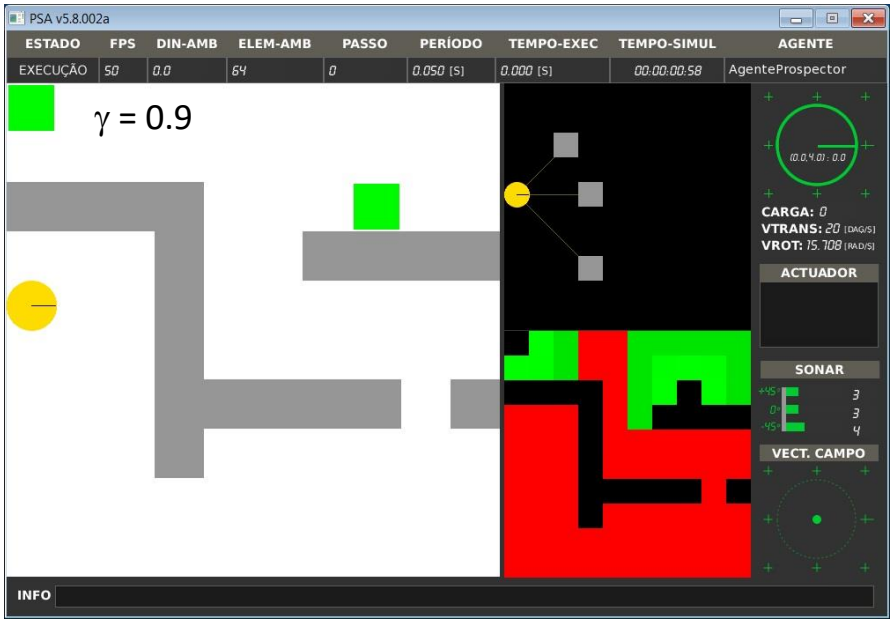
POLÍTICA - IMPLEMENTAÇÃO

Gerar política com base na utilidade

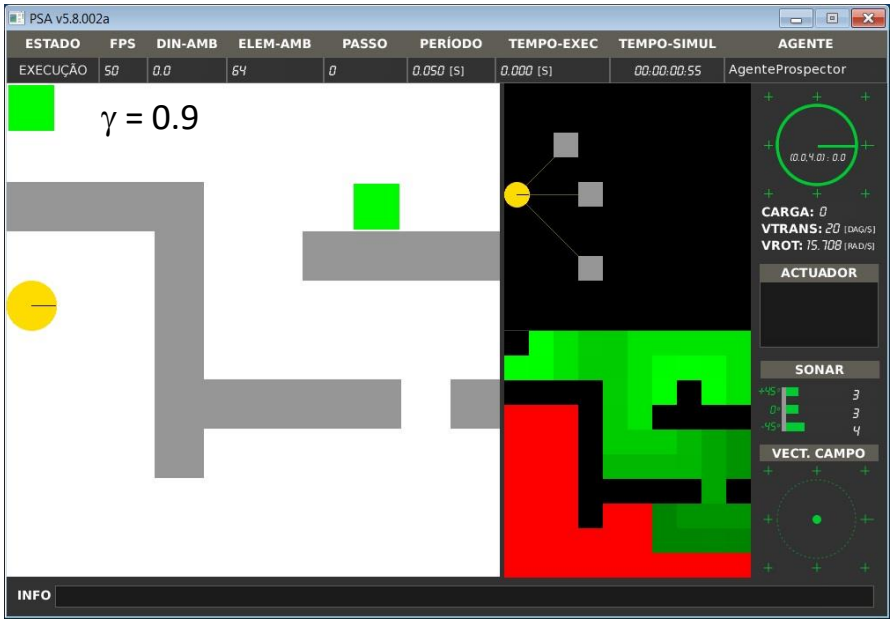
1. politica(U):
2. $\pi = \{\}$
3. for s in S:
4. if $A(s)$:
5. $\pi(s) = \underset{a \in A(s)}{\text{argmax}}\, U_{\text{accao}}(s, a, U)$
6. return π

PROCESSOS DE DECISÃO DE MARKOV: EXEMPLO

1

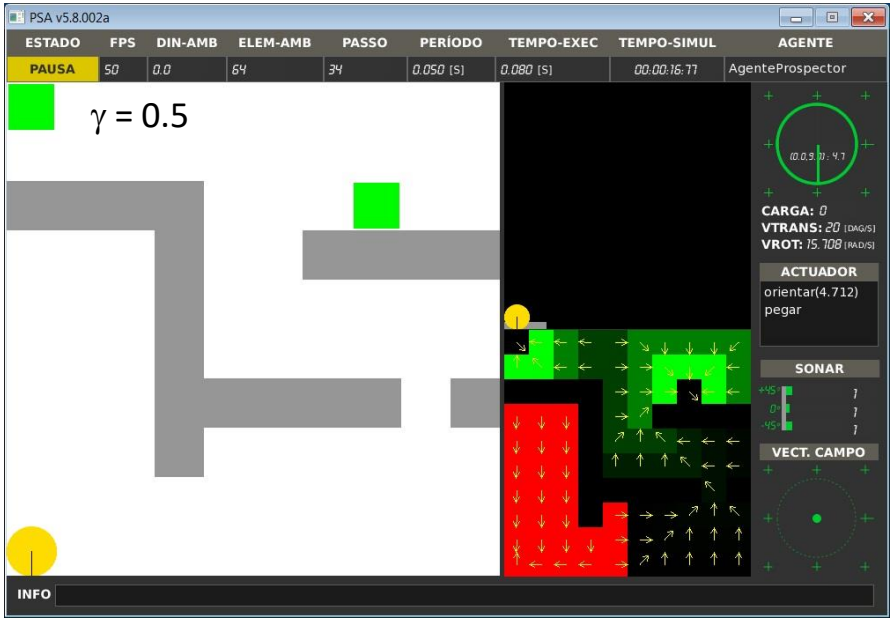


2



3

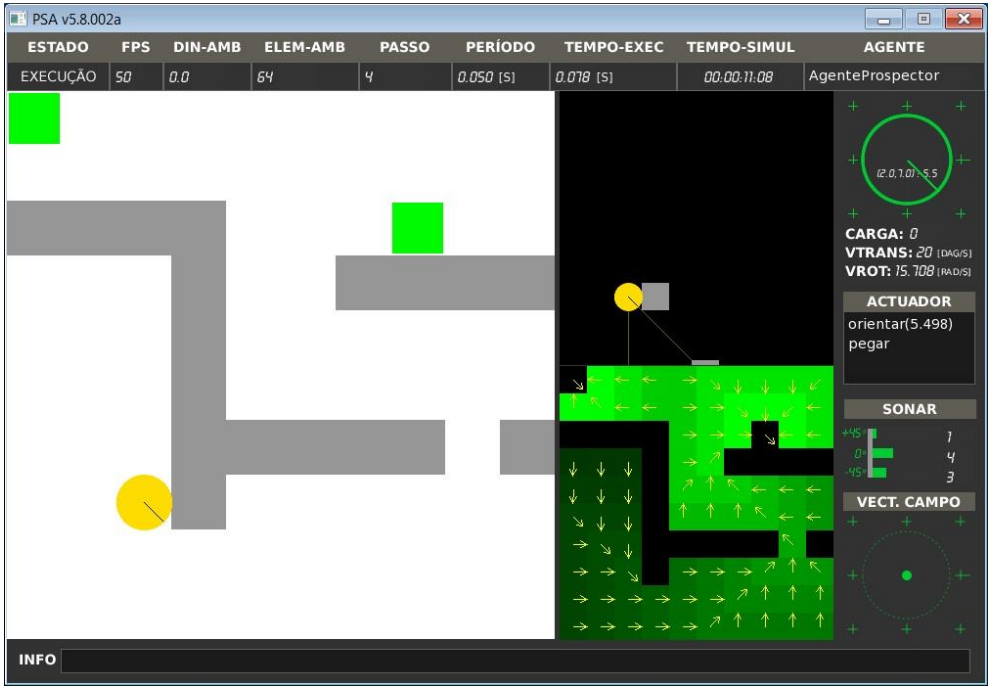




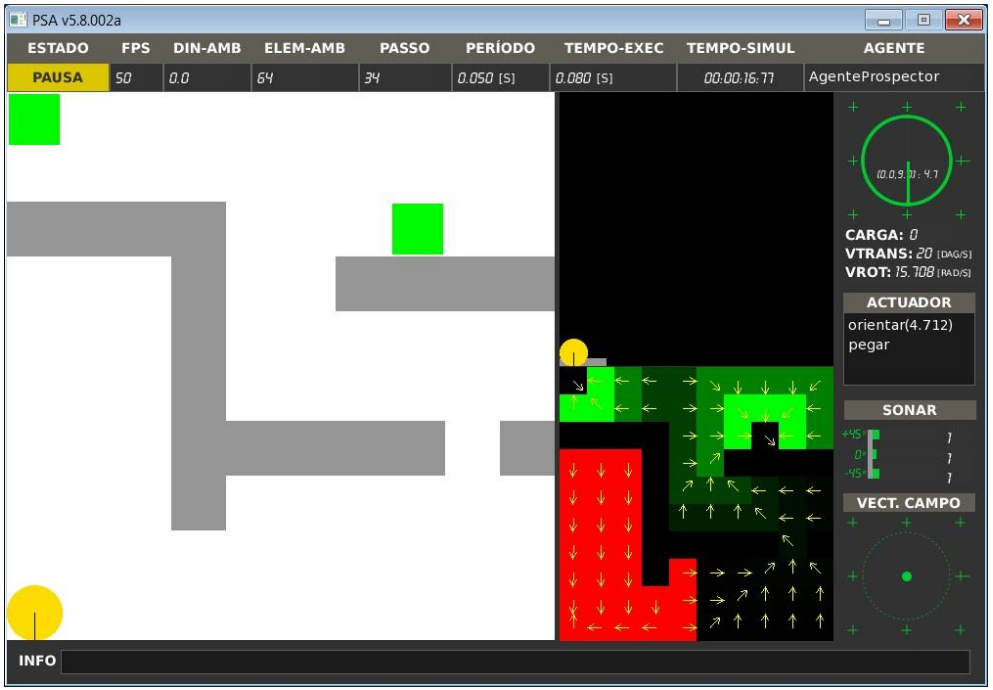
PROCESSOS DE DECISÃO DE MARKOV

Exemplo do efeito do factor de desconto

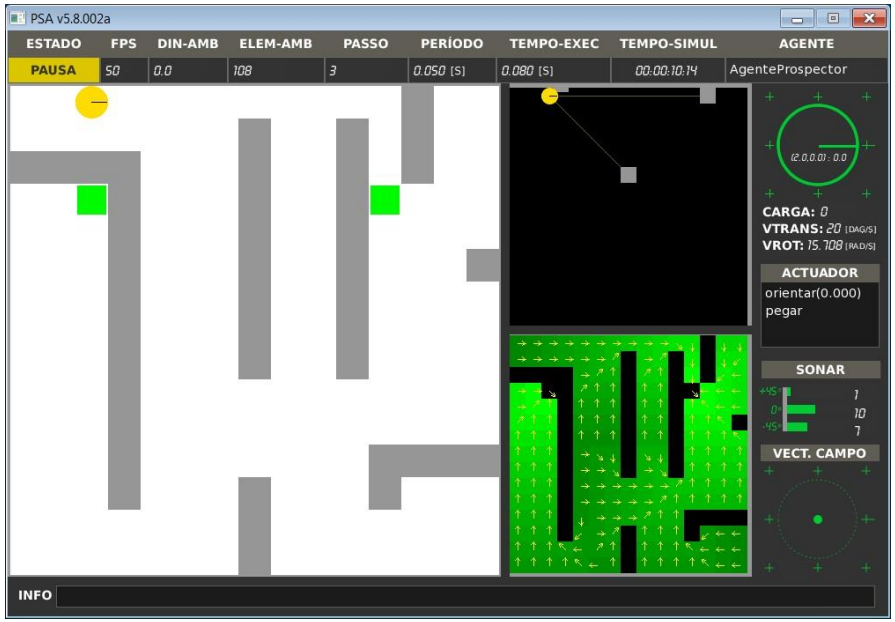
$\gamma = 0.9$



$\gamma = 0.5$

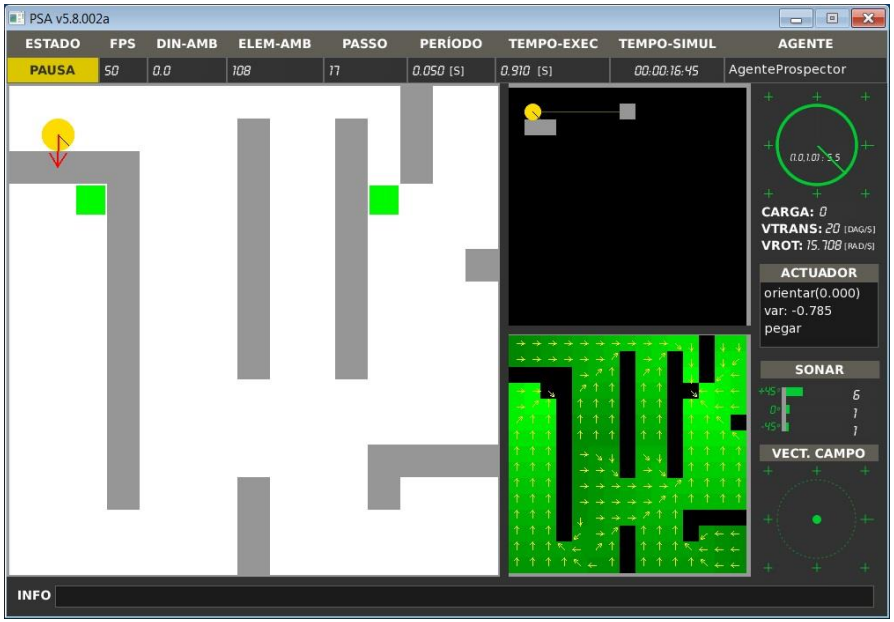


PDM - DETERMINISMO E NÃO-DETERMINISMO



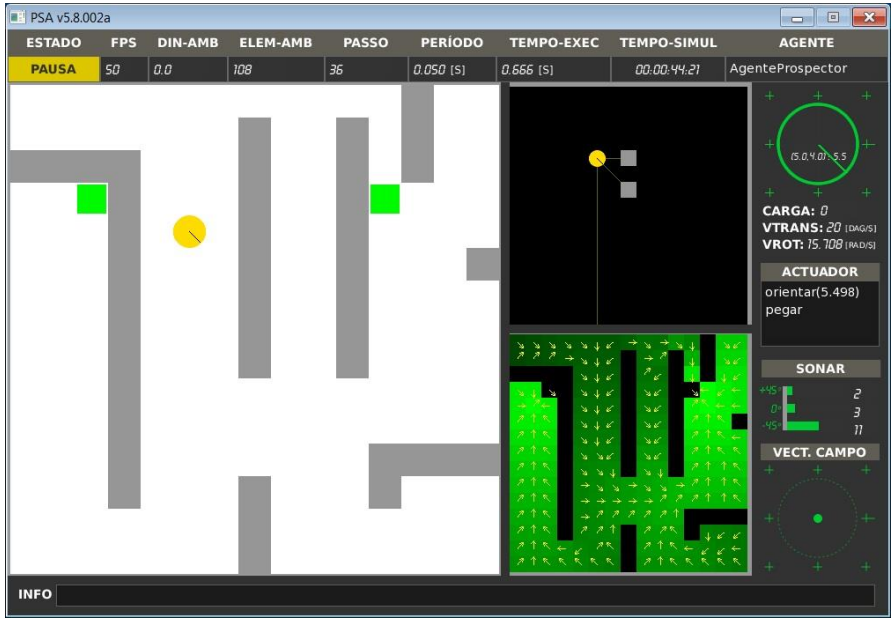
Modelo determinista

Ambiente determinista



Modelo determinista

Ambiente não-determinista



Modelo não-determinista

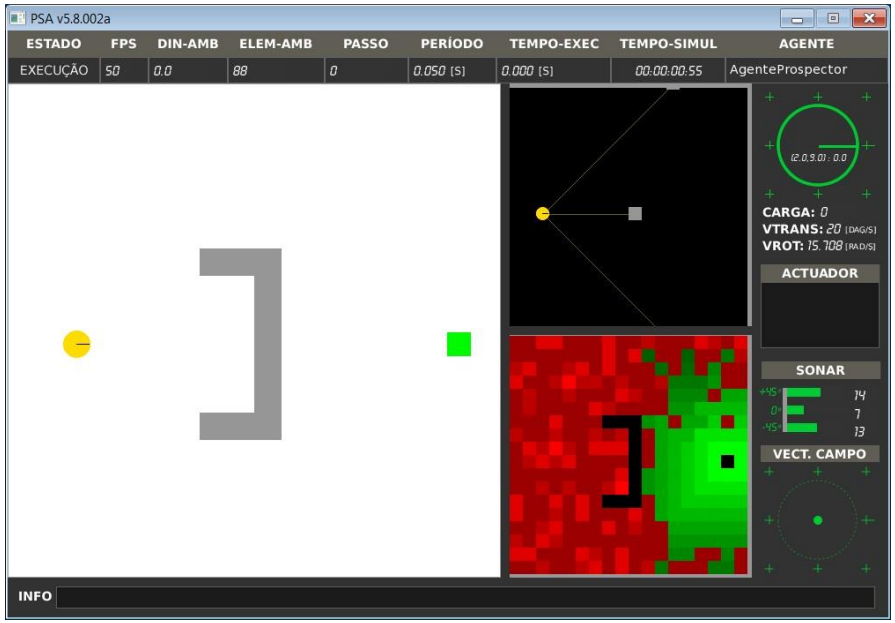
Ambiente não-determinista

CÁLCULO DA UTILIDADE DE ESTADO

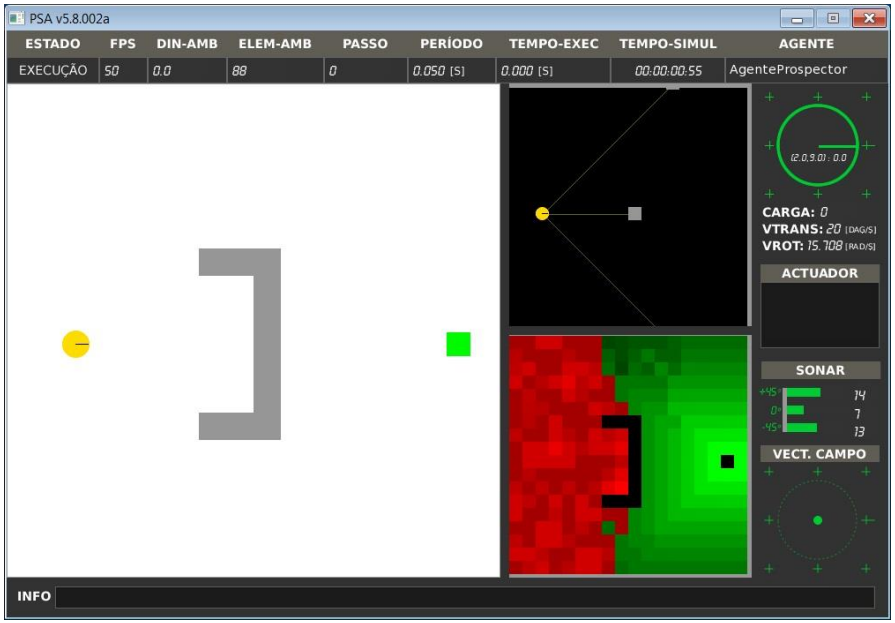
- **Iteração de valor** pode ser vista como uma *propagação de informação de valor* através do espaço de estados
  - **Síncrona**
    - As iterações actualizam sistematicamente cada estado
    - Manutenção de uma cópia da utilidade anterior
  - **Assíncrona**
    - As iterações não actualizam sistematicamente cada estado
    - **Necessário continuar a iterar até que todos os estados tenham sido actualizados**

PDM – ITERAÇÃO DE VALOR ASSÍNCRONA

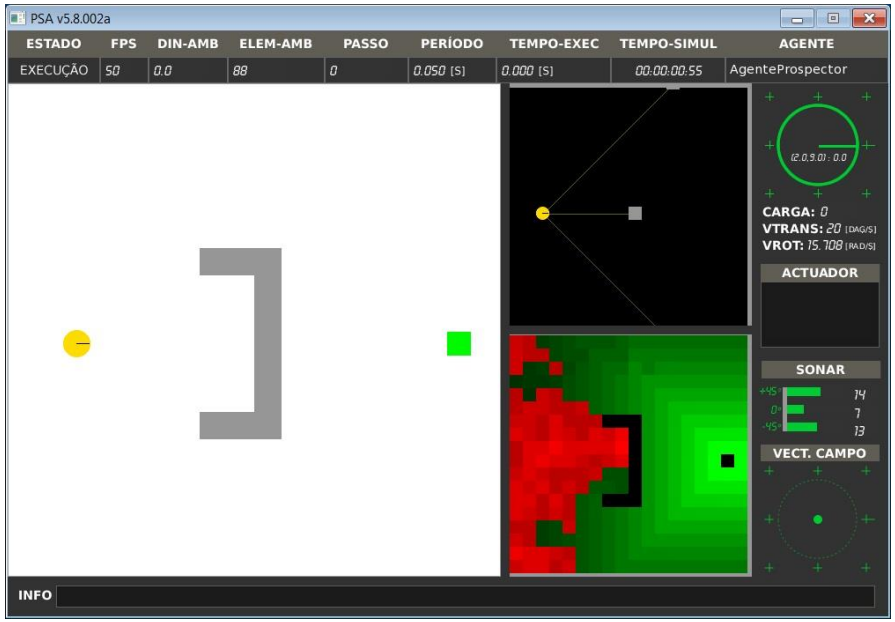
1



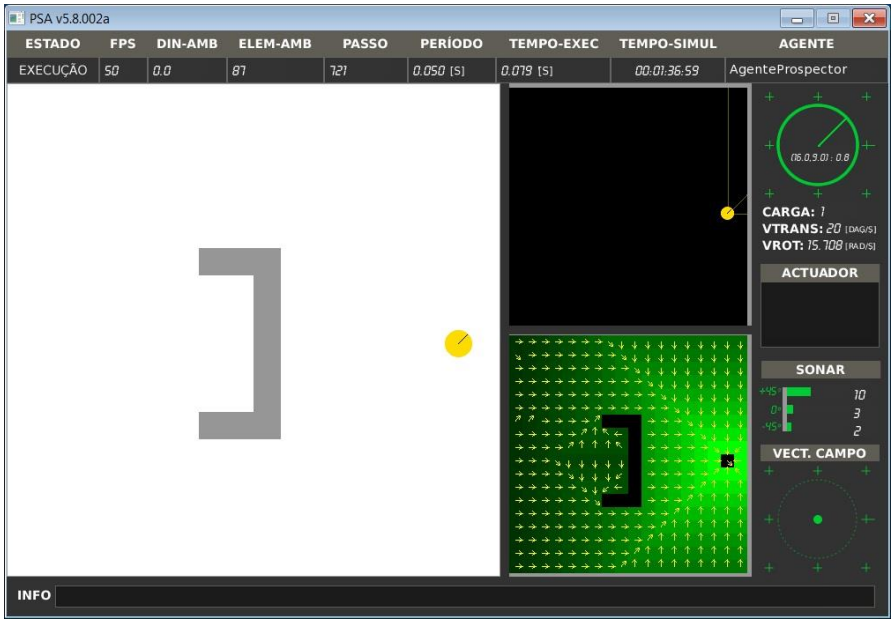
2



3



4



PROCESSOS DE DECISÃO DE MARKOV

- **Problemas**
  - Dimensão dos espaços de estados (*problema da dimensionalidade*)
  - Modelos desconhecidos

$$U^{\pi^*}(s) = \max_a \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma U^{\pi}(s')]$$

? **?**

Resolução através de aprendizagem por reforço

REFERÊNCIAS

[Russel & Norvig, 2010]
S. Russell, P. Norvig, “Artificial Intelligence: A Modern Approach”, 3rd Ed., Prentice Hall, 2010

[Sutton & Barto, 1998]
R. Sutton, A. Barto, “Reinforcement Learning: An Introduction”, MIT Press, 1998

[Sutton & Barto, 2012]
R. Sutton, A. Barto, “Reinforcement Learning: An Introduction”, 2nd Edition - Preview, MIT Press, 2012

[Sutton & Barto, 2020]
R. Sutton, A. Barto, “Reinforcement Learning: An Introduction”, 2nd Edition, MIT Press, 2020

[Mahadevan, 2009]
S. Mahadevan, “Learning Representation and Control in Markov Decision Processes: New Frontiers”, Foundations and Trends in Machine Learning, 1:4, 2009

[LaValle, 2006]
S. LaValle, “Planning Algorithms”, Cambridge University Press, 2006

[Kragic & Vincze, 2009]
D. Kragic, M. Vincze, “Vision for Robotics”, Foundations and Trends in Robotics, 1:1, 2009