APRENDIZAGEM POR REFORÇO

Luís Morgado

ISEL-DEI

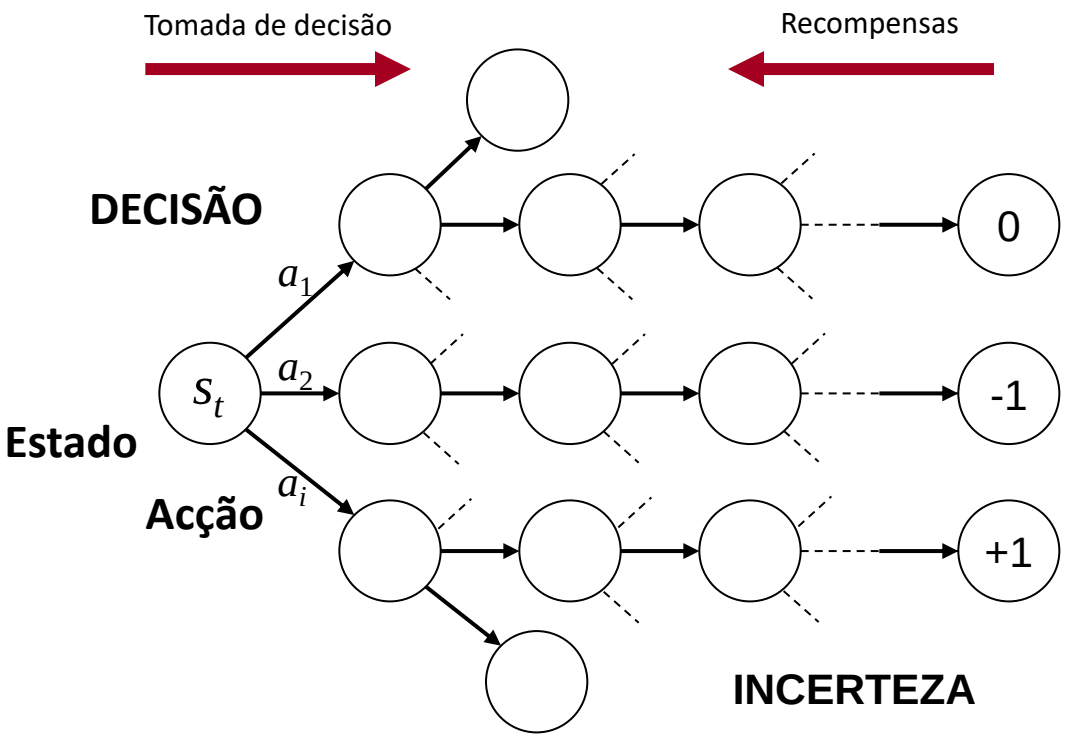
PROBLEMA DA DECISÃO SEQUENCIAL

Num processo de decisão geral, para cada estado s_n, cada decisão de acção (a_1, a_2, …, a_i) pode levar a **múltiplas ramificações de estados e decisões futuras**

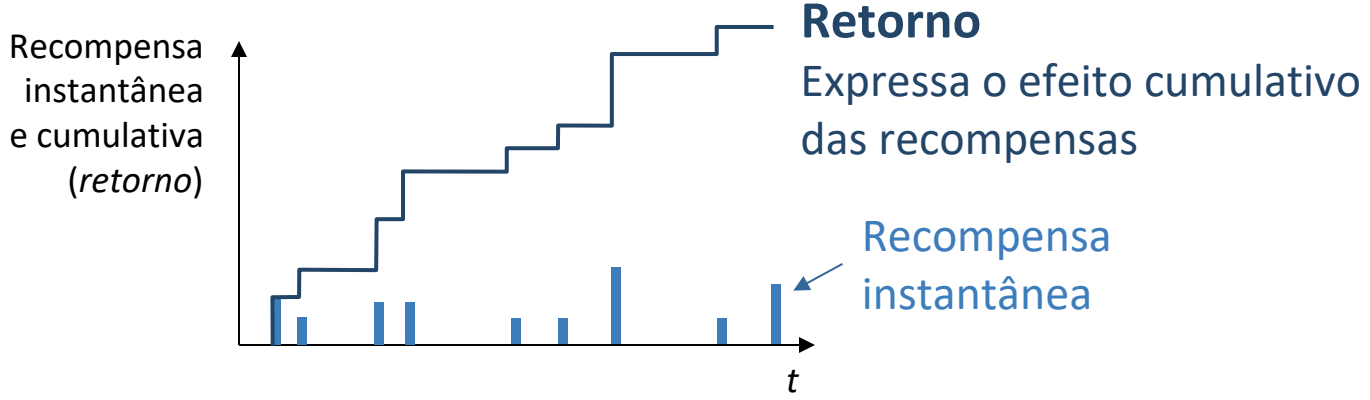
O **valor** (*utilidade*) desses estados e decisões pode não ser conhecido de imediato, acontecendo apenas **diferido no tempo**, em função dos encadeamentos de estados e decisões futuras

No caso geral, a própria evolução dos estados observados em função das acções realizadas pode não ser determinista, ou seja, estar sujeita a **incerteza**

Como decidir qual a acção a realizar?



RECOMPENSA E RETORNO



Tipos de retorno

Soma das recompensas

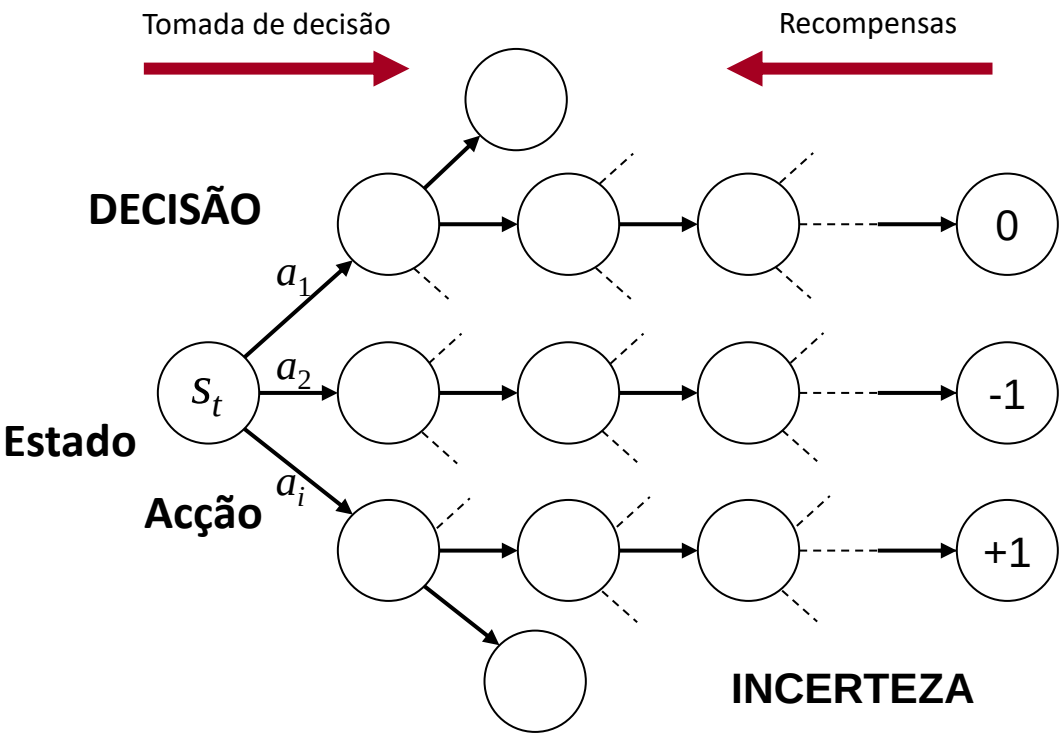
$$G_t = r_t + r_{t+1} + \ldots + r_{t+n} = \sum_{i=0}^{n} r_{t+i}$$

Soma das recompensas com desconto temporal

$$G_t = r_t + \gamma \cdot r_{t+1} + \gamma^2 \cdot r_{t+2} + \gamma^3 \cdot r_{t+3} + \ldots = \sum_{i=0}^{\infty} \gamma^i \cdot r_{t+i}$$

$\gamma \in [0,1]$ - Factor de desconto

PROBLEMA DA DECISÃO SEQUENCIAL



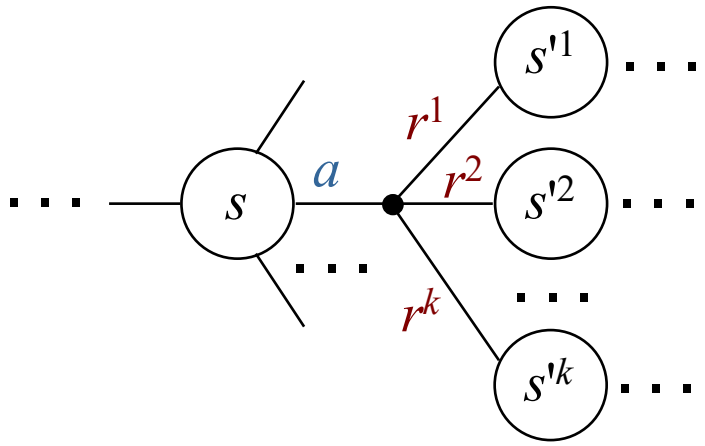
Como decidir qual a acção a realizar?

- Calcular o *retorno* para cada acção (soma das recompensas ao longo do tempo)
- Escolher a acção com maior retorno

Problema: Incerteza nas recompensas

PROBLEMA DA DECISÃO SEQUENCIAL

A realização de uma acção pode ter diferentes efeitos se o ambiente for não-determinista, ou seja, existe **incerteza no resultado das acções**



$$G_s^1 = r^1 + \gamma \cdot G_{s'1}$$

$$G_s^2 = r^2 + \gamma \cdot G_{s'2}$$

$$\dots$$

Utilidade de um estado (estimativa valor do retorno)**:**

$$U(s) = E\langle G_s \rangle = \lim_{n\to\infty} \frac{1}{n} \sum_{i=1}^{n} G_s^i$$

O PRINCÍPIO DA DECISÃO ÓPTIMA

A decisão óptima é a que maximiza a utilidade de cada estado observado

$$U^{\pi}(s) = \mathrm{E}\left\langle r_1 + \gamma r_2 + \gamma^2 r_3 + \ldots \right\rangle$$

Equação de Bellman

$$= \mathrm{E}\left\langle r_1 + \gamma U^{\pi}(s') \right\rangle$$

$$= \sum_a \pi(s,a) \underbrace{\sum_{s'} T(s,a,s') \left[R(s,a,s') + \gamma U^{\pi}(s') \right]}_{U(s,a)}$$

Política óptima π^*

Para cada estado s, escolher a acção a com maior utilidade

$$\pi^*(s) = \mathrm{argmax}_a \, U(s,a)$$

PROCESSOS DE DECISÃO DE MARKOV

- **Problemas**
  - Dimensão dos espaços de estados (*problema da dimensionalidade*)
  - Modelos desconhecidos

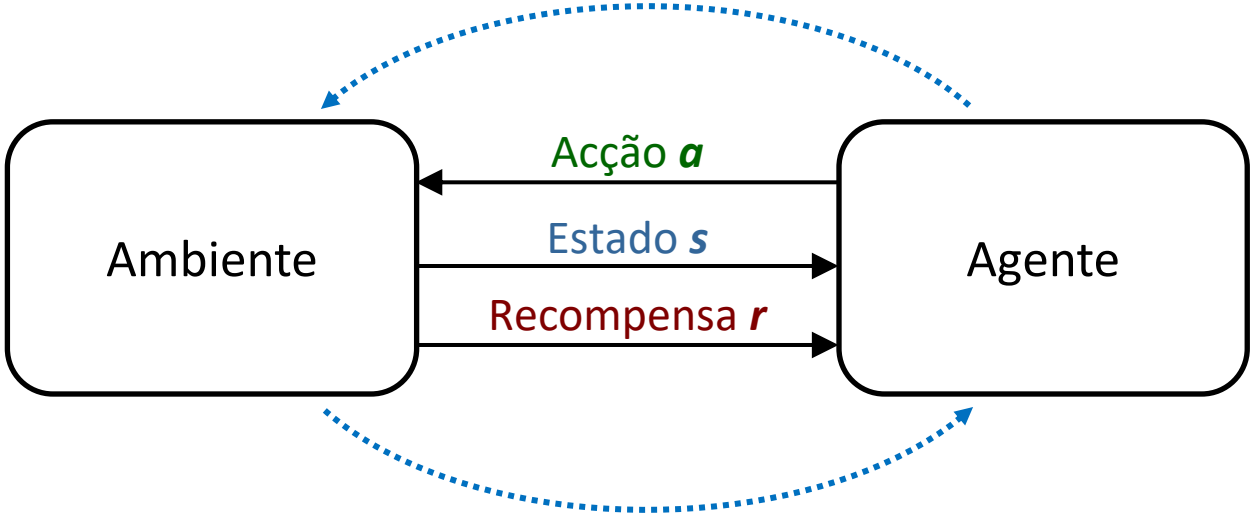
$$U(s,a) = \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma U(s')]$$

? ?

Resolução através de aprendizagem por reforço

APRENDIZAGEM POR REFORÇO

- **Aprendizagem de comportamentos**
  - Aprender "*como fazer*"
  - Com base numa medida de desempenho (*recompensa*) obtida por interacção directa com o ambiente
  - **Resolução iterativa e incremental de um problema de decisão sequencial através da experiência**



RETORNO DESCONTADO NO TEMPO

Soma das recompensas com desconto temporal

$\gamma \in [0,1]$ - Factor de desconto

$$G_t = r_t + \gamma \cdot \underbrace{r_{t+1} + \gamma^2 \cdot r_{t+2} + \gamma^3 \cdot r_{t+3} + \ldots}_{G_{t+1}} = \sum_{i=0}^{\infty} \gamma^i \cdot r_{t+i}$$

G_{t+1}
Retorno futuro

Corresponde à soma da recompensa imediata com o retorno futuro:

$$G_t = r_t + \gamma \cdot G_{t+1}$$

ESTIMATIVA DE VALOR DE ACÇÃO

Para um conjunto finito de n amostras (s, a, r, s', a') a estimativa de valor $Q(s,a)$ é calculada com base nas amostras observadas

Aprendizagem incremental a partir da experiência

$$s \rightarrow a \rightarrow r \rightarrow s' \rightarrow a' \rightarrow \ldots$$

$$Q(s,a) \approx E\langle G(s,a)\rangle$$ **Valor estimado de estado-acção**

$$G(s,a) = r + \gamma G(s',a')$$ **Retorno**

$$J(s,a) = r + \gamma Q(s',a')$$ **Retorno estimado**

$$\approx r + \gamma G(s',a')$$

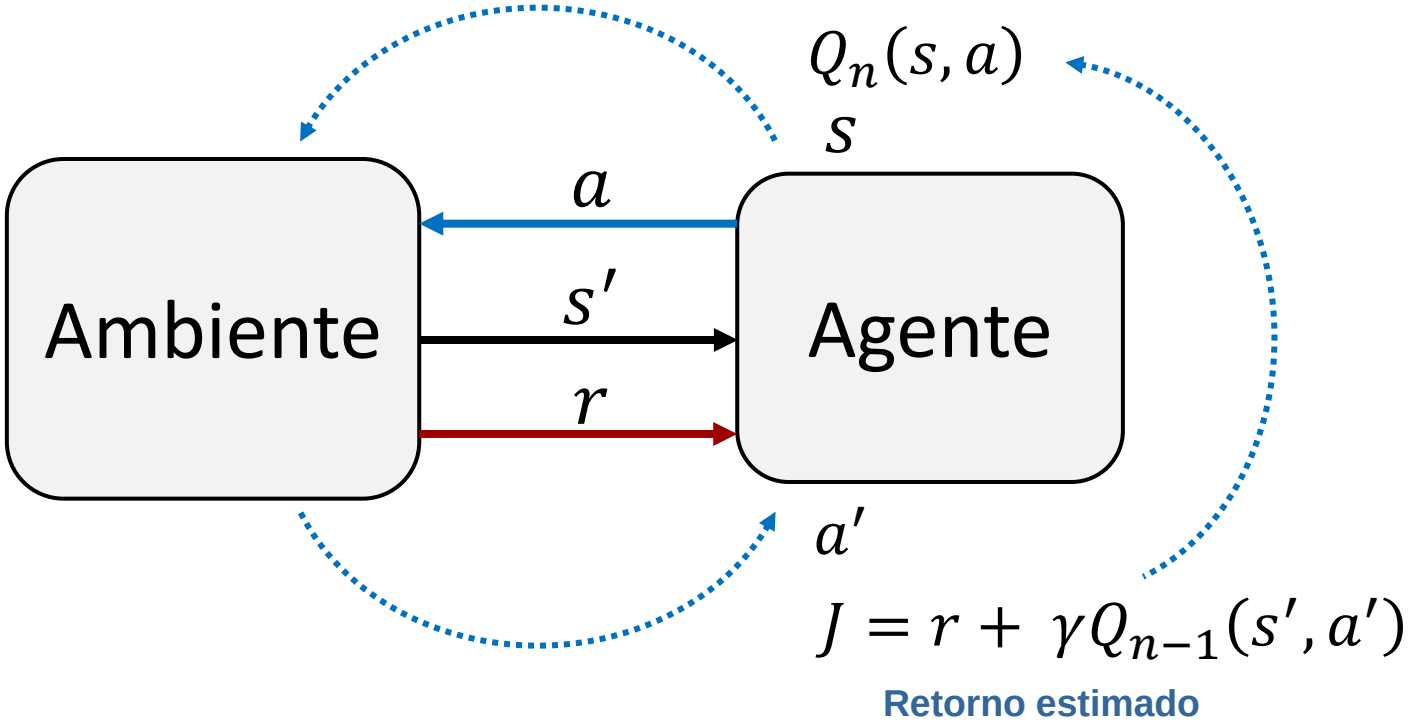
$$Q(s,a) = \frac{1}{n}\sum_{i=1}^{n} J(s,a)_i$$

$$E\langle x\rangle \approx \frac{1}{n}\sum_{i=1}^{n} x_i$$

Aproximação do valor esperado para um conjunto finito de n amostras

APRENDIZAGEM POR REFORÇO

Aprendizagem iterativa incremental



ESTIMATIVA DE VALOR DE ACÇÃO

Forma incremental da estimativa de valor $Q(s,a)$

$$Q_n(s,a) = \frac{1}{n}\sum_{i=1}^{n} J_i$$

$$Q_n(s,a) = \frac{1}{n}\left(J_n + \sum_{i=1}^{n-1} J_i\right)$$

$$J_i = r_i + \gamma Q_{n-1}(s'_i, a'_i)$$

Retorno estimado
(Valor alvo)

$$Q_n(s,a) = \frac{1}{n}\left(J_n + (n-1)\frac{1}{n-1}\sum_{i=1}^{n-1} J_i\right)$$

$$Q_n(s,a) = \frac{1}{n}\left(J_n + (n-1)Q_{n-1}(s,a)\right)$$

$$Q_n(s,a) = \frac{1}{n}\left(J_n + nQ_{n-1}(s,a) - Q_{n-1}(s,a)\right)$$

$$J_n = r_n + \gamma Q_{n-1}(s'_n, a'_n)$$
$$= r + \gamma Q_{n-1}(s,a)$$

Retorno estimado actual

$$Q_n(s,a) = Q_{n-1}(s,a) + \frac{1}{n}\left(J_n - Q_{n-1}(s,a)\right)$$

$$Q_n(s,a) = Q_{n-1}(s,a) + \alpha\left(r + \gamma Q_{n-1}(s',a') - Q_{n-1}(s,a)\right)$$

ESTIMATIVA DE VALOR DE ACÇÃO

Cálculo incremental da estimativa de valor $Q(s,a)$

Estimativa anterior do valor de no estado s realizar uma acção a

Retorno estimado
(Valor alvo)

$$Q_n(s,a) = Q_{n-1}(s,a) + \frac{1}{n}\left(r_n + \gamma Q_{n-1}(s',a') - Q_{n-1}(s,a)\right)$$

Erro de estimativa
Diferença entre a recompensa observada e a estimativa de valor da acção a

APRENDIZAGEM POR REFORÇO

Processo de aprendizagem por diferença temporal

- Actualização da estimativa de valor de acção com base na mudança desse valor entre instantes sucessivos
  - *Diferença temporal*

Passo de actualização da estimativa de valor $Q(s,a)$:

Nova Estimativa ← Estimativa + α(Retorno estimado – Estimativa)

Retorno estimado
(Valor alvo)

$$Q(s,a) \leftarrow Q(s,a) + \alpha\big(\overbrace{r + \gamma Q(s',a')}^{} - Q(s,a)\big)$$

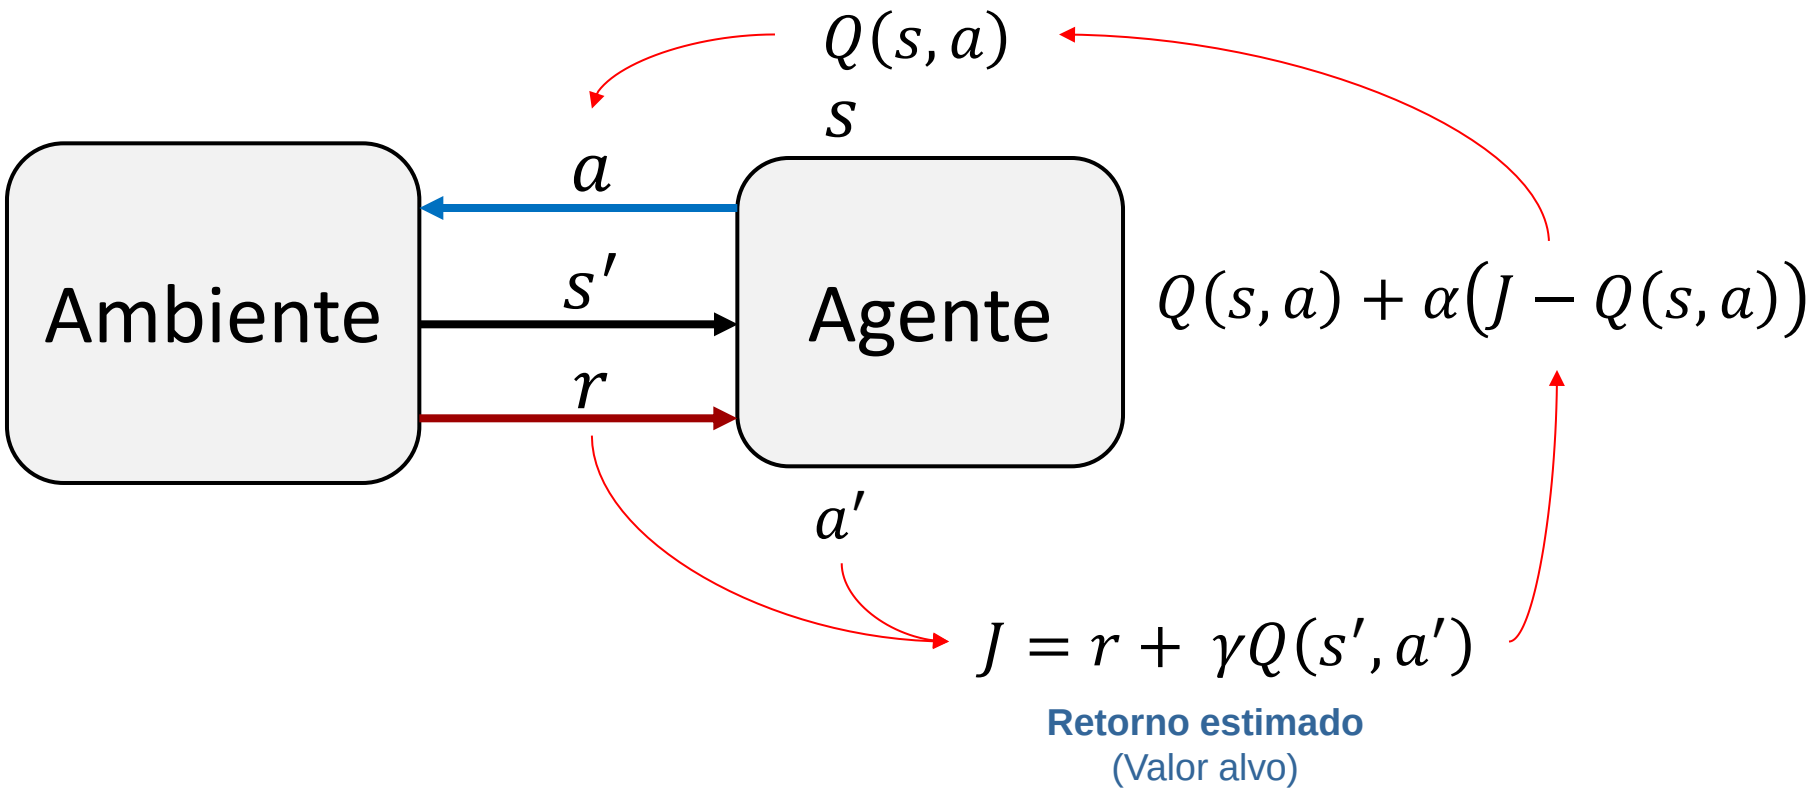
Erro de estimativa
(Diferença temporal)

$\alpha \in [0,1]$ - Factor de aprendizagem

APRENDIZAGEM POR REFORÇO

Processo de aprendizagem por diferença temporal

$$Q(s,a) \leftarrow Q(s,a) + \alpha\big(r + \gamma Q(s',a') - Q(s,a)\big)$$



ESTIMATIVA DE VALOR DE ACÇÃO

- **Propriedades**
  - Os valores da função *Q* **convergem** no limite se:
    - Cada par estado-acção (*s,a*) for visitado um número ilimitado de vezes
    - O parâmetro α tender para 0 no limite:

      $\alpha(s,a) \approx 1/n$

      Sendo *n* o número de vezes em que a acção *a* foi seleccionada no estado *s*

ESTIMATIVA DE VALOR DE ACÇÃO

- **Problemas não estacionários**
  - A distribuição de probabilidades muda com o tempo
  - O parâmetro α pode assumir valores diferentes de 1/*n* possibilitando uma ponderação não linear das recompensas ao longo do tempo

$$Q(s,a) \leftarrow Q(s,a) + \alpha\big(r + \gamma Q(s',a') - Q(s,a)\big)$$

$\alpha \in [0,1]$ - Factor de aprendizagem

Determina a relevância das recompensas em função do tempo

$\alpha \rightarrow 0$: Maior relevância das recompensas mais antigas

$$Q(s,a) \leftarrow Q(s,a)$$

$\alpha \rightarrow 1$: Maior relevância das recompensas mais recentes

$$Q(s,a) \leftarrow r + \gamma Q(s',a')$$

EXPLORAÇÃO vs. APROVEITAMENTO

- Duas vertentes da aprendizagem:
  - **Exploração**
    - Escolher uma acção que permita explorar o mundo para melhorar a aprendizagem
    - Tem por objectivo explorar todos os estados possíveis, tentando todas as acções
    - **Acção exploratória**
      - Obtenção de experiência
  - **Aproveitamento**
    - Escolher a acção que leva à melhor recompensa de acordo com a aprendizagem
    - **Acção sôfrega (*Greedy*)**
      - Utiliza o conhecimento resultante da aprendizagem para obter o máximo de recompensa

EXPLORAÇÃO vs. APROVEITAMENTO

- Acção de aproveitamento - sôfrega (*greedy*)
  - $a^* = \text{argmax}_a Q(s, a)$
- Aproveitamento

  Acção escolhida num instante *t* é a acção sôfrega

  $a_t = a^*$
- Exploração

  Acção escolhida num instante *t* é diferente da acção sôfrega, por exemplo, escolha aleatória

  $a_t \neq a^*$

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

- **Dilema explorar *vs*. aproveitar**
  - **Quando é que se aprendeu o suficiente para começar a aplicar o que se aprendeu?**

- **Estratégia ε-*greedy***

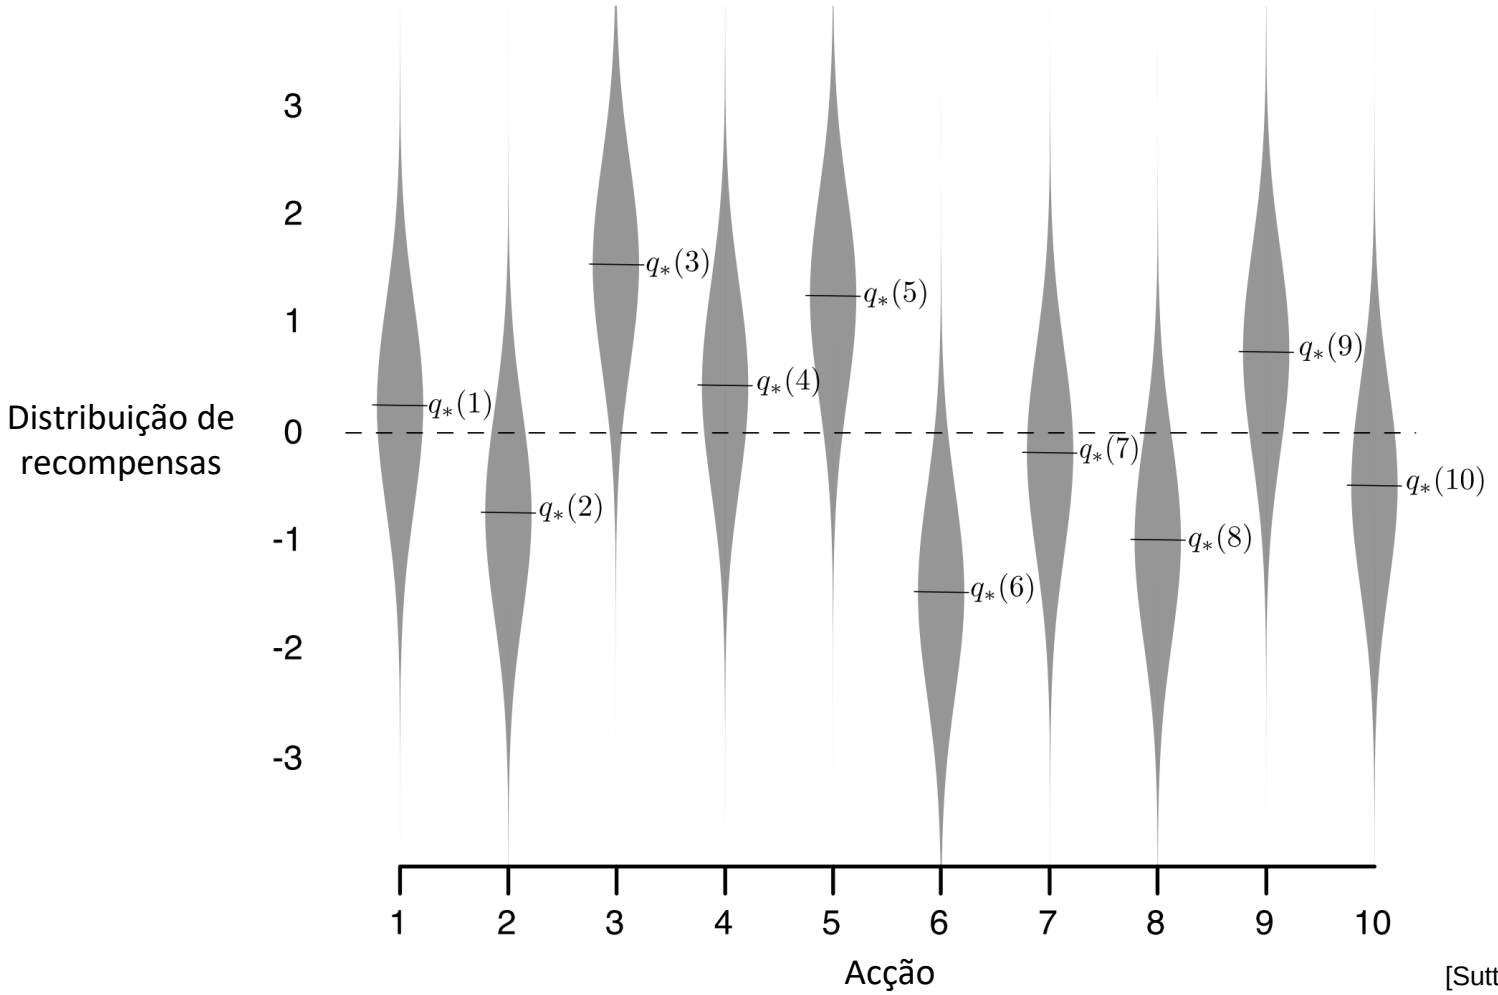
$$a_t = \begin{cases} a^* \text{ com probabilidade } 1 - \varepsilon \\ \text{acção aleatória com probabilidade } \varepsilon \end{cases}$$

ε - Probabilidade de exploração

Compromisso entre exploração e aproveitamento

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

Exemplo: Problema de selecção de acção com 10 acções possíveis, $q_*(a)$ indica o valor de cada acção, as recompensas são determinadas com base em distribuições de probabilidade com média $\mu = q^*(a)$ e variância $\sigma^2 = 1$

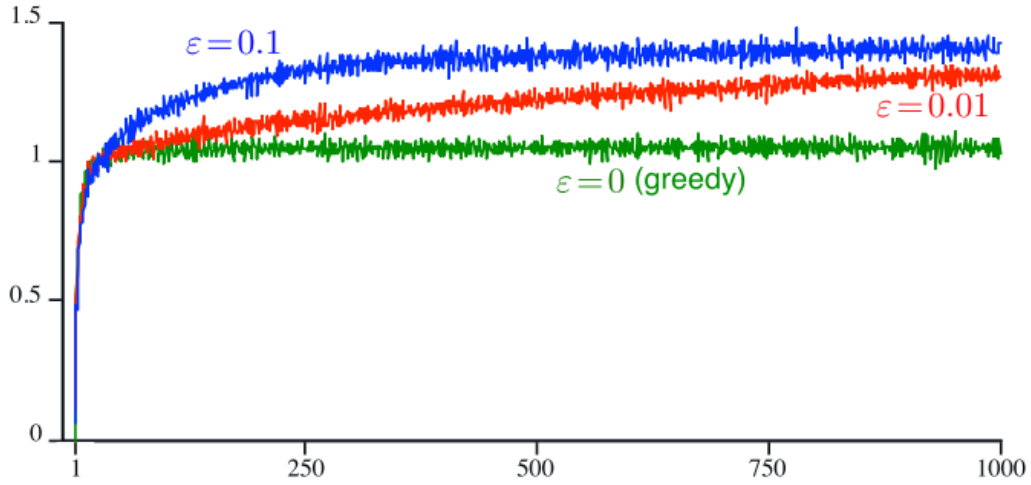


[Sutton & Barto, 2020]

ESTRATÉGIAS DE SELECÇÃO DE ACÇÃO

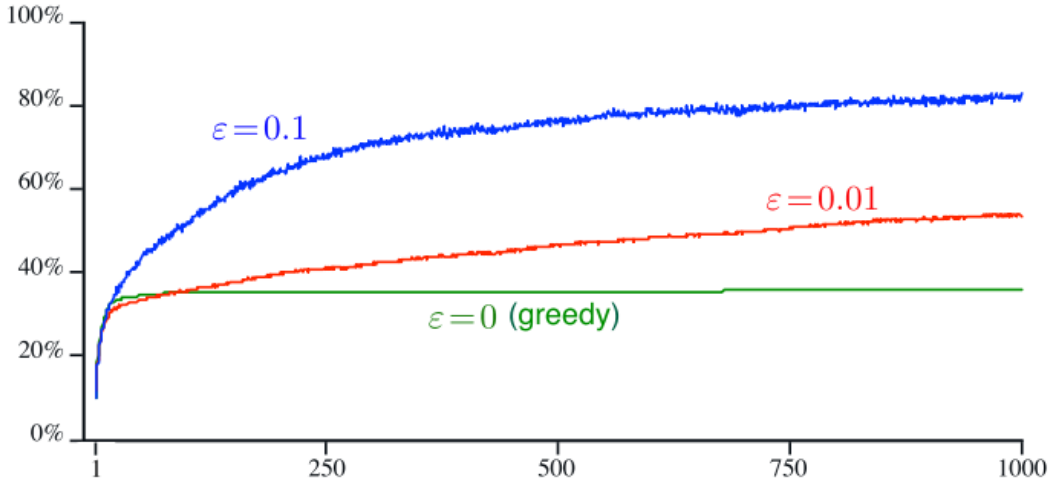
Exemplo:

Recompensa média obtida



Passos

% de escolha da acção óptima



Passos

[Sutton & Barto, 2020]

ALGORITMO *SARSA*

Controlo de aprendizagem com política de selecção de acção única ("*On-Policy*")

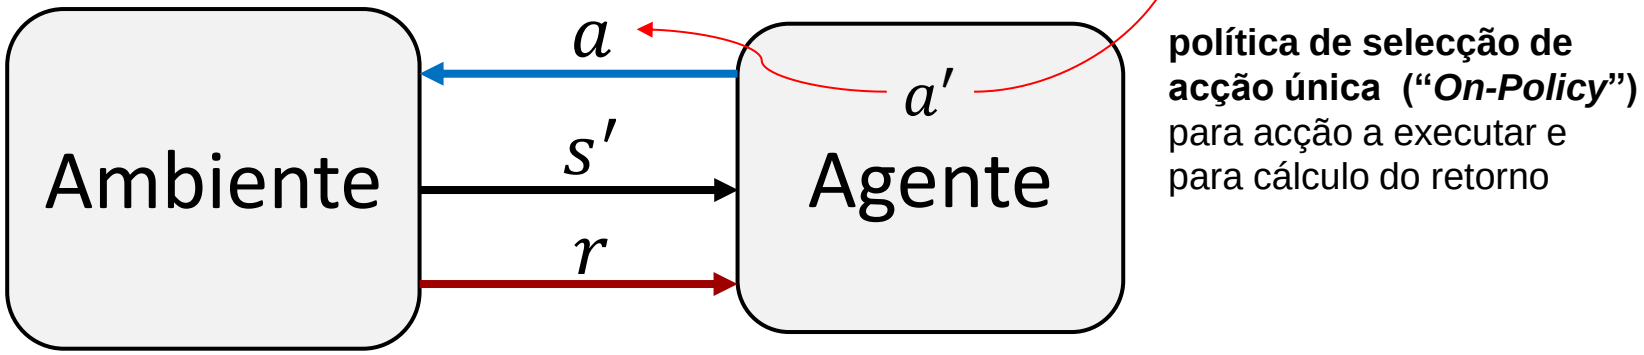
- Utilização da mesma política para acção e aprendizagem
- Exploração de todas as acções (por exemplo, estratégia ε-*greedy*)

Passo de aprendizagem:

$$s \rightarrow a \rightarrow r \rightarrow s' \rightarrow a'$$

Retorno esperado
(Valor alvo)

$$J = r + \gamma Q(s', a')$$



política de selecção de acção única ("*On-Policy*") para acção a executar e para cálculo do retorno

RETORNO DE ESTADOS TERMINAIS

Nos estados terminais, correspondentes ao final de um episódio, não existem acções seguintes a realizar

Passo de experiência com continuidade

$s \rightarrow a \rightarrow r \rightarrow s' \rightarrow a' \rightarrow \ldots$ Continuação de episódio

$J = r + \gamma Q(s', a')$

Retorno J depende de recompensas futuras

Passo de experiência final

$s \rightarrow a \rightarrow r \rightarrow s' \rightarrow \square$ Fim de episódio, s' é um estado terminal

$J = r$

Retorno J só depende de recompensa observada

APRENDIZAGEM POR REFORÇO *SARSA*

Aprendizagem incremental a partir da experiência:

$s \rightarrow a \rightarrow r \rightarrow s' \rightarrow a' \rightarrow \ldots$

Passo de aprendizagem

```
1.  aprender(s, a, r, s', a', final):
2.      if final:
3.          J = r                                  Retorno estimado do passo final
4.      else:
5.          J = r + γQ(s', a')
6.      Q(s, a) = Q(s, a) + α(J − Q(s, a))
```

ALGORITMO *SARSA*

Controlo de aprendizagem com política de selecção de acção única ("*On-Policy*")

1. Iniciar $Q(s, a)$
2. Repetir (por cada episódio)
3. Iniciar s
4. Seleccionar acção a para o estado s
5. Repetir (por cada passo)
6. Executar acção a, observar r e s'
7. Seleccionar acção a' para o estado s'
8. aprender(s, a, r, s', a')
9. Actualizar $s \leftarrow s'$, $a \leftarrow a'$
10. Até s ser um estado terminal

SELECÇÃO DE ACÇÃO ε-*greedy*

Seleccionar acção

```
1.  seleccionar_accao(s):
2.      if random() > ε:
3.          a = accao_sofrega(s)        Aproveitar conhecimento
4.      else:
5.          a = accao_exploracao()      Explorar
6.      return a
```

Obter acção sôfrega (*greedy*)

```
1.  accao_sofrega(s):
2.      shuffle(accoes)                 Escolha aleatória entre acções com igual valor
3.      return argmax_{a∈accoes} Q(s, a)
```

Obter acção de exploração

```
1.  accao_exploracao():
2.      return choice(accoes)
```

MEMÓRIA DE APRENDIZAGEM

Iniciar memória de aprendizagem

```
1.  iniciar(valor_omissao = 0.0):
2.      this.valor_omissao = valor_omissao
3.      Q = {}
```

Memória de aprendizagem $Q : (s, a) \rightarrow \mathbb{R}$

Obter $Q(s, a)$

```
1.  q(s, a):
2.      return Q.get((s, a), valor_omissao)
```

Actualizar memória de aprendizagem

```
1.  actualizar(s, a, q):
2.      Q[(s, a)] = q
```

REFERÊNCIAS

[Sutton & Barto, 2020]

R. Sutton, A. Barto, “Reinforcement Learning: An Introduction”, 2nd Edition, MIT Press, 2020

[Poole & Mackworth, 2010]

D. Poole, A. Mackworth, Artificial Intelligence: Foundations of Computational Agents, Cambridge University Press, 2010

[Barnard, 2003]

C. Barnard, “Animal Behaviour: Mechanism, Development, Ecology and Evolution”, Prentice Hall, 2003

[Koppula, 2020]

R. Koppula, “Exploration vs. Exploitation In Reinforcement Learning”, *https://www.manifold.ai/exploration-vs-exploitation-in-reinforcement-learning*, 2020