APRENDIZAGEM POR REFORÇO

Luís Morgado

ISEL-DEI

POLÍTICA COMPORTAMENTAL ÓPTIMA

Algoritmo *SARSA* - Propagação de valor

No algoritmo SARSA o controlo de aprendizagem utiliza uma estratégia de selecção de acção única para execução e actualização de valor ("*On-Policy*")

- A actualização da estimativa de valor é realizada com base na acção escolhida para realização (por exemplo, ε-*greedy*)

Propagação de valor tendo por base a estimativa de valor $Q(s',a')$ associada ao estado seguinte s' e à acção seguinte a'

$$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma Q(s',a') - Q(s,a)]$$

A acção escolhida para execução, por exemplo, com base uma estratégia de selecção de acção ε-*greedy*, pode ser uma acção de exploração, e por isso não corresponder à decisão óptima, pelo que **não existe garantia da aprendizagem convergir para a política óptima**

POLÍTICA COMPORTAMENTAL ÓPTIMA

- **Função valor de estado-acção**

$$Q^{\pi}(s,a)$$

- **Valor óptimo**

$$Q^{*}(s,a) = \max_{\pi} Q^{\pi}(s,a)$$

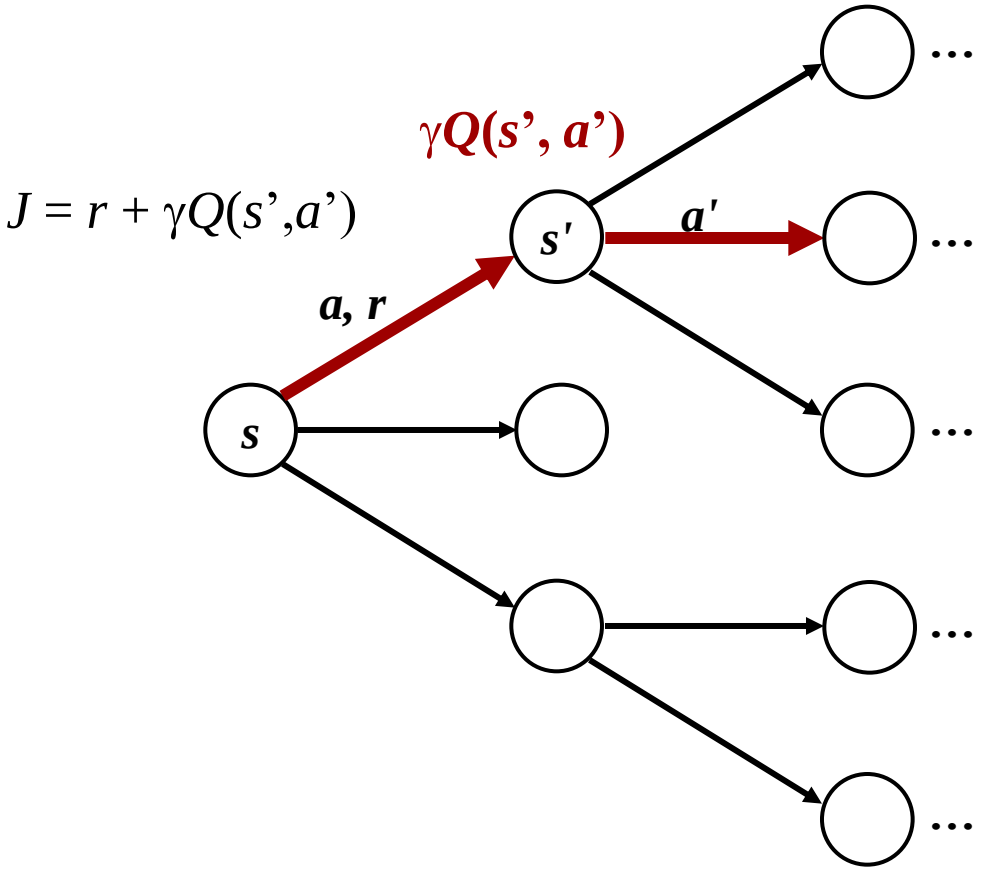
- **Política óptima**

$$\pi^{*}(s) = \arg\max_{a} Q^{*}(s,a)$$

Política sôfrega ("*greedy*") em relação a $Q^{*}(s, a)$

ALGORITMO *SARSA*

Estimativa de retorno *J* (valor estimado de realizar a acção *a* num estado *s*) **considerando a acção *a'* seleccionada para realização**



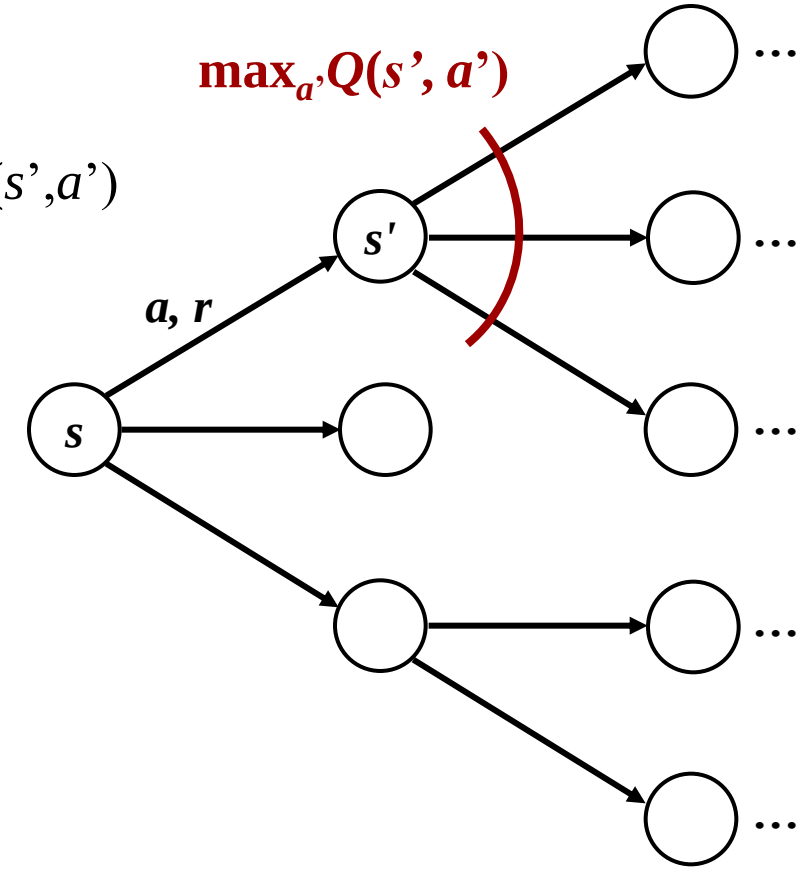
A acção utilizada para propagação de valor é a que foi seleccionada para ser executada, podendo ser uma acção de exploração, pelo que pode não ser a que corresponde à política óptima, ou seja, a que maximiza a respectiva estimativa de valor $\max_{a'} Q(s',a')$

$$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma Q(s',a') - Q(s,a)]$$

ALGORITMO *Q-LEARNING*

Estimativa de retorno *J* (valor estimado de realizar a acção *a* num estado *s*) **considerando a acção correspondente à melhor estimativa *Q*(*s'*,*a'*)**

$J = r + \gamma \max_{a'} Q(s',a')$



Das várias acções possíveis no estado s' é escolhida para propagação de valor a que maximiza a respectiva estimativa de valor $\max_{a'} Q(s',a')$

$$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$$

ALGORITMO *Q-LEARNING*

Propagação de valor

No algoritmo *Q-Learning* o controlo de aprendizagem utiliza políticas distintas para execução de acção e para actualização de valor ("*Off-Policy*")

- A actualização da estimativa de valor é realizada com base na acção que maximiza a o valor para o estado seguinte – estratégia sôfrega (*greedy*)

Propagação de valor tendo por base a maximização do valor $\max_{a'} Q(s',a')$ associado ao estado seguinte s'

$$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$$

A acção escolhida para actualização da estimativa de valor tem por base a estratégia de selecção de acção sôfrega (*greedy*), a qual maximiza a estimativa de valor associada ao estado seguinte, de modo a que a **aprendizagem possa convergir para a política óptima**

ALGORITMO *Q-LEARNING*

Controlo de aprendizagem com estratégias de selecção de acção diferentes para execução e para actualização de valor ("*Off-Policy*")

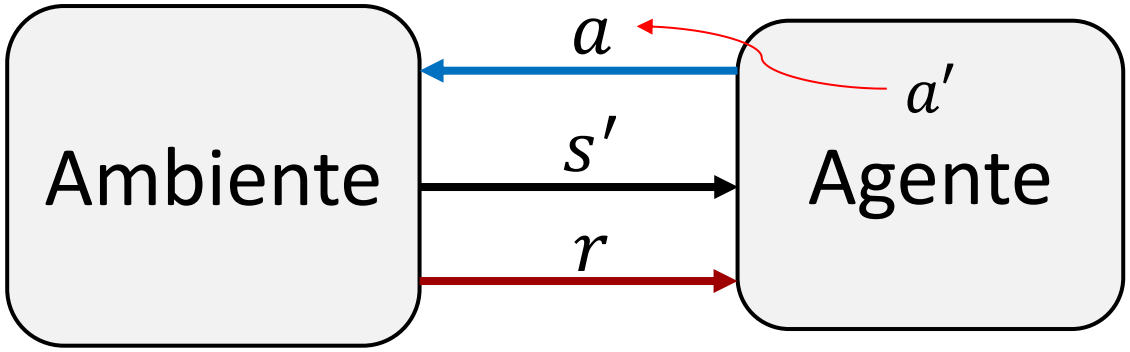
- A execução de acção utiliza uma estratégia de selecção de acção com exploração (por exemplo, ε-*greedy*)
- A actualização de estimativas de valor utiliza uma estratégia sôfrega (*greedy*)

Passo de aprendizagem:

$$s \rightarrow a \rightarrow r \rightarrow s'$$

Retorno esperado
(Valor alvo)

$$J = r + \gamma \max_{a'} Q(s', a')$$



política de selecção de acção diferente ("*Off-Policy*") para acção a executar e para cálculo do retorno

APRENDIZAGEM POR REFORÇO *Q-LEARNING*

Aprendizagem incremental a partir da experiência com estratégias de selecção de acção diferentes para execução e para actualização de valor

$s \rightarrow a \rightarrow r \rightarrow s' \rightarrow \ldots$

Passo de aprendizagem

```
1.  aprender(s, a, r, s', final):
2.      a' = sel_accao.accao_sofrega(s')      Obter acção de maximização de Q(s,a)
3.      aprender(s, a, r, s', a', final)
```

sel_accao Instância do mecanismo de selecção de acção

ALGORITMO *Q-LEARNING*

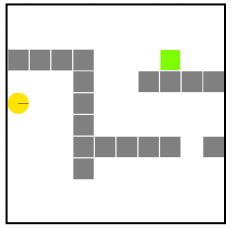
Controlo de aprendizagem com estratégias de selecção de acção diferentes para execução e para actualização de valor ("*Off-Policy*")

1. Iniciar $Q(s,a)$
2. Repetir (por cada episódio)
3. Iniciar s
4. Repetir (por cada passo)
5. Seleccionar acção a para o estado s
6. Executar a acção a, observar r e s'
7. aprender(s, a, r, s')
8. Actualizar $s \leftarrow s'$
9. Até s ser um estado terminal

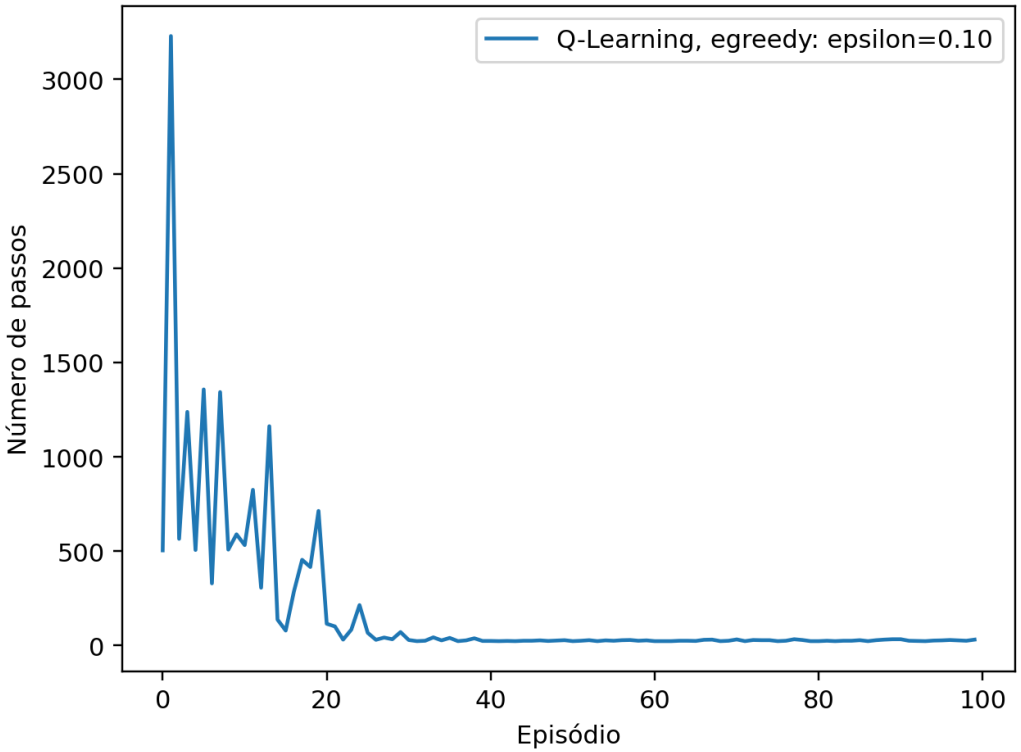
ALGORITMO *Q-LEARNING*

Exemplo:

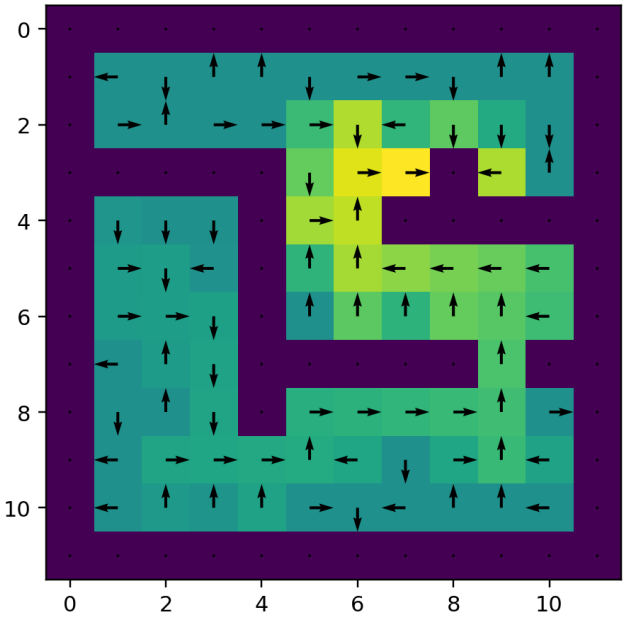
Aprendizagem de recolha de alvos num ambiente bidimensional



Evolução do processo de aprendizagem



Política resultante da aprendizagem após 100 episódios

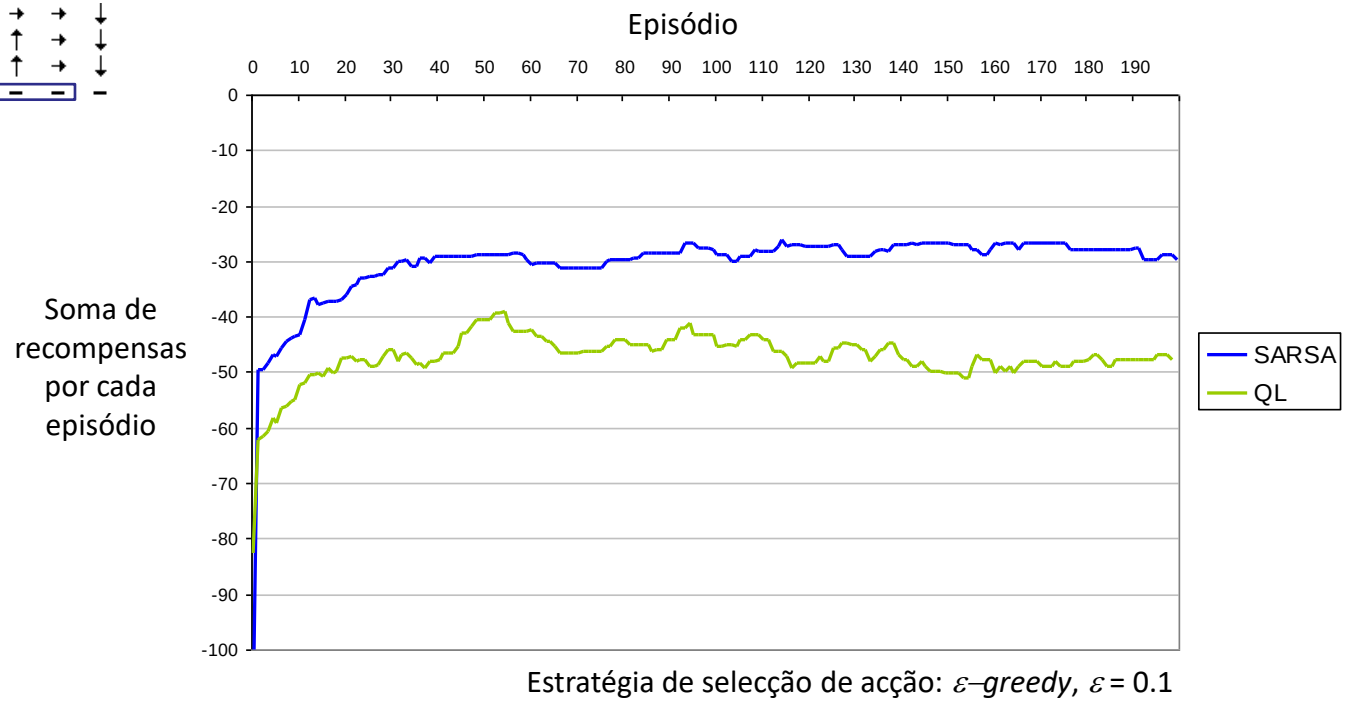


Cores indicam valor estimado de cada estado $V(s) = \max_a Q(s,a)$

SARSA vs. *Q-LEARNING*

Exemplo: Problema com possibilidade de grandes perdas

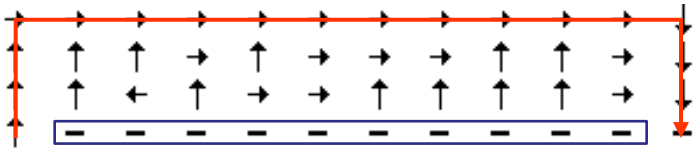




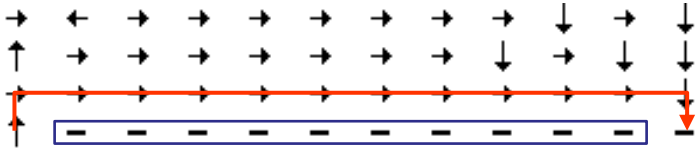
Estratégia de selecção de acção: ε–*greedy*, $\varepsilon = 0.1$

Políticas resultantes da aprendizagem:

SARSA: Política mais robusta em relação a perdas



Q-Learning: Política óptima (maximiza retorno)



PROCESSO DE APRENDIZAGEM

- **Dois tipos de aprendizagem por reforço**
  - **Política de selecção de acção única (*On-policy*)**
    - Utilização da mesma política de selecção de acção para comportamento e para propagação de valor
    - Propagação de valor com todas as acções exploradas
      - Expressa todos os ganhos e perdas
    - Exemplo:
      - Algoritmo **SARSA**

PROCESSO DE APRENDIZAGEM

- **Dois tipos de aprendizagem**
  - **Políticas de selecção de acção diferenciadas (*Off-policy*)**
    - Utilização de diferentes políticas de selecção de acção para comportamento e para propagação de valor
    - Escolha de acções para propagação de valor que maximizam a estimativa de valor $Q(s,a)$
      - Propagação de valor de forma sôfrega
      - **Optimização da função valor $Q(s,a)$**

DILEMA EXPLORAR / APROVEITAR

- **Para convergir para o valor óptimo**
  - Não se pode apenas explorar
  - Não se pode apenas aproveitar
- **Estratégia Sôfrega (*Greedy*)**
  - Mínimos/máximos locais
- **Nunca se pode parar de explorar**
  - Convergência assimptótica
- **Deve-se progressivamente reduzir a exploração**
  - Estratégia sôfrega no limite da exploração

ALGORITMO *Q-LEARNING*

- **Propriedades**
  - Os valores da matriz *Q* **convergem** no limite se:
    - Se cada par estado-acção (*s,a*) for visitado um número ilimitado de vezes
    - O parâmetro α tender para 0 no limite
  - No limite a estratégia ε-*greedy* de aproveitamento de *Q*(*s,a*) converge para a **política óptima**

- **Estes requisitos podem ser satisfeitos através de:**
  - $\alpha(s,a) \approx 1/n$
    - Sendo *n* o número de vezes que a acção ***a*** foi seleccionada em ***s***
  - Estratégia de selecção de acção ε-*greedy* com $\varepsilon \approx 1/t$
    - Sendo ***t*** função do tempo ou do número de tentativas de aprendizagem

REFERÊNCIAS

[Sutton & Barto, 2020]
R. Sutton, A. Barto, “Reinforcement Learning: An Introduction”, 2nd Edition, MIT Press, 2020

[Poole & Mackworth, 2010]
D. Poole, A. Mackworth, Artificial Intelligence: Foundations of Computational Agents, Cambridge University Press, 2010

[Barnard, 2003]
C. Barnard, “Animal Behaviour: Mechanism, Development, Ecology and Evolution”, Prentice Hall, 2003